

Examen « Optimisation Numérique et Sciences des Données »

Durée 2 heures • Feuille manuscrite au format A4 autorisée • Calculatrice non autorisée

1 Questions de cours

- Une fonction f quadratique atteint son minimum en $\mathbf{x}_*$. La Figure 1 représente la distance entre la solution $\mathbf{x}_*$ et les itérées $\mathbf{x}_k$ d'un algorithme de descente de gradient, pour 3 stratégies de pas différentes : pas constant, pas estimé par backtracking, et pas optimal. Associer, en expliquant brièvement votre réponse, chacune des trois courbes à la stratégie correspondante.




FIGURE 1 – Descente de gradient

- Les factorisations suivantes sont-elles des décompositions en valeurs singulières ? Justifier dans chaque cas.

$$(a) A = \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & 1 \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \quad (b) B = \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \\ \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$(c) C = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & -1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \quad (d) D = \begin{bmatrix} 1 & 2 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 1 & 1 \end{bmatrix}.$$

- On considère le réseau à deux couches représenté en Figure 2, où l'on a explicitement représenté la fonction non-linéaire σ et les biais b_1, b_2 :

- Exprimer les sorties intermédiaires z_1 et z_2 en fonction de l'entrée $\mathbf{x} = [x_1 \ x_2 \ x_3]^\top$ des vecteurs de poids $\mathbf{w}_1 = [w_{11} \ w_{12} \ w_{13}]^\top$, $\mathbf{w}_2 = [w_{21} \ w_{22} \ w_{23}]^\top$, et des biais b_1, b_2 .
- Exprimer de même la sortie finale y en fonction de $\mathbf{x}$ et des différents paramètres du réseau.




FIGURE 2 – Réseau de neurones

2 Optimisation numérique

On considère un vecteur $\mathbf{x}_0 \in \mathbb{R}^3$ inconnu, et des observations $\mathbf{y} \in \mathbb{R}^3$ de la forme

$$\mathbf{y} = \mathbf{A}\mathbf{x}_0 + \varepsilon, \quad \mathbf{A} = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \\ 1 & -1 & -2 \end{bmatrix}$$

où $\varepsilon \in \mathbb{R}^3$ modélise les erreurs de mesures. On souhaite estimer $\mathbf{x}_0$ à partir de $\mathbf{y}$ en résolvant le problème des moindres carrés

$$\min_{\mathbf{x} \in \mathbb{R}^3} \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2 \quad (1)$$

où $\|\cdot\|_2$ est la norme euclidienne usuelle.

1. Ce problème admet-il un minimiseur unique ? pas de minimiseur ? plusieurs minimiseurs ? Justifier votre réponse.
2. On considère le critère régularisé

$$f(\mathbf{x}) := \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2 + \frac{1}{2} \|\mathbf{x}\|_2^2.$$

Montrer que $f(\mathbf{x})$ peut s'écrire sous la forme

$$\frac{1}{2} \mathbf{x}^\top \mathbf{P} \mathbf{x} + \mathbf{q}^\top \mathbf{x} + r$$

où vous explicitez $\mathbf{P}$, $\mathbf{q}$ et r .

3. En détaillant les calculs, exprimer le gradient $\nabla f(\mathbf{x})$ en fonction de $\mathbf{A}$ et $\mathbf{y}$.
4. En expliquant votre démarche, exprimer la solution du problème d'optimisation

$$\min_{\mathbf{x} \in \mathbb{R}^3} f(\mathbf{x})$$

en fonction de $\mathbf{A}$ et $\mathbf{y}$.

3 Classification

3.1 Séparateur linéaire

On considère un jeu de données constitué de 8 échantillons dans $\mathbb{R}^2$, labellisés positivement et négativement :

- classe +1 : (1, 2), (3/2, 3), (3, 2), (3, 4)
- classe -1 : (1, 0), (2, 1), (3, 0), (2, -1)

1. Représenter les observations sur la Figure 3a en utilisant 2 couleurs (ou 2 formes) différentes pour distinguer les classes.
2. Représenter l'hyperplan optimal au sens des SVM. Donner son équation et calculer sa marge.
3. Quels sont les vecteurs de support ?

3.2 Astuce du noyau

On considère un nouveau jeu de données, constitué de 4 échantillons étiquetés positivement : (2, 2), (2, -2), (-2, -2), (-2, 2) et 4 échantillons étiquetés négativement : (1, 1), (1, -1), (-1, -1), (-1, 1).

1. Représenter ces observations sur la Figure 3b avec deux couleurs différentes. Les classes sont-elles linéairement séparables ?
2. Expliquer en quelques lignes le principe de l'astuce du noyau.
3. On considère la fonction de redescription suivante :

$$\varphi(\mathbf{x}) = \begin{cases} (4 - x_2 + |x_1 - x_2| + 1, 4 - x_1 + |x_1 - x_2| + 1) & \text{si } \|x\|_2 > 2 \\ (x_1, x_2) & \text{sinon} \end{cases}$$

Calculer les coordonnées des échantillons dans l'espace de redescription et les représenter en Figure 3c en utilisant les mêmes couleurs qu'en 1.

4. Tracer sur la même figure l'hyperplan optimal au sens des SVM, donner son équation et calculer sa marge.
5. Quelle est la classe attribuée à un échantillon de coordonnée (6, 6) dans l'espace d'origine ?
6. Donner un exemple d'une autre fonction de redescription $\psi : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ qui aurait pu être utilisée pour classifier ces données.

4 Décompositions matricielles

1. On considère dans cette question la matrice $\mathbf{A}$ définie dans l'exercice 2 ci-dessus.
 - (a) Calculer la matrice $\mathbf{B} = \mathbf{A}^\top \mathbf{A}$.
 - (b) Quel est le rang de $\mathbf{B}$? En déduire une valeur propre et un vecteur propre de $\mathbf{B}$ (on rappelle qu'un couple valeur/vecteur propre est un couple $(\lambda, \mathbf{v})$ tel que $\mathbf{v} \neq 0$ et $\mathbf{B}\mathbf{v} = \lambda\mathbf{v}$).
 - (c) Quel est le rang de $\mathbf{B} - 6\mathbf{I}_3$? Trouver deux vecteurs $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^3$ non colinéaires (et non nuls) tels que $\mathbf{B}\mathbf{v}_1 = 6\mathbf{v}_1$ et $\mathbf{B}\mathbf{v}_2 = 6\mathbf{v}_2$.
 - (d) Trouver les valeurs singulières de $\mathbf{A}$, ainsi que les vecteurs singuliers droits associés.
2. Soit $\mathbf{X} \in \mathbb{R}^{m \times n}$, pour $m, n \in \mathbb{N}$ donnés. On note

$$\mathbf{X} = \mathbf{U} \operatorname{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0) \mathbf{V}^\top$$




FIGURE 3 – Classification

la décomposition en valeurs singulières de $\mathbf{X}$, avec $\sigma_1 \geq \dots \geq \sigma_r > 0$. Montrer que

$$\|X\|_F = \sqrt{\sum_{j=1}^r \sigma_j^2}$$

où $\|\mathbf{X}\|_F = \sqrt{\text{Tr}(\mathbf{X}^\top \mathbf{X})}$ est la norme de Frobenius.