

Optimisation Numérique et Sciences des Données

Sciences des données – Décompositions matricielles et tensorielles

Paul Catala (CRAN, UL)

paul.catala(at)univ-lorraine.fr

Master Ingénierie des Systèmes Complexes M2 ISC 925

Semestre 9 – 2024

Basé sur des cours de D. Brie, S. Miron et K. Usevich

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications

- Données complexes, nombreuses, en grande dimension : images, vidéos, sons, champs électriques ou magnétiques, textes, graphes relationnels, etc...

Ce qu'il faut attendre de ce cours : pour un certain type de données...

- **... comment représenter efficacement ces données ?**

→ Modèles de complexité faible (e.g. faible rang, parcimonie)
Réduction de dimension


- **... quelles méthodes pour traiter ces données ?**

→ Régression, classification

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications

■ Données sous forme matricielle :

- Signaux continus / données temporelles $\mathbf{x}(t)$



- Images en niveaux de gris / discrétisation d'une fonction $f(x, y)$
- N échantillons, p variables explicatives : matrice $N \times p$

■ Matrices à partir des données :

- Statistiques des données : matrice de covariance $\mathbf{E}(\mathbf{xx}^T)$, histogrammes 2D
- Matrices d'adjacence / laplacienne pour des données sur graphes

Matrices : notations

- **Matrice** : $\mathbf{X} \in \mathbb{R}^{m \times n}$, m $\begin{array}{|c|} \hline \mathbf{X} \\ \hline \end{array}$ n
- **éléments** de la matrice : $\mathbf{X}_{ij}$
- **lignes** : $\mathbf{X}_{i,:} = [(\mathbf{X})_{i1}, (\mathbf{X})_{i2}, \dots, (\mathbf{X})_{iJ}]$
- **colonnes** : $\mathbf{X}_{:,j} = [(\mathbf{X})_{1j}, (\mathbf{X})_{2j}, \dots, (\mathbf{X})_{Ij}]$
- **sous-matrice** : $\mathbf{X}_{i_1:i_2, j_1:j_2} = [\mathbf{X}_{ij}]_{i=i_1, j=j_1}^{i_2, j_2}$
- **transposition, inversion** : $(\cdot)^T, (\cdot)^{-1}$
- **matrice diagonale** :

$$\text{diag}\{a_1, \dots, a_p\} = \begin{bmatrix} a_1 & & \\ & \ddots & \\ & & a_p \end{bmatrix}$$

Dans MATLAB : $\mathbf{X}(\mathbf{i}, \mathbf{j})$, $\mathbf{X}(\mathbf{i}, :)$, $\mathbf{X}(:, \mathbf{j})$

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{X} = \mathbf{a}_1 \mathbf{s}_1^T + \cdots + \mathbf{a}_p \mathbf{s}_p^T = \sum_{k=1}^p \mathbf{a}_k \mathbf{s}_k^T \quad (\text{Décomposition})$$

$$\text{Notation : } \mathbf{A} = [\mathbf{a}_1 | \dots | \mathbf{a}_p]; \quad \mathbf{S} = [\mathbf{s}_1 | \dots | \mathbf{s}_p] \quad \rightsquigarrow \quad \mathbf{X} = \mathbf{A} \mathbf{S}^T$$

$$\begin{matrix} & n \\ & \boxed{\mathbf{X}} \\ m & \end{matrix} = \begin{matrix} & \mathbf{s}_1^T \\ | & \text{---} \\ \mathbf{a}_1 & \\ | & \end{matrix} + \cdots + \begin{matrix} & \mathbf{s}_p^T \\ | & \text{---} \\ \mathbf{a}_p & \\ | & \end{matrix} = \begin{matrix} & p \\ & \boxed{\mathbf{A}} \\ m & \end{matrix} \begin{matrix} n \\ \boxed{\mathbf{S}^T} \\ p & \end{matrix} \quad (\text{Factorisation})$$

Rang d'une matrice :

1. nombre minimal de matrices de rang 1 permettant de représenter $\mathbf{X}$
2. taille minimale de la factorisation $\mathbf{A} \mathbf{B}^T$

Exemple de matrices faible rang



(a) rang =



(b) rang =



(c) rang =

Exemple de matrices faible rang



(d) rang = 1



(e) rang =



(f) rang =

Exemple de matrices faible rang



(g) rang = 1



(h) rang = 2



(i) rang = 3


- Les décompositions/factorisations de matrices ne sont **pas uniques** !
Par exemple, avec T orthogonale, *i.e.* $T^{-1} = T^{\top}$, on a toujours

$$X = AS^{\top} = AT(ST)^{\top}$$

↪ la factorisation est aveugle aux **permutations** de lignes/colonnes, **agrandissement/rétrécissement**, **rotations**, etc...

- Ajout de **contraintes** (orthogonalité, non-négativité, indépendance, ...) pour retrouver l'unicité
↪ décompositions particulières : SVD, NMF, ICA, ...

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications



SVD (“economy size”)

$$\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

The diagram shows the SVD decomposition of matrix $\mathbf{X}$ into three matrices: $\mathbf{U}$, $\mathbf{\Sigma}$, and $\mathbf{V}^T$. Matrix $\mathbf{X}$ is represented by a rectangle with height m and width n . It is equal to the product of matrix $\mathbf{U}$ (height m , width p), matrix $\mathbf{\Sigma}$ (height p , width p), and matrix $\mathbf{V}^T$ (height p , width n). Matrix $\mathbf{\Sigma}$ is shown as a square containing the singular values $\sigma_1, \dots, \sigma_p$ along its diagonal.

avec $p = \min(m, n)$

$\mathbf{X}$: $(m \times n)$ matrice de données

$\mathbf{U} = [\mathbf{u}_1 | \dots | \mathbf{u}_p]$: $(m \times p)$ matrice orthogonale (vecteurs singuliers gauches)

$\mathbf{V} = [\mathbf{v}_1 | \dots | \mathbf{v}_p]$: $(n \times p)$ matrice orthogonale (vecteurs singuliers droits)

$\mathbf{\Sigma} = \text{diag}\{\sigma_1, \dots, \sigma_p\}$: $(p \times p)$ matrice diagonale


$\sigma_1 \geq \dots \geq \sigma_p \geq 0$: valeurs singulières

rang de $\mathbf{X}$ = nombre de valeurs singulières non-nulles

SVD et rang




rang=2




rang=2

rang=3



rang=3

rang= ?



rang= ?

$$\mathbf{X} \mathbf{X}^T = \mathbf{U} \Sigma^2 \mathbf{U}^T$$

$$\mathbf{X}^T \mathbf{X} = \mathbf{V} \Sigma^2 \mathbf{V}^T$$

- Les **vecteurs singuliers gauches** $\mathbf{U}$ sont les vecteurs propres de $\mathbf{X} \mathbf{X}^T$.
- Les **vecteurs singuliers droits** $\mathbf{V}$ sont les vecteurs propres de $\mathbf{X}^T \mathbf{X}$.
- Les **valeurs singulières** (non-nulles) de $\mathbf{X}$ sont les racines carrées des valeurs propres (non-nulles) de $\mathbf{X}^T \mathbf{X}$ ou $\mathbf{X} \mathbf{X}^T$.

- La SVD est **unique** (sous certaines conditions).
- La norme de Frobenius de $\mathbf{X}$: $\|\mathbf{X}\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_p^2}$.
- La SVD donne la "meilleure" approximation de rang faible d'une matrice :
la solution du problème d'optimisation

$$\min \|\mathbf{X} - \mathbf{X}_r\|_F \quad \text{s. c.} \quad \text{rang}(\mathbf{X}_r) = r, \quad r < p$$

est donnée par :

$$\mathbf{X}_r = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

Forme matricielle : $\mathbf{X}_r = \mathbf{U}_{:,1:r} \mathbf{\Sigma}_{1:r,1:r} (\mathbf{V}_{:,1:r})^T$

L'erreur de la meilleure approximation : $\|\mathbf{X} - \mathbf{X}_r\|_F = \sqrt{\sigma_{r+1}^2 + \dots + \sigma_p^2}$

- Compression et débruitage (traitement d'image, sismique, ...).
- Extraction des motifs et analyse des textures.
- Analyse en composantes principales (statistique, systèmes de recommandations,...).
- Résolution de systèmes d'équations linéaires (calcul de la pseudo-inverse).

Algorithmes pour la SVD


Méthodes pour la décomposition en valeurs propres, algorithmes *gloutons* (Gram-Schmidt, ...), factorizations QR, *etc.*

Débruitage et compression d'image (1)



Image originale




Image bruitée



Débruitage et compression d'image (2)



Analyse en composantes principales




Composantes principales = vecteurs singuliers de la matrice de covariance $E(\mathbf{x}\mathbf{x}^\top)$

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications




Exemple : analyse de mélanges par spectroscopie

- Spectroscopie : mesure de la réponse lumineuse d'un tissu après excitation (par exemple laser)
 - Un spectre mesuré est une combinaison linéaire des spectres des composants pures (λ)
 - Acquisition de spectres dans différentes conditions physico-chimiques (x)



$$= \begin{bmatrix} 2/3 & 1/3 \\ 1/2 & 1/2 \\ 1/3 & 2/3 \end{bmatrix} \cdot$$



Modèle de mélange instantané

$$\mathbf{X}(x, \lambda) = \sum_k \mathbf{a}_k(x) \mathbf{s}_k(\lambda)$$

Les valeurs sont positives !

- Analyse de données massives (Big Data)
- Bioinformatique
- Apprentissage statistique (Machine Learning)
- **Chimiometrie**
- **Imageries hyperspectrales** : télédétection, microscopie, ...

$$\mathbf{X} = \mathbf{A} \mathbf{S}^T$$

avec

$\mathbf{X} : (m \times n)$ matrice de données

$\mathbf{A} : (m \times p)$ matrice de mélange à *estimer*

$\mathbf{S} : (n \times p)$ matrice source à *estimer*

Contrainte de non-négativité

$$\mathbf{A} \geq 0 \text{ et } \mathbf{S} \geq 0$$

$\Rightarrow$ **Factorisation en matrices non-négatives (NMF)**

Unicité ?

Quelles sont les conditions sur $\mathbf{S}$ et $\mathbf{A}$ pour que la **NMF** de $\mathbf{X}$ **soit unique** ?

Si la solution n'est pas unique, quelle est l'ensemble des solutions admissibles ?

Comment réduire l'ensemble des solutions admissibles ?

Algorithmes ?

Estimation conjointe de $\mathbf{A} \geq 0$ et $\mathbf{S} \geq 0$: ALS, NMF, ALS régularisée, NMF régularisée, méthodes Bayésiennes ...

Méthodes géométriques : N-Findr, Minimum Volume Enclosing Simplex, ...



$\mathbf{A}$ et $\mathbf{S}$ sont des matrices de rang p (rang colonne plein)

$$\mathbf{A} \mathbf{S}^T = \tilde{\mathbf{A}} \tilde{\mathbf{S}}^T$$

si et seulement si

$$\exists \mathbf{T}(p \times p) \text{ inversible telle que } \begin{cases} \tilde{\mathbf{A}} = \mathbf{A} \mathbf{T}^{-1} \\ \tilde{\mathbf{S}} = \mathbf{S} \mathbf{T}^T \Leftrightarrow \tilde{\mathbf{S}}^T = \mathbf{T} \mathbf{S}^T \end{cases}$$

Quelles sont les conditions sur $\mathbf{S}$, $\mathbf{A}$ et $\mathbf{T}$ qui permettent de garantir que $\tilde{\mathbf{A}}$ et $\tilde{\mathbf{S}}$ sont non-negatives ?

Indéterminations d'échelle

$\mathbf{T} = \text{Diag}(\lambda_1, \dots, \lambda_p)$ avec $\lambda_i > 0, \forall i = 1, \dots, p, \Rightarrow \tilde{\mathbf{S}} \geq 0$ et $\tilde{\mathbf{A}} \geq 0$.

Normalisation de $\mathbf{A}$ ou $\mathbf{S}$ (par exemple Sum to One)

Indéterminations d'ordre

$\mathbf{T}$ matrice de permutation de ligne $\Rightarrow \mathbf{T}^{-1}$ matrice de permutation de colonne
 $\Rightarrow \tilde{\mathbf{S}} \geq 0$ and $\tilde{\mathbf{A}} \geq 0$.

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2], \quad \mathbf{S} = [\mathbf{s}_1 \ \mathbf{s}_2], \quad \mathbf{X} = \mathbf{AS}^T = \tilde{\mathbf{A}}\tilde{\mathbf{S}}^T$$

Indéterminations d'ordre

$$\mathbf{\Pi} = \mathbf{\Pi}^{-1} = \mathbf{\Pi}^T = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

permutation des colonnes :

$$\tilde{\mathbf{A}} = \mathbf{A}\mathbf{\Pi} = [\mathbf{a}_2 \ \mathbf{a}_1], \quad \tilde{\mathbf{S}} = \mathbf{S}\mathbf{\Pi} = [\mathbf{s}_2 \ \mathbf{s}_1]$$

Indéterminations d'échelle

$$\mathbf{\Lambda} = \mathbf{\Lambda}^T = \begin{bmatrix} \alpha & 0 \\ 0 & \beta \end{bmatrix}, \quad \alpha, \beta \geq 0$$

$$\tilde{\mathbf{A}} = \mathbf{A}\mathbf{\Lambda}^{-1} = \left[\frac{1}{\alpha} \mathbf{a}_1 \ \frac{1}{\beta} \mathbf{a}_2 \right], \quad \tilde{\mathbf{S}} = \mathbf{S}\mathbf{\Lambda}^T = [\alpha \mathbf{s}_1 \ \beta \mathbf{s}_2]$$

- Une paire $(\mathbf{A}, \mathbf{S})$ est une solution admissible si $\mathbf{A}$ et $\mathbf{S}$ sont des matrices non-negatives dont le produit donne $\mathbf{X}$.

Unicité essentielle

Soit $\mathbf{X}$ une matrice admettant la NMF $\mathbf{X} = \mathbf{A} \mathbf{S}^T$. On dit que la solution est essentiellement unique si les seules indéterminations sont les indéterminations d'ordre et d'échelle.

- Dans le cas de deux sources, *i.e.*

$$\mathbf{A} = [\mathbf{a}_1 \ \mathbf{a}_2] \quad \mathbf{S} = [\mathbf{s}_1 \ \mathbf{s}_2]$$

on peut montrer que la NMF est essentiellement unique.

- Optimisation sous contraintes de positivité

$$\min_{\mathbf{A} \geq 0, \mathbf{S} \geq 0} \|\mathbf{X} - \mathbf{AS}^\top\|_F^2$$

- Problème non convexe $\rightarrow$ Minimisation alternée de type "Alternate Least Squares" (ALS) : MCR-ALS (Tauler), NMF (Lee & Seung), ALS (Kim & Park), HALS (Cichocki et al.)


$$\mathbf{A}_{k+1} \leftarrow \min_{\mathbf{A} \geq 0} \|\mathbf{X} - \mathbf{AS}_k^\top\|_F^2$$

$$\mathbf{S}_{k+1} \leftarrow \min_{\mathbf{S} \geq 0} \|\mathbf{X} - \mathbf{A}_{k+1}\mathbf{S}^\top\|_F^2$$

- Pour réduire d'avantage l'ensemble des solutions admissibles, on peut recourir à la régularisation (= ajout de contraintes sur $\mathbf{A}$ et $\mathbf{S}$, par exemple parcimonie)

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
- 5. Données tensorielles**
6. Décompositions tensorielles
7. Applications

- Analyse de données : co-clustering, graphes
- Apprentissage automatique : modélisation des distributions, réseaux de neurones
- Chimiométrie : MEEF, Microscopie Raman polarisée, RMN-ND
- Ingénierie biomédicale : EEG multivoie, ECG multivoie
- Biologie, environnement : gene array, bio-capteur, surveillance environnementale
- Traitement d'antenne : radar, astronomie, acoustique sous-marine, géophysique
- Télécommunications : MIMO, identification de canaux non-linéaires, ...



Fonction multivariable

$$\mathbf{v} = [v_1, \dots, v_N]$$

$$x : \mathbb{R}^N \rightarrow \mathbb{R}$$

$$\mathbf{v} \mapsto x(\mathbf{v})$$

Cas discret : échantillonnage de $x(\mathbf{v})$ sur une grille régulière $\rightarrow$ tableau multidimensionnel

$$\mathcal{X}_{i_1 i_2 \dots i_N}$$

On assimile un tenseur $\mathcal{X}$ à un tableau multidimensionnel.


N : ordre d'un tenseur (= nombre de modes)

($N = 0$) Scalaire s

($N = 1$) vecteur $\mathbf{v} = [v_i]$

($N = 2$) matrice $\mathbf{M} = [m_{ij}]$

($N \geq 3$) tenseur $\mathcal{T} = [t_{ijk}]_{i,j,k=1}^{I,J,K}$, $(\mathcal{T})_{ijk} = t_{ijk}$




Fibres, tranches (tenseur d'ordre 3)

Fibres :


colonnes

$$\mathcal{X}_{:,j,k}$$




lignes

$$\mathcal{X}_{i,:,k}$$



tubes


$$\mathcal{X}_{i,j,:}$$



Tranches :


horizontales

$$\mathcal{X}_{i,:,:}$$




latérales

$$\mathcal{X}_{:,j,:}$$




frontales

$$\mathcal{X}_{:,:,k}$$




Tenseur diagonal, tenseur symétrique



Tenseur diagonal

$$(\mathcal{X})_{ijk} \neq 0 \text{ ssi } i = j = k$$




Tenseur (cubique) symétrique

$$(\mathcal{X})_{ijk} = \mathcal{X}_{\sigma(ijk)}, \sigma : \text{permutation}$$

Transformation d'un tenseur en une matrice

Un tenseur $\mathcal{Y}$ peut se déplier de N façons différentes : $\mathbf{Y}_{(n)}$



Transformation d'un tenseur en un vecteur $\mathbf{y} = \text{vec}(\mathcal{Y})$ ($IKJ \times 1$)

Matlab (demo 1)



Kronecker, Hadamard, Khatri-Rao

Notations

$$\mathbf{A} = [\mathbf{a}_1 \cdots \mathbf{a}_R], (I \times R) \quad \mathbf{B} = [\mathbf{b}_1 \cdots \mathbf{b}_R], (J \times R)$$

Produit de Kronecker

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & a_{12}\mathbf{B} & \cdots \\ a_{21}\mathbf{B} & a_{22}\mathbf{B} & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

Produit de Khatri-Rao

$$\mathbf{A} \odot \mathbf{B} = [\mathbf{a}_1 \otimes \mathbf{b}_1 \cdots \mathbf{a}_R \otimes \mathbf{b}_R], (IJ \times R)$$

Produit de Hadamard (produit termes à termes)

$\mathbf{A}, \mathbf{B}$ matrices de même dimension $(I \times J)$

$$\mathbf{A} * \mathbf{B} = [a_{ij}b_{ij}], (I \times J)$$

Produits matriciels et tensoriels (2)

Propriétés

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^T \otimes \mathbf{A})\text{vec}(\mathbf{X})$$

$$(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = \mathbf{AC} \otimes \mathbf{BD}$$

$$(\mathbf{A} \otimes \mathbf{B})^\dagger = \mathbf{A}^\dagger \otimes \mathbf{B}^\dagger$$

$$(\mathbf{A} \odot \mathbf{B}) \odot \mathbf{C} = \mathbf{A} \odot (\mathbf{B} \odot \mathbf{C}) = \mathbf{A} \odot \mathbf{B} \odot \mathbf{C}$$

$$(\mathbf{A} \odot \mathbf{B})^\top (\mathbf{A} \odot \mathbf{B}) = \mathbf{A}^\top \mathbf{A} * \mathbf{B}^\top \mathbf{B}$$

$$(\mathbf{A} \odot \mathbf{B})^\dagger = (\mathbf{A}^\top \mathbf{A} * \mathbf{B}^\top \mathbf{B})^\dagger (\mathbf{A} \odot \mathbf{B})^\top$$

$^\top$: transposée

† : pseudoinverse

Produit tensoriel

$\mathbf{a} \circ \mathbf{b}$, $(I \times J)$, $(\mathbf{a} \circ \mathbf{b})_{ij} = a_i b_j$ i.e. $\mathbf{a} \circ \mathbf{b} = \mathbf{a} \mathbf{b}^T$, matrice de rang 1.

$\mathbf{a} \circ \mathbf{b} \circ \mathbf{c}$, $(I \times J \times K)$, $(\mathbf{a} \circ \mathbf{b} \circ \mathbf{c})_{ijk} = a_i b_j c_k$ i.e. tenseur de rang 1.

Produit n-mode

$$\mathbf{A} : (J \times I_n), \quad \mathcal{X} : (I_1 \times I_2 \cdots \times I_N)$$


$$\mathcal{X} \times_n \mathbf{A} : (I_1 \times \cdots \times I_{n-1} \times J \times I_{n+1} \cdots \times I_N)$$

$$(\mathcal{X} \times_n \mathbf{A})_{i_1 \cdots i_{n-1} j i_{n+1} \cdots i_N} = \sum_{i_n=1}^{I_n} x_{i_1 \cdots i_N} a_{j i_n}$$

Matlab (demo 2)

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Factorisation en matrices non-négatives (NMF)
5. Données tensorielles
6. Décompositions tensorielles
7. Applications

Décompositions tensorielles



Rappel : rang matriciel

$$\mathbf{X} \in \mathbb{R}^{I \times J}, \quad \mathbf{X} = \sum_{r=1}^R \mathbf{a}_r \mathbf{b}_r^T = \mathbf{A} \mathbf{B}^T$$

$$\begin{array}{c} J \\ \boxed{\mathbf{X}} \\ I \end{array} = \begin{array}{c} | \quad \mathbf{b}_1^T \quad | \\ \mathbf{a}_1 \\ | \end{array} + \cdots + \begin{array}{c} | \quad \mathbf{b}_R^T \quad | \\ \mathbf{a}_R \\ | \end{array} = \begin{array}{c} R \\ \boxed{\mathbf{A}} \\ I \end{array} \begin{array}{c} J \\ \boxed{\mathbf{B}^T} \\ R \end{array}$$

Rang d'une matrice :

1. nombre minimal de matrices de rang 1 permettant de représenter $\mathbf{X}$
2. taille minimale de la factorisation $\mathbf{A} \mathbf{B}^T$

Contraintes d'orthogonalité : SVD $\mathbf{X} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$

Extension de la SVD aux tenseurs depend de la définition du rang :

1. Décomposition CP (canonique polyadique)
2. Décomposition Tucker : HOSVD (Higher order SVD)


Décomposition de Tucker d'un tenseur d'ordre 3

[Tucker, 1966], [De Lathauwer 1997]

$$(\mathcal{Y})_{ijk} = \sum_{p=1}^{R_1} \sum_{q=1}^{R_2} \sum_{r=1}^{R_3} g_{pqr} u_{ip} v_{jq} w_{kr}$$

$$\mathcal{Y} = \sum_{p=1}^{R_1} \sum_{q=1}^{R_2} \sum_{r=1}^{R_3} g_{pqr} \mathbf{u}_p \circ \mathbf{v}_q \circ \mathbf{w}_r$$

$$\mathcal{Y} = \mathcal{G} \times_1 \mathbf{U} \times_2 \mathbf{V} \times_3 \mathbf{W} = \llbracket \mathcal{G}, \mathbf{U}, \mathbf{V}, \mathbf{W} \rrbracket$$



$\mathcal{G}$ — tenseur coeur

$\mathbf{U}, \mathbf{V}, \mathbf{W}$ — matrices facteurs

Décomposition de Tucker d'un tenseur d'ordre N

$$\mathcal{X} = \mathcal{G} \times_1 \mathbf{A}^{(1)} \times_2 \mathbf{A}^{(2)} \cdots \times_N \mathbf{A}^{(N)} = \llbracket \mathcal{G}, \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$$

Non unicité de la décomposition de Tucker

$$\mathcal{X} = \llbracket \mathcal{G} \times_1 \mathbf{T}_1 \times_2 \mathbf{T}_2 \times_3 \mathbf{T}_3, \mathbf{A}\mathbf{T}_1^{-1}, \mathbf{B}\mathbf{T}_2^{-1}, \mathbf{C}\mathbf{T}_3^{-1} \rrbracket$$

Contraintes : Orthogonalité des modes et du tenseur coeur

$$\mathcal{X} = \llbracket \mathcal{G}, \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)} \rrbracket$$

n-rank : rang colonne du tenseur déplié selon le mode n : $R_n = \text{rank}(\mathbf{X}_{(n)})$

$\Rightarrow$ **rang multilinéaire** du tenseur : $(R_1, R_2, \dots, R_N)$

Data: Data $\mathcal{X}$, rank- $(R_1, \dots, R_N)$

for $n = 1, \dots, N$ **do**

$[\mathbf{U}_n, \mathbf{\Lambda}, \mathbf{V}_n] = \text{svd}(\mathbf{X}_{(n)}, R_n)$

end

$\mathcal{G} = \mathcal{X} \times_1 \mathbf{U}_1^\top \cdots \times_N \mathbf{U}_N^\top$

Result: $\mathcal{G}$, $\mathbf{U}_1 \cdots \mathbf{U}_N$

Très proche d'une meilleure approximation de rang- $(R_1, \dots, R_N)$

[De Lathauwer 1997]

Décomposition CP d'un tenseur d'ordre 3

CP (canonique polyadique) : Candecomp/PARAFAC [Hitchcock, 1927] [Harshman, 1970-1972], [Carroll - Chang, 1970]

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r, \quad \boxed{\mathcal{X}} = \mathbf{a}_1 \left| \begin{array}{c} \mathbf{c}_1 / \\ \mathbf{b}_1 \end{array} \right. + \cdots + \mathbf{a}_R \left| \begin{array}{c} \mathbf{c}_R / \\ \mathbf{b}_R \end{array} \right.$$

rang tensoriel $\stackrel{\text{def}}{=}$ nombre minimal R de tenseurs de rang 1 nécessaire pour représenter $\mathcal{X}$.

Notation : $\mathcal{X} = \llbracket \mathbf{A}, \mathbf{B}, \mathbf{C} \rrbracket$, avec des *matrices facteurs*

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_R \end{bmatrix}, \mathbf{B} = \begin{bmatrix} \mathbf{b}_1 & \cdots & \mathbf{b}_R \end{bmatrix}, \mathbf{C} = \begin{bmatrix} \mathbf{c}_1 & \cdots & \mathbf{c}_R \end{bmatrix}$$

Décomposition CP (ordre 3) : écriture par tranche

$$\mathcal{X}_{:, :, k} = \mathbf{A} \text{diag}(C_{k,:}) \mathbf{B}^T$$

$$\boxed{\mathcal{X}_{:, :, 1}} = \begin{array}{c} \textcolor{blue}{c_{1,1}} \text{---} \mathbf{b}_1^T \text{---} \\ | \qquad \qquad \qquad | \\ \mathbf{a}_1 \qquad \qquad \qquad \mathbf{a}_r \\ | \qquad \qquad \qquad | \end{array} + \dots + \begin{array}{c} \textcolor{blue}{c_{R,1}} \text{---} \mathbf{b}_r^T \text{---} \\ | \qquad \qquad \qquad | \\ \mathbf{a}_r \qquad \qquad \qquad \mathbf{a}_r \\ | \qquad \qquad \qquad | \end{array}$$

$\vdots$

$$\boxed{\mathcal{X}_{:, :, K}} = \begin{array}{c} \textcolor{blue}{c_{1,K}} \text{---} \mathbf{b}_1^T \text{---} \\ | \qquad \qquad \qquad | \\ \mathbf{a}_1 \qquad \qquad \qquad \mathbf{a}_r \\ | \qquad \qquad \qquad | \end{array} + \dots + \begin{array}{c} \textcolor{blue}{c_{R,K}} \text{---} \mathbf{b}_r^T \text{---} \\ | \qquad \qquad \qquad | \\ \mathbf{a}_r \qquad \qquad \qquad \mathbf{a}_r \\ | \qquad \qquad \qquad | \end{array}$$

$\Updownarrow$

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r = \llbracket \mathbf{A}, \mathbf{B}, \mathbf{C} \rrbracket$$

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r^{(1)} \circ \dots \circ \mathbf{a}_r^{(N)} = \llbracket \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$$

Ecriture alternative par dépliage :

$$\mathbf{X}_{(1)} = \mathbf{A}^{(1)} (\mathbf{A}^{(N)} \odot \dots \odot \mathbf{A}^{(2)})^T, \quad (I_1 \times I_2 \dots I_N)$$

$$\text{Cas } N = 3 : \mathbf{X}_{(1)} = \mathbf{A}(\mathbf{C} \odot \mathbf{B})^T, \quad (I \times JK)$$

Rang du tenseur : nombre minimal de tenseur de rang 1 nécessaire pour représenter $\mathcal{X}$. Définition analogue au cas matriciel ... mais le rang tensoriel a des propriétés très différentes !

- Le rang d'un tenseur peut être différent si on considère une décomposition sur $\mathbb{R}$ ou $\mathbb{C}$

- **Rang maximal**

$$\text{rang}(\mathcal{X}) \leq \min(IJ, IK, JK)$$

- **Rang typique** : rang lorsque $\mathbf{A}$, $\mathbf{B}$ et $\mathbf{C}$ sont des matrices dont les valeurs sont des réalisations de v.a. à densité absolument continue
 $\neq$ rang maximal
- Approximation de rang faible : problème mal posé, impossibilité de calculer l'approximation de façon récursive ou explicite

- Survey : [Tomasi - Bro 2006]
- Moindres carrés alternés (ALS) [Harshman, 1970], [Bro, 1998]
- Méthode de descente de gradient avec recherche de pas optimal [Rajih - Comon - Harshman, 2008],
- Moindres carrés non linéaires : [Sorber - Van Barel - De Lathauwer, 2013].
- Diagonalisation conjointe, [De Lathauwer, 2006], [Luciani - Albera, 2014]
- Contrainte de non-négativité [Cichocki - Zdunek - Phan - Amari, 2009], [Royer - Thirion-Moreau - Comon, 2011].
- Boîte à outils : N-way (Matlab), tensor toolbox (Matlab), tensorlab (Matlab), three way (R), TensorLy (Python)

Data: Data $\mathcal{X}$, rank R

Initialize $\mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R}$

repeat

for $n = 1, \dots, N$ **do**

$$\mathbf{V} = \mathbf{A}^{(1)\top} \mathbf{A}^{(1)} * \dots * \mathbf{A}^{(n-1)\top} \mathbf{A}^{(n-1)} * \mathbf{A}^{(n+1)\top} \mathbf{A}^{(n+1)} * \dots * \mathbf{A}^{(N)\top} \mathbf{A}^{(N)}$$

$$\mathbf{A}^{(n)} = \mathbf{X}_n(\mathbf{A}^{(N)} \odot \dots \odot \mathbf{A}^{(n+1)} \dots \odot \mathbf{A}^{(n-1)} \dots \odot \mathbf{A}^{(1)}) \mathbf{V}^\dagger$$


 Normalize columns of $\mathbf{A}^{(n)}$ (storing norms as λ)

end


until *fitting does not improve or max iteration reached*;

Result: $\lambda, \mathbf{A}^{(1)} \dots \mathbf{A}^{(N)}$

$$\text{CPD} : (I + J + K - 2)F$$



$$\text{Tucker} : IR_1 + JR_2 + KR_3 + R_1 R_2 R_3 - R_1^2 - R_2^2 - R_3^2$$



Usages principaux :

Tucker : compression (meilleurs algorithmes)

CP : identification (grace à la propriété d'**unicité**)

$$\boxed{\mathbf{M}} = \begin{array}{c} | \text{---} \mathbf{b}_1^T \text{---} \\ \mathbf{a}_1 \\ | \end{array} + \dots + \begin{array}{c} | \text{---} \mathbf{b}_r^T \text{---} \\ \mathbf{a}_r \\ | \end{array}$$

Example en chimiometrie (MEEF)

$$\begin{array}{l} \boxed{\mathbf{M}_1} \\ \vdots \\ \boxed{\mathbf{M}_N} \end{array} = \begin{array}{c} c_{1,1} \cdot \mathbf{a}_1 \mathbf{b}_1^T \\ + \dots + \\ c_{r,1} \cdot \mathbf{a}_r \mathbf{b}_r^T \end{array}$$
$$\begin{array}{c} c_{1,N} \cdot \mathbf{a}_1 \mathbf{b}_1^T \\ + \dots + \\ c_{r,N} \cdot \mathbf{a}_r \mathbf{b}_r^T \end{array}$$

Example en chimiometrie (MEEF)

$$\begin{array}{c}
 \boxed{M_1} \\
 \vdots \\
 \boxed{M_N}
 \end{array}
 =
 \begin{array}{c}
 c_{1,1} \cdot \frac{\mathbf{b}_1^T}{\mathbf{a}_1} + \dots + c_{r,1} \cdot \frac{\mathbf{b}_r^T}{\mathbf{a}_r} \\
 c_{1,N} \cdot \frac{\mathbf{b}_1^T}{\mathbf{a}_1} + \dots + c_{r,N} \cdot \frac{\mathbf{b}_r^T}{\mathbf{a}_r}
 \end{array}$$

$\Updownarrow$

$$\begin{array}{c}
 \dots \\
 \boxed{M_2} \\
 \boxed{M_1}
 \end{array}
 \begin{array}{c}
 \boxed{M_N} \\
 \boxed{M_2} \\
 \boxed{M_1}
 \end{array}
 =
 \frac{c_1}{\mathbf{a}_1} \frac{\mathbf{b}_1}{\mathbf{b}_1} + \dots + \frac{c_r}{\mathbf{a}_r} \frac{\mathbf{b}_r}{\mathbf{b}_r}$$

Exemple en chimiometrie (MEEF)

spectroscopie de fluorescence
matrice d'Emission/Excitation

rang = # composants de mélange
 N experimentations, concentrations différentes


$$\begin{array}{c}
 \begin{array}{c} \text{Heatmap 1} \\ \vdots \\ \text{Heatmap N} \end{array} = \begin{array}{c} \boxed{M_1} \\ \vdots \\ \boxed{M_N} \end{array} = \begin{array}{c} c_{1,1} \cdot \begin{array}{c} | \\ \mathbf{a}_1 \\ | \end{array} \mathbf{b}_1^T + \dots + c_{r,1} \cdot \begin{array}{c} | \\ \mathbf{a}_r \\ | \end{array} \mathbf{b}_r^T \\ \\ c_{1,N} \cdot \begin{array}{c} | \\ \mathbf{a}_1 \\ | \end{array} \mathbf{b}_1^T + \dots + c_{r,N} \cdot \begin{array}{c} | \\ \mathbf{a}_r \\ | \end{array} \mathbf{b}_r^T \end{array}
 \end{array}$$

$$\Downarrow$$

$$\begin{array}{c} \dots \\ \boxed{M_2} \\ \boxed{M_1} \end{array} \begin{array}{c} \boxed{M_N} \\ \vdots \\ \end{array} = \begin{array}{c} c_1 / \\ \mathbf{a}_1 | \end{array} \mathbf{b}_1 + \dots + \begin{array}{c} c_r / \\ \mathbf{a}_r | \end{array} \mathbf{b}_r$$


Exemple : classification d'images

Réseau convolutionnel



Inconvenient : cout important de stockage

Convolutional layers



$$\mathcal{V}(x, y, t) = g\left(\sum_{i=x-d+1}^x \sum_{j=y-d+1}^y \sum_{s=1}^S \mathcal{K}(i-x+d, j-y+d, s, t) \mathcal{U}(i, j, s) + b(x, y, t)\right)$$


défini par tensor 4D $\mathcal{K} \in \mathbb{R}^{d \times d \times S \times T}$

$\Rightarrow$ compression par décomposition CP

Tensor approximations for NN compression

(Lebedev et al., 2015)

$$\mathcal{K} \approx \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r \circ \mathbf{d}_r,$$



- Les données se présentent très généralement sous forme matricielles/tensorielles
- Nécessité de savoir manipuler ces structures
- Il est important d'avoir des méthodes d'approximation/simplification de ces données. Cela passe souvent par des algorithmes de décompositions ou factorisations
- Les propriétés mathématiques des décompositions (existence, unicité, etc..) influent sur la complexité du problème.