

Optimisation Numérique et Sciences des Données

Sciences des données – Support Vector Machines

Paul Catala (CRAN, UL)
paul.catala(at)univ-lorraine.fr

Master Ingénierie des Systèmes Complexes M2 ISC 925
Semestre 9 – 2024

1. Introduction
2. SVM à marge dure
3. Résolution du problème sous contraintes
4. SVM à marge souple
5. Astuce du noyau

- "Big data": accès à un grand nombre données **labellisées**

$$(\mathbf{x}_i, y_i) \in \mathbb{R}^n \times \mathcal{Y}$$

- **Apprentissage supervisé**: trouver une fonction **paramétrée** $f_\theta : \mathbb{R}^n \rightarrow \mathcal{Y}$ t.q.


$$f_\theta(\mathbf{x}_i) = y_i$$

avec de bonnes propriétés de généralisations.


- Exemples:
 - $\mathcal{Y} = \{0, 1\}$: **classification binaire**
 - $\mathcal{Y} = \{0, 1, \dots, K\}$: classification multi-classes
 - $\mathcal{Y} = \mathbb{R}, f_\theta(\mathbf{x}) = \theta_1^\top \mathbf{x} + \theta_2$: **régression linéaire**
- Il existe aussi des méthodes d'apprentissage semi-supervisé et non-supervisé

- Les machines à vecteurs de support (SVM en anglais) sont des méthodes d'apprentissage supervisé, pour des tâches de classification binaires. Elles ont été développés dans les années 90
- Elles généralisent les classifieurs linéaires à marge maximale

- Dans $\mathbb{R}^n$, un hyperplan est un espace affine (i.e. un point + un espace vectoriel) de dimension $n - 1$



(a) une droite en dimension 2



(b) un plan en dimension 3

- Equation d'un hyperplan:

$$a_1x_1 + a_2x_2 + \dots + a_nx_n + b = 0$$


- Un hyperplan divise l'espace en deux:

$$\{x; \langle a, x \rangle + b > 0\} \quad \text{et} \quad \{x; \langle a, x \rangle + b < 0\}$$

- On considère un jeu de p données labellisées

$$\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_p, y_p)\}$$

avec $\mathbf{x}_i \in \mathbb{R}^n$ et $y_i \in \{1, -1\}$, pour tout $i = 1, \dots, p$



- Ces données sont dites **linéairement séparables** s'il existe un hyperplan et $\varepsilon > 0$ tels que

$$\begin{cases} \mathbf{a}'^T \mathbf{x}_i + b' \geq \varepsilon & \text{si } y_i = 1 \\ \mathbf{a}'^T \mathbf{x}_i + b' \leq -\varepsilon & \text{si } y_i = -1 \end{cases}$$


ou de manière équivalente s'il existe $\mathbf{a} \in \mathbb{R}^n$ et $b \in \mathbb{R}$ tels que

$$y_i(\mathbf{a}^T \mathbf{x}_i + b) \geq 1 \quad \text{pour tout } i = 1, \dots, p.$$

- On considère un jeu de p données labellisées

$$\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_p, y_p)\}$$

avec $\mathbf{x}_i \in \mathbb{R}^n$ et $y_i \in \{1, -1\}$, pour tout $i = 1, \dots, p$



- Ces données sont dites **linéairement séparables** s'il existe un hyperplan et $\varepsilon > 0$ tels que

$$\begin{cases} \mathbf{a}'^T \mathbf{x}_i + b' \geq \varepsilon & \text{si } y_i = 1 \\ \mathbf{a}'^T \mathbf{x}_i + b' \leq -\varepsilon & \text{si } y_i = -1 \end{cases}$$


ou de manière équivalente s'il existe $\mathbf{a} \in \mathbb{R}^n$ et $b \in \mathbb{R}$ tels que

$$y_i(\mathbf{a}^T \mathbf{x}_i + b) \geq 1 \quad \text{pour tout } i = 1, \dots, p.$$

- On considère un jeu de p données labellisées

$$\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_p, y_p)\}$$

avec $\mathbf{x}_i \in \mathbb{R}^n$ et $y_i \in \{1, -1\}$, pour tout $i = 1, \dots, p$



- Ces données sont dites **linéairement séparables** s'il existe un hyperplan et $\varepsilon > 0$ tels que

$$\begin{cases} \mathbf{a}'^T \mathbf{x}_i + b' \geq \varepsilon & \text{si } y_i = 1 \\ \mathbf{a}'^T \mathbf{x}_i + b' \leq -\varepsilon & \text{si } y_i = -1 \end{cases}$$


ou de manière équivalente s'il existe $\mathbf{a} \in \mathbb{R}^n$ et $b \in \mathbb{R}$ tels que

$$y_i(\mathbf{a}^T \mathbf{x}_i + b) \geq 1 \quad \text{pour tout } i = 1, \dots, p.$$

- On considère un jeu de p données labellisées

$$\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_p, y_p)\}$$

avec $\mathbf{x}_i \in \mathbb{R}^n$ et $y_i \in \{1, -1\}$, pour tout $i = 1, \dots, p$



- Ces données sont dites **linéairement séparables** s'il existe un hyperplan et $\varepsilon > 0$ tels que

$$\begin{cases} \mathbf{a}'^T \mathbf{x}_i + b' \geq \varepsilon & \text{si } y_i = 1 \\ \mathbf{a}'^T \mathbf{x}_i + b' \leq -\varepsilon & \text{si } y_i = -1 \end{cases}$$

ou de manière équivalente s'il existe $\mathbf{a} \in \mathbb{R}^n$ et $b \in \mathbb{R}$ tels que

$$y_i(\mathbf{a}^T \mathbf{x}_i + b) \geq 1 \quad \text{pour tout } i = 1, \dots, p.$$


- Classification **linéaire** = à partir de $(\mathbf{x}_i, y_i)$, trouver les paramètres $(a_1, \dots, a_n, b)$ d'un hyperplan séparateur.
- La fonction de décision est ensuite simplement donnée par

$$\text{sign}(\mathbf{a}^\top \mathbf{x} + b)$$


- Faible marge: on s'attend à de faibles performances en généralisation
Large marge: on s'attend à de bonnes performances en généralisation

1. Introduction
2. SVM à marge dure
3. Résolution du problème sous contraintes
4. SVM à marge souple
5. Astuce du noyau

- On suppose que les données sont linéairement séparables
- **Définition (Marge).** C'est la plus petite distance (perpendiculaire) entre les données des deux classes et l'hyperplan séparateur



- Exercice: calcul de la marge
- Marge = mesure de confiance dans la classification, bonnes propriétés de généralisation



Equation d'un hyperplan séparateur: $\mathbf{a}^\top \mathbf{x} + b = \text{cste}$


$\mathbf{a}$ vecteur normal à l'hyperplan; $\mathbf{x}_1, \mathbf{x}_2$ tels que $\mathbf{a}^\top \mathbf{x}_1 + b = -1$ et $\mathbf{a}^\top \mathbf{x}_2 + b = 1$

$$\mathbf{a}^\top (\mathbf{x}_1 - \mathbf{x}_2) = \rho \|\mathbf{a}\| = 2$$

donc $\rho = 2/\|\mathbf{a}\|$.

- Un choix naturel est de **maximiser** la marge: on parle d'hyperplan à marge maximale


$$\min \frac{1}{2} \|a\|^2 \quad \text{s.c.} \quad y_i(a^\top x_i + b) \geq 1, \quad i = 1, \dots, p$$



- Intuition géométrique:
 - la contrainte $y_i(a^\top x_i + b) \geq 1$ place x_i est du bon côté de l'hyperplan

- Un choix naturel est de **maximiser** la marge: on parle d'hyperplan à marge maximale

$$\min \frac{1}{2} \|a\|^2 \quad \text{s.c.} \quad y_i(a^\top x_i + b) \geq 1, \quad i = 1, \dots, p$$




- Intuition géométrique:
 - la contrainte $y_i(a^\top x_i + b) \geq 1$ place x_i est du bon côté de l'hyperplan

- Les vecteurs de support sont les points $\mathbf{x}_i$ tels que

$$y_i(\mathbf{a}^\top \mathbf{x}_i + b) = 1,$$


c'est-à-dire que $\mathbf{x}_i$ se trouve **sur** la marge.



- Les vecteurs de support sont les points x_i tels que

$$y_i(a^\top x_i + b) = 1,$$

c'est-à-dire que x_i se trouve sur la marge.



- L'hyperplan (a, b) n'est défini qu'à partir de ces points

1. Introduction
2. SVM à marge dure
3. Résolution du problème sous contraintes
4. SVM à marge souple
5. Astuce du noyau

- Lorsqu'on minimise une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ **convexe, différentiable** sans contraintes, une condition nécessaire et suffisante d'optimalité est

$$\nabla f(x_*) = 0.$$

- Quelles sont les conditions d'optimalités d'un problème sous contraintes d'égalité


$$\min f(x) \quad \text{s.c.} \quad g_i(x) = 0, \quad i = 1, \dots, p$$

où f et les fonctions de contraintes g_i sont **convexes, différentiables**?

- Lorsque les g_i sont différentiables, l'ensemble des contraintes

$$V_g := \{x \in \mathbb{R}^n ; g_i(x) = 0, \forall i\}$$


définit une **variété lisse**.



- Lorsque les g_i sont différentiables, l'ensemble des contraintes

$$V_g := \{x \in \mathbb{R}^n ; g_i(x) = 0, \forall i\}$$

définit une **variété lisse**.




- Un vecteur v est **tangent** à V_g en a s'il existe un chemin différentiable $\gamma : [0, 1] \rightarrow \mathbb{R}^n$ sur la variété tel que $\gamma(0) = a$ (**γ passe par a**) et $\gamma'(0) = v$ (**v est tangent au chemin en a**).

- Lorsque les g_i sont différentiables, l'ensemble des contraintes

$$V_g := \{x \in \mathbb{R}^n ; g_i(x) = 0, \forall i\}$$

définit une **variété lisse**.



- Un vecteur v est **tangent** à V_g en a s'il existe un chemin différentiable $\gamma : [0, 1] \rightarrow \mathbb{R}^n$ sur la variété tel que $\gamma(0) = a$ (γ passe par a) et $\gamma'(0) = v$ (v est tangent au chemin en a).
- L'ensemble des vecteurs tangents à une variété lisse en a est un espace vectoriel, appelé **espace tangent**. Dans notre cas,


$$\mathcal{T}_a(V_g) = \text{Vect}(\nabla g_1(a), \dots, \nabla g_p(a))^\perp$$

CONDITIONS NÉCESSAIRES D'OPTIMALITÉ

- Si f atteint son minimum sur V en x_* , alors pour tout chemin différentiable $\gamma : [0, 1] \rightarrow \mathbb{R}^n$ sur V_g tel que $\gamma(t_*) = x_*$ on doit avoir

$$(f \circ \gamma)'(t_*) = \nabla f(x_*)^\top \gamma'(t_*) = 0.$$

- Autrement dit, $\nabla f(x_*)$ est orthogonal à l'espace tangent de V_g en x_* , i.e. ici



$$\nabla f(x_*) \in \text{Vect}(\nabla g_1(x_*), \dots, \nabla g_p(x_*))$$

$$\iff \exists \nu \in \mathbb{R}^p, \nabla f(x_*) = - \sum \nu_{*i} \nabla g_i(x_*)$$

$$\iff \exists \nu \in \mathbb{R}^p, \nabla(f + \sum \nu_{*i} g_i)(x_*) = 0$$

- La fonction

$$\mathcal{L}(x, \nu) := f(x) + \sum_{i=1}^p \nu_i g_i(x)$$

s'appelle le **Lagrangien** du problème, les variables ν_i s'appellent des **multiplicateurs de Lagrange**. Les CN d'optimalité du problème s'écrivent

$$\begin{cases} \nabla_x \mathcal{L}(x, \nu) = 0 & \text{(ce qu'on vient de voir)} \\ \nabla_\nu \mathcal{L}(x, \nu) = 0 & \text{(on retrouve les contraintes d'égalités)} \end{cases}$$

- On considère un problème d'optimisation avec contraintes d'égalité et d'inégalité

$$\min f(x) \quad \text{s.t.} \quad \begin{cases} g_i(x) = 0 & i = 1, \dots, p \\ h_j(x) \leq 0 & j = 1, \dots, q \end{cases}$$

où les fonctions f, g_i, h_j sont **convexes, différentiables**

- A l'optimum, on a soit $h_j(\mathbf{x}_*) < 0$ (**contrainte inactive**), soit $h_j(\mathbf{x}_*) = 0$ (**contrainte active**)
- On définit le **Lagrangien** du problème

$$\mathcal{L}(x, \lambda, \nu) := f(x) + \sum_{i=1}^p \nu_i g_i(x) + \sum_{j=1}^q \lambda_j h_j(x)$$

Les conditions nécessaires d'optimalité du problème (**conditions KKT**) sont

$$\begin{cases} \nabla_x \mathcal{L}(x, \lambda, \nu) = 0 \\ g_i(x) = 0 & i = 1, \dots, p \\ \lambda_j \geq 0 & j = 1, \dots, q \\ \lambda_j h_j(x) = 0 & j = 1, \dots, q \end{cases}$$

- *Theorem (Dualité forte).* Sous certaines conditions non discutées ici, on a

$$\min_x f(x) \quad \text{s.t.} \quad \begin{cases} g_i(x) = 0 & i = 1, \dots, p \\ h_j(x) \leq 0 & j = 1, \dots, q \end{cases}$$

$$\iff \min_x \max_{\lambda \geq 0, \nu} \mathcal{L}(x, \lambda, \nu)$$

$$\iff \max_{\lambda \geq 0, \nu} \min_x \mathcal{L}(x, \lambda, \nu) =: \max_{\lambda \geq 0, \nu} d(\lambda, \nu)$$

- Le problème de maximisation s'appelle **problème dual** (le problème initial, **problème primal**)
- La minimisation par rapport à x de $\mathcal{L}(x, \lambda, \nu)$ fait (souvent) apparaître des contraintes sur λ et/ou ν (provenant de la condition $\nabla_x \mathcal{L} = 0$)

- On souhaite résoudre le problème contraint:

$$\min \frac{1}{2} \|\mathbf{a}\|^2 \quad \text{s.c.} \quad y_j(\mathbf{a}^\top \mathbf{x}_j + b) \geq 1, \quad j = 1, \dots, q$$

- C'est un problème **convexe**. On considère le **Lagrangien**

$$\mathcal{L}(\mathbf{a}, b, \boldsymbol{\lambda}) = \frac{1}{2} \|\mathbf{a}\|^2 + \sum_{j=1}^q \lambda_j (1 - y_j(\mathbf{a}^\top \mathbf{x}_j + b))$$

Les contraintes d'inégalités sont **affines** en $(\mathbf{a}, b)$: les conditions KKT sont aussi **suffisantes** dans ce cas, et il y a **dualité forte**!

$$\begin{cases} \nabla_{\mathbf{a}} \mathcal{L}(\mathbf{a}, b, \boldsymbol{\lambda}) = 0 \iff \mathbf{a} = \sum \lambda_j y_j \mathbf{x}_j \\ \nabla_b \mathcal{L}(\mathbf{a}, b, \boldsymbol{\lambda}) = 0 \iff \sum \lambda_j y_j = 0 \\ \lambda_j \geq 0, \quad \lambda_j (1 - y_j(\mathbf{a}^\top \mathbf{x}_j + b)) = 0 \quad \forall j \end{cases}$$

- Injectées dans le Lagrangien, les relations précédentes conduisent au problème dual associé

$$\begin{aligned} \max_{\lambda} \quad & \sum_{j=1}^q \lambda_j - \frac{1}{2} \sum_{j,j'=1}^q \lambda_j \lambda_{j'} y_j y_{j'} \mathbf{x}_j^{\top} \mathbf{x}_{j'} \\ \text{s.c.} \quad & \sum \lambda_j y_j = 0, \quad \lambda_j \geq 0, \quad j = 1, \dots, q \end{aligned}$$

- On préfère souvent résoudre cette formulation car elle ne dépend que des produits scalaires deux à deux des données $\mathbf{x}_j^{\top} \mathbf{x}_{j'}$

- Le vecteur optimal $\mathbf{a}_*$ normal à l'hyperplan séparateur est donné par

$$\mathbf{a}_* = \sum \lambda_{j*} y_j \mathbf{x}_j$$

- A l'optimum, les conditions KKT imposent $\lambda_{j*}(1 - y_j(\mathbf{a}_*^\top \mathbf{x}_i + b)) = 0$:

1er cas: $y_j(\mathbf{a}_*^\top \mathbf{x}_i + b) > 1$

Alors $\lambda_{j*} = 0$, et $\mathbf{x}_j$ n'apparaît pas dans l'expression de $\mathbf{a}$

2ème cas: $y_j(\mathbf{a}_*^\top \mathbf{x}_i + b) = 1$

Alors $\lambda_{j*} \neq 0$, et $\mathbf{x}_j$ se trouve sur la marge: c'est un **vecteur de support**


- La fonction de décision pour le problème de classification est finalement donnée par

$$\text{sign} \left(\sum_{j=1}^q \lambda_{j*} y_j \langle \mathbf{x}, \mathbf{x}_j \rangle + b_* \right)$$

1. Introduction
2. SVM à marge dure
3. Résolution du problème sous contraintes
4. SVM à marge souple
5. Astuce du noyau


LIMITATIONS

- Une classification par hyperplan à marge dure n'est pas toujours souhaitable:
 - il peut y avoir des points aberrants/des erreurs dans les données: risque d'**overfitting**
 - les données ne sont pas toujours strictement linéairement séparables



LIMITATIONS

- Une classification par hyperplan à marge dure n'est pas toujours souhaitable:
 - il peut y avoir des points aberrants/des erreurs dans les données: risque d'**overfitting**
 - les données ne sont pas toujours strictement linéairement séparables



- On voudrait autoriser les "mauvaises" classifications: on modifie la formulation du problème afin de **pénaliser** les données mal classées

- meilleure robustesse aux données individuelles
- meilleure classification de la majorité des données
- solution du problème d'optimisation

$$\min \quad \frac{1}{2} \|a\|^2 + \alpha \sum_{i=1}^p \xi_i \quad \text{s.c.} \quad y_i(a^\top x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, p$$

- La contrainte


$$y_i(a^\top x_i + b) \geq 1 - \xi_i$$

autorise les échantillons du mauvais côté de la marge, voire de l'hyperplan, tandis que le terme $\alpha \sum \xi_i$ pénalise ces échantillons


- le paramètre α règle le compromis entre la largeur de la marge et le nombre d'échantillons mal classés
 - α grand: petite marge, moins d'erreurs de classification
 - α faible: une grande marge, plus d'erreurs de classification

1. Calculer le Lagrangien du problème SVM à marge souple
2. Donner les conditions d'optimalité
3. Formuler le problème dual


ILLUSTRATION




$\alpha = 0.02$



$\alpha = 0.07$




$\alpha = 0.2$



$\alpha = 0.7$

1. Introduction
2. SVM à marge dure
3. Résolution du problème sous contraintes
4. SVM à marge souple
5. Astuce du noyau

Les données ne sont pas toujours linéairement séparables




TRANSFORMATION

Les données peuvent devenir linéairement séparables après une **transformation non-linéaire**

$$\varphi : \mathbf{x} \mapsto \begin{bmatrix} \varphi_1(\mathbf{x}) & \varphi_2(\mathbf{x}) & \dots \end{bmatrix}$$

Exemple: φ transformation polynomiale



$$\varphi(\mathbf{x}) = \begin{bmatrix} x_1 & x_2 & x_1^2 + x_2^2 \end{bmatrix}$$

■ Problème primal

$$\min \frac{1}{2} \|\mathbf{a}\|^2 + \alpha \sum_{j=1}^q \xi_j \quad \text{s.c.} \quad y_i(\mathbf{a}^\top \varphi(\mathbf{x}_j) + b) \geq 1 - \xi_j, \quad \xi_j \geq 0, \quad j = 1, \dots, q$$

■ Problème dual

$$\begin{aligned} \max_{\lambda} \quad & \sum_{j=1}^q \lambda_j - \frac{1}{2} \sum_{j,j'=1}^q \lambda_j \lambda_{j'} y_j y_{j'} \langle \varphi(\mathbf{x}_j), \varphi(\mathbf{x}_{j'}) \rangle \\ \text{s.c.} \quad & \sum \lambda_j y_j = 0, \quad \alpha \geq \lambda_j \geq 0, \quad j = 1, \dots, q \end{aligned}$$

■ La fonction de décision est finalement donnée par

$$\text{sign} \left(\sum_{j=1}^q \lambda_{j*} y_j \langle \varphi(\mathbf{x}), \varphi(\mathbf{x}_j) \rangle + b_* \right)$$

- L'enjeu est de définir un noyau $K(\mathbf{x}_j, \mathbf{x}_{j'}) = \langle \varphi(\mathbf{x}_j), \varphi(\mathbf{x}_{j'}) \rangle$ (un noyau est simplement une fonction symétrique de $\mathcal{X} \times \mathcal{X}$ dans $\mathbb{R}$) tel que
 - la fonction de décision associée soit performante
 - calculer $K(\mathbf{x}_j, \mathbf{x}_{j'})$ soit peu coûteux même en grande dimension
- Exemples de noyaux

Polynomial de degré d	$(1 + \langle \mathbf{x}, \mathbf{x}' \rangle)^d$
Sigmoidal	$1/\eta_0 \tanh(\beta_0 \langle \mathbf{x}, \mathbf{x}' \rangle + \alpha_0)$
Gaussien	$1/\eta_0 \exp(-\ \mathbf{x} - \mathbf{x}'\ ^2 / \beta_0^2)$
Laplacien	$1/\eta_0 \exp(-\ \mathbf{x} - \mathbf{x}'\ _1 / \beta_0)$
Cauchy	$\frac{1}{\eta_0} \frac{1}{1 + \ \mathbf{x} - \mathbf{x}'\ ^2 / \beta_0^2}$

- Remarque: tout algorithme pouvant s'exprimer en termes de produits scalaires peut bénéficier de l'astuce du noyau