



Faculté des Sciences et Technologies
Master 2 Ingénierie des Systèmes Complexes (ISC)

TD/TP

Sciences des données

Classification de chiffres écrits à la main

K. Usevich

Table des matières

1	Jeu de données données USPS	1
1.1	Construction du jeu de données	1
1.2	Analyse en composantes principales (ACP)	1
2	Classification SVM	2
2.1	Classification	2
2.2	Réglages des hyperparamètres	3
3	Pour aller plus loin	3
3.1	Pré-traitements	3
3.2	Classification multi-classes	3


1 Jeu de données données USPS

1.1 Construction du jeu de données

Le jeu de données se trouve dans le fichier `usps_all.mat` et est représenté par un tenseur `data` d'ordre 3. Les dimensions du tenseur sont $256 \times 1100 \times 10$.

```
load("usps_all.mat"); % charge 'data'
data = double(data);
```

Chaque colonne `data(:,j,k)` est la vectorisation d'une image, pour laquelle l'indice `k` correspond à une classe (de 0 à 9) et l'indice `j` correspond à un échantillon. Ainsi, la première dimension correspond aux pixels, la deuxième aux chiffres, et la troisième aux classes, comme montré dans la figure ci-dessous. L'ordre des classes est '1', '2', '3', ..., '0'.



1. Afficher quelques exemples des images d'entraînement, dans les classes 7 et 9 par exemple, à l'aide de `imagesc`.

```
colormap(gray);
% Insérer votre code ici
```

2. En apprentissage automatique, il est d'usage de séparer le jeu de données en deux parties : une partie servant à l'entraînement du modèle ("training"), l'autre à sa validation. Diviser le jeu de données en deux tenseurs `T` et `V`, en sélectionnant des sous-tenseurs de `data` selon la deuxième dimension (échantillons). Les indices `ind_train` et `ind_valid` correspondant à chaque sous-tenseurs sont donnés dans le fichier `usps_partition.mat`.

```
load("usps_partition.mat"); % charge 'ind_train' et 'ind_valid'
% Insérer votre code ici
```

1.2 Analyse en composantes principales (ACP)

3. Pour le tenseur des données d'entraînement `T`, calculer le dépliement du tenseur `T` selon le mode (une matrice avec 256 lignes) à l'aide de la commande `reshape`, et trouver la matrice `U` des premiers vecteurs singuliers gauches.
4. Replier chaque vecteur singulier en une matrice à l'aide de `reshape` et les afficher avec `imagesc`.

Dans ce qui suit, nous allons entraîner une SVM sur deux des 10 classes (les chiffres 7 et 9).

5. Extraire de `T` les données des deux classes 7 et 9 (avec la commande `T(:, :, ?)`), et décomposer ces données labellisées en : 1) une matrice `Xt(chiffre, pixel)` de 256 colonnes, et 2) un vecteur `yt(classe)` de labels.
6. Décomposer de même les données de validation en matrice `Xv` et vecteur `yv`.

7. Les colonnes de la matrice U calculée précédemment engendrent un espace vectoriel de faible dimension (ici 10), qui est une (bonne) approximation de l'image de X . L'ACP consiste à projeter nos données sur cet espace de dimension réduite ($\tilde{X} = XU$).

```
Xt_ACP = Xt*U; % projection
```

2 Classification SVM

2.1 Classification

Le classifieur SVM de Matlab est `fitcsvm`. Cette fonction prend plusieurs options (consulter son aide), notamment :

- 'BoxConstraint' : si cette option est fixée à `inf`, le classifieur utilise une marge dure. Pour toute autre valeur strictement positive, la marge est souple (la valeur par défaut est 1)
- 'KernelFunction' : le noyau utilisé le cas échéant (par exemple 'polynomial', 'gaussian', etc...)
- 'KernelScale' : dans le cas d'un noyau gaussien, ce paramètre correspond à l'écart-type (par défaut, 1)
- 'Verbose' : affiche ou non les informations liées au classifieur pendant l'optimisation (par défaut, 1)

1. Retrouver ces différentes options dans l'aide de `fitcsvm`.
2. Entraîner un classifieur SVM à marge souple et à noyau gaussien sur les données projetées X_ACP . Attention : on utilisera le paramètre `..., 'Standardize', true, ...` pour normaliser les données.

Une fois le classifieur entraîné, les valeurs de labels prédites à partir des données X_ACP se calculent avec la commande `predict`.

```
labels = predict(s,X_ACP);
```

Dans le cas de deux classes, disons par exemple 1 et 0, la commande Matlab `confusionmat` retourne la matrice de confusion associée aux prédictions, c'est-à-dire la matrice

$$\begin{bmatrix} TP & FN \\ FP & TN \end{bmatrix}$$

avec

- TP : nombre de bonnes prédictions de la classe 1 ("true positive")
- FP : nombre de mauvaises prédictions de la classe 1 ("false positive")
- FN : nombre de mauvaises prédictions de la classe 0 ("false negative")
- TN : nombre de bonnes prédictions de la classe 0 ("true negative")

Une mesure possible du taux d'erreur est donné par $\frac{FP+FN}{n}$ où n est le nombre d'échantillons.

4. Calculer le taux d'erreur de classification sur les données d'entraînement.
5. Réduire la dimension des données de validation avec la même matrice U qui a été utilisée pour les données d'apprentissage. Calculer les prédictions et le taux d'erreurs de classification.

2.2 Réglages des hyperparamètres

1. Répéter les codes précédents pour différentes valeurs du paramètre 'KernelScale' dans l'intervalle [0;20]. Tracer les courbes des erreurs d'apprentissage et de validation correspondant. Quelle est une bonne valeur de ce paramètre ?

```
sigma_list = 0.5:0.5:20;
% Insérer votre code ici
for i=1:length(sigma_list)
    % Insérer votre code ici
end
% Insérer votre code ici (plot)
```

2. Une façon courante et pratique de régler les hyperparamètres (comme 'KernelScale') est d'utiliser la méthode de validation croisée. Cette méthode n'utilise que les données d'apprentissage, en les sous-divisant d'une manière astucieuse en sous-ensembles d'entraînement et de validation. On peut optimiser le paramètre 'KernelScale' de la façon suivante :

```
s_opt = fitcsvm(Xt,yt,'Verbose',1,'Standardize',true,'KernelFunction','gaussian',
    'KernelScale',1,'OptimizeHyperparameters','KernelScale');
sigma_opt = s_opt.KernelParameters.Scale;
```

3. Comparez les résultats (paramètre optimal, taux d'erreur) avec l'erreur de validation obtenue à l'étape précédente.

3 Pour aller plus loin

3.1 Pré-traitements

1. Répétez la procédure pour deux autres classes (chiffres 6 et 8). Est-il plus difficile de séparer ces classes ? La courbe d'erreur de validation est-elle différente de la précédente ?
2. Prenez deux photos (noir et blanc, carré) avec votre smartphone, représentant les deux classes (6 et 8), ou utilisez les photos fournies dans les fichiers du tp. Classifiez-les après les étapes de pré-traitement suivantes :
 - Recadrage
 - Conversion en négatif (blanc sur fond noir)
 - Correction du contraste – il faut normaliser les données de telle façon que les valeurs minimales et maximales deviennent 0 et 255 : $f_{i,j} = \frac{f_{i,j} - f_{\min}}{f_{\max} - f_{\min}} \cdot 255$
 - Redimensionnement à l'aide de la fonction `imresize`.

3.2 Classification multi-classes

Cette partie de TP est proposée uniquement pour ceux qui auraient déjà tout fait.

Il y a deux stratégies principales pour entraîner un classifieur multi-classe (avec M classes) à partir des outils de classification bi-classes que nous avons vues :

One-vs-one : on entraîne des classifieurs SVM bi-classes pour chacune des paires de classes. Par exemple : '1' vs. '2', '1' vs. '3', ..., '1' vs. '0', '2' vs. '3', ..., '2' vs. '0', ... etc. Pour trouver une prédiction, on évalue ensuite tous les classifieurs sur un nouvel échantillon, et on choisit la classe qui ressort le plus souvent. Par exemple :

- '1' vs. '2' : '1'
- '1' vs. '3' : '1'
- '2' vs. '3' : '3'

⇒ la classe '1' est choisie.

One-vs-all : On entraîne M classifieurs pour la classification binaire :

- '1' vs. '2','3',... '0'
- '2' vs. '1','3',... '0'
- $\vdots$
- '0' vs. '1','2',... '9'

1. Implémenter une des deux stratégies pour le jeu de données USPS. Calculer la matrice de confusion et le taux d'erreur.