

Optimisation Numérique et Sciences des Données

Sciences des Données - Décompositions matricielles

Paul Catala (CRAN, UL)
paul.catala(at)univ-lorraine.fr

Master Ingénierie des Systèmes Complexes
Semestre 9 – 2025

D'après des cours de D. Brie, S. Miron et K. Usevich


1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Applications

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Applications


- La structure des données, *e.g.* positivité, parcimonie, faible rang, ..., joue un rôle essentiel dans les méthodes de traitement et leur efficacité.
- Pouvoir représenter/manipuler des données de manière économe est d'autant plus important avec l'apprentissage profond, où la notion de **frugalité** prend de plus en plus de poids.
- Cela joue aussi un rôle dans l'interprabilité et l'explicabilité des données
- Sur le plan mathématique, impacte sur la vitesse de convergence des algorithmes, et les garanties de reconstruction

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Applications

Signaux multivariés (échantillonnés)




P échantillons, N variables explicatives : matrice $P \times N$




https://blog_fr.interchim.com/cytometrie-flux-analyse-cellulaire/

Images (en niveaux de gris)




(wikipedia)

Statistiques des données : matrice de covariance, histogrammes



MATRICES À PARTIR DE DONNÉES

Matrices d'adjacence, Laplaciens (données sur graphe)



<https://machinelearningknowledge.ai/graph-neural-networks-gnn-explained-for-beginners/>

$$\mathbf{X} \in \mathbb{R}^{m \times n}, \quad \mathbf{X} = \mathbf{a}_1 \mathbf{s}_1^T + \dots + \mathbf{a}_p \mathbf{s}_p^T = \sum_{k=1}^p \mathbf{a}_k \mathbf{s}_k^T \quad (\text{Décomposition})$$

Notation : $\mathbf{A} = [\mathbf{a}_1 | \dots | \mathbf{a}_p]; \quad \mathbf{S} = [\mathbf{s}_1 | \dots | \mathbf{s}_p] \rightsquigarrow \mathbf{X} = \mathbf{A} \mathbf{S}^T$

$$m \begin{array}{|c|} \hline \mathbf{X} \\ \hline \end{array} \overset{n}{=} \begin{array}{|c|} \hline \mathbf{a}_1 \\ \hline \end{array} \begin{array}{|c|} \hline \mathbf{s}_1^T \\ \hline \end{array} + \dots + \begin{array}{|c|} \hline \mathbf{a}_p \\ \hline \end{array} \begin{array}{|c|} \hline \mathbf{s}_p^T \\ \hline \end{array} = m \begin{array}{|c|} \hline \mathbf{A} \\ \hline \end{array} \overset{p}{\times} \begin{array}{|c|} \hline \mathbf{S}^T \\ \hline \end{array} \overset{n}{=} \quad (\text{Factorisation})$$

Rang d'une matrice :

- (i) nombre de colonnes (ou lignes) indépendantes
- (ii) nombre minimal de matrices de rang 1 permettant de représenter $\mathbf{X}$
- (iii) taille minimale de la factorisation $\mathbf{A} \mathbf{B}^T$

On a toujours $\text{rank}(\mathbf{X}) \leq \min(m, n)$



rang =



rang =



rang =



rang = 1




rang =



rang =



rang = 1



rang = 2



rang = 3



$\text{rang} \simeq \frac{m}{2}$ (symmetry)



$\text{rang} \simeq \min(n, m)$
(aléatoire)



$\text{rang} \simeq \frac{m}{2}$ (symmetry)



$\text{rang} \simeq \min(n, m)$
(aléatoire)

Beaucoup de matrices intéressantes en pratique sont (bien approximées par) des matrices de faible rang


- Les décompositions/factorisations de matrices ne sont **pas uniques**!
Par exemple, avec T orthogonale, i.e. $T^{-1} = T^{\top}$, on a toujours

$$X = AS^{\top} = AT(ST)^{\top}$$

↪ la factorisation est aveugle aux **permutations** de lignes/colonnes, **agrandissement/rétrécissement**, **rotations**, etc...

- Ajout de **contraintes** (orthogonalité, non-négativité, indépendance, ...) pour retrouver l'unicité
↪ décompositions particulières : SVD, NMF, ICA, ...
- Dans ce cours, nous ne parlerons que de **décomposition en valeurs singulières** (aka SVD)

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Applications



Théorème

Soit $\mathbf{X} \in \mathbb{R}^{m \times n}$ de rang r . Il existe $\mathbf{U} \in \mathbb{R}^{m \times m}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ *orthogonales*, et $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ *diagonale* telles que

$$\mathbf{X} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad \text{et} \quad \mathbf{\Sigma} = \begin{bmatrix} \text{diag}(\sigma_1, \dots, \sigma_r) & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix}$$

avec $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = \sigma_p = 0$, et $p = \min(m, n)$.

$\mathbf{U} = [\mathbf{u}_1 | \dots | \mathbf{u}_m] : (m \times m)$ matrice orthogonale (vecteurs singuliers gauches)

$\mathbf{V} = [\mathbf{v}_1 | \dots | \mathbf{v}_n] : (n \times n)$ matrice orthogonale (vecteurs singuliers droits)

$\mathbf{\Sigma} = \text{diag}\{\sigma_1, \dots, \sigma_p\} : (m \times n)$ matrice diagonale (valeurs singulières)

On a de manière équivalente la *décomposition*

$$\mathbf{X} = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

rang de $\mathbf{X}$ = nombre de valeurs singulières non-nulles

- par défaut (rappel : $p = \min(m, n)$)

$$\begin{array}{c} n \\ \boxed{\mathbf{X}} \\ m \end{array} = \begin{array}{c} m \\ \boxed{\mathbf{U}} \\ m \end{array} \begin{array}{c} n \\ \boxed{\begin{smallmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_p \end{smallmatrix}} \\ m \end{array} \begin{array}{c} n \\ \boxed{\mathbf{V}^T} \\ n \end{array} = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$$

- "economy size"

$$\begin{array}{c} n \\ \boxed{\mathbf{X}} \\ m \end{array} = \begin{array}{c} p \\ \boxed{\mathbf{U}} \\ m \end{array} \begin{array}{c} p \\ \boxed{\begin{smallmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_p \end{smallmatrix}} \\ p \end{array} \begin{array}{c} n \\ \boxed{\mathbf{V}^T} \\ p \end{array} = \sum_{i=1}^p \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$$

- forme réduite (si $\text{rank}(\mathbf{X}) = r < p$)

$$\begin{array}{c} n \\ \boxed{\mathbf{X}} \\ m \end{array} = \begin{array}{c} r \\ \boxed{\mathbf{U}} \\ m \end{array} \begin{array}{c} r \\ \boxed{\begin{smallmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{smallmatrix}} \\ r \end{array} \begin{array}{c} n \\ \boxed{\mathbf{V}^T} \\ r \end{array} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$$

$$\text{Ker } \mathbf{X} = \text{Vect}(v_{r+1}, \dots, v_n)$$

$$\text{Im } \mathbf{X} = \text{Vect}(u_1, \dots, u_r)$$

$$\text{Ker } \mathbf{X}^\top = \text{Vect}(u_{r+1}, \dots, u_m)$$


$$\text{Im } \mathbf{X}^\top = \text{Vect}(v_1, \dots, v_r)$$




rang=2

rang=3


rang= ?



rang=2



rang=3



rang= ?

$$\mathbf{X} \mathbf{X}^T = \mathbf{U} \mathbf{\Sigma}^2 \mathbf{U}^T$$

$$\mathbf{X}^T \mathbf{X} = \mathbf{V} \mathbf{\Sigma}^2 \mathbf{V}^T$$

- Les **vecteurs singuliers gauches** $\mathbf{U}$ sont les vecteurs propres de $\mathbf{X} \mathbf{X}^T$.
- Les **vecteurs singuliers droits** $\mathbf{V}$ sont les vecteurs propres de $\mathbf{X}^T \mathbf{X}$.
- Les **valeurs singulières** (non-nulles) de $\mathbf{X}$ sont les racines carrées des valeurs propres (non-nulles) de $\mathbf{X}^T \mathbf{X}$ ou $\mathbf{X} \mathbf{X}^T$. En particulier, elles sont déterminées de manière **unique**.

Soit $\mathbf{X} \in \mathbb{R}^{m \times n}$ et soit $(\mathbf{U}, \mathbf{\Sigma}, \mathbf{V})$ sa factorisation SVD. Pour $s \leq \min(m, n)$, la matrice

$$\mathbf{X}_r \stackrel{\text{def}}{=} \sum_{i=1}^s \sigma_i \mathbf{u}_i \mathbf{v}_i^\top$$

donne la meilleure approximation de rang faible d'une matrice au sens de la norme de Frobenius $\|\mathbf{X}\|_F = \sqrt{\text{Tr}(\mathbf{X}^\top \mathbf{X})} = \sqrt{\sigma_1^2 + \dots + \sigma_p^2}$.

la solution du problème d'optimisation

$$\min \|\mathbf{X} - \mathbf{X}_r\|_F \quad \text{s. c.} \quad \text{rang}(\mathbf{X}_r) \leq r, \quad r < p$$

est donnée par :

$$\boxed{\mathbf{X}_r = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^\top}$$

Forme matricielle : $\mathbf{X}_r = \mathbf{U}_{:,1:r} \mathbf{\Sigma}_{1:r,1:r} (\mathbf{V}_{:,1:r})^\top$

L'erreur de la meilleure approximation : $\|\mathbf{X} - \mathbf{X}_r\|_F = \sqrt{\sigma_{r+1}^2 + \dots + \sigma_p^2}$

1. Introduction
2. Données et décompositions matricielles
3. Décomposition en valeurs singulières (SVD)
4. Applications

- Compression et débruitage (traitement d'image, sismique, ...).
- Extraction des motifs et analyse des textures.
- Analyse en composantes principales (statistique, systèmes de recommandations,...).
- Résolution de systèmes d'équations linéaires (calcul de la pseudo-inverse).

Algorithmes pour la SVD


Méthodes pour la décomposition en valeurs propres, algorithmes *gloutons* (Gram-Schmidt, ...), factorizations QR, etc.

DÉBRUITAGE ET COMPRESSION D'IMAGE (1)



Image originale



Image bruitée



DÉBRUITAGE ET COMPRESSION D'IMAGE (2)



Problème des moindres carrés :

$$\min_{x \in \mathbb{R}^n} \|Ax - y\|_2^2$$

étant donnés $A \in \mathbb{R}^{m \times n}$ et $y \in \mathbb{R}^m$.

$$\begin{aligned} \|Ax - u\|_2^2 &= \|U\Sigma V^\top x - y\|_2^2 = \|\Sigma V^\top x - U^\top y\|_2^2 \\ &= \sum_{i=1}^r |\sigma_i v_i^\top x - u_i^\top y|^2 + \sum_{i=r+1}^m |u_i^\top y|^2 \end{aligned}$$

Le minimum est atteint pour

$$x_\star = \sum_{i=1}^r \frac{u_i^\top y}{\sigma_i} v_i + x_0 \stackrel{\text{def}}{=} x_+ + x_0$$

$$\text{et } \|x_\star\|^2 = \|x_+\|^2 + \|x_0\|^2 \geq \|x_+\|^2$$

$$x_+ = \sum_{i=1}^r \frac{u_i^\top y}{\sigma_i} v_i = A^\dagger y \quad \text{où} \quad A^\dagger \stackrel{\text{def}}{=} V \begin{bmatrix} \text{diag}(\frac{1}{\sigma_1}, \dots, \frac{1}{\sigma_r}) & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} U^\top$$

- Si A est injective, alors $A^\dagger y$ est l'unique solution du problème des moindres carrés
- Si A n'est pas injective, alors $A^\dagger y$ est la solution du problème ayant la plus petite norme ℓ_2
- $A^\dagger A A^\dagger = A^\dagger$
- $A A^\dagger A = A$

A partir de données $(x_1, \dots, x_N) \in \mathbb{R}^d$, on souhaite trouver une **représentation optimale** $z \in \mathbb{R}^{d'}$ avec $d' < d$ par **projection orthogonale** sur un **sous espace** bien choisi

Projection orthogonale $\iff$ base orthogonale $\mathbf{U} \in \mathbb{R}^{d \times d'}$

$\mathbf{X} \in \mathbb{R}^{d \times N}$ matrice de données $\iff \mathbf{Z} = \mathbf{U}^\top \mathbf{X} \in \mathbb{R}^{d' \times N}$ matrice des données projetées

L'analyse en composante principale (ACP) est une **factorisation matricielle** ($\mathbf{X} = \mathbf{WZ}$) qui choisit $\mathbf{Z}$ avec les colonnes les plus **décorrélées** possibles. Elle s'appuie logiquement sur la matrice de covariance des données.

La matrice de covariance d'un vecteur aléatoire $\mathbf{X}$ à valeurs dans $\mathbb{R}^d$ est donnée par

$$\text{Cov}(\mathbf{X}) = \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))^\top)$$

A partir d'une matrice de données $\mathbf{X} = \begin{bmatrix} \mathbf{x}_1 & \dots & \mathbf{x}_N \end{bmatrix}$, on peut calculer la matrice de covariance empirique :

$$\hat{\mathbf{C}} = \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

où $\bar{\mathbf{x}} = \frac{1}{N-1} \sum_{i=1}^N \mathbf{x}_i$ est le vecteur des moyennes empiriques. En notant

$\underline{\mathbf{X}} = \begin{bmatrix} \mathbf{x}_1 - \bar{\mathbf{x}} & \dots & \mathbf{x}_N - \bar{\mathbf{x}} \end{bmatrix}$ la matrice des données **centrées**, on a simplement

$$\hat{\mathbf{C}} = \frac{1}{N-1} \underline{\mathbf{X}} \underline{\mathbf{X}}^\top$$

Une matrice de covariance est toujours semi-définie positive.

Loi normale multivariée en deux dimensions

$$\mathbf{X} \sim f(x) = \frac{1}{2\pi\sqrt{\det(\Sigma)}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right)$$

pour $\mu \in \mathbb{R}^2, \Sigma \in \mathbb{R}^{2 \times 2}$ semi-définie positive



$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\begin{bmatrix} 1/10 & 0 \\ 0 & 1 \end{bmatrix}$$



$$\begin{bmatrix} 0.7 & 0.3 \\ 0.3 & 0.4 \end{bmatrix}$$

Comment trouver le sous-espace ?

Deux critères équivalents :

- minimiser l'erreur quadratique moyenne

$$\min \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2$$

où $\tilde{\mathbf{x}}_i$ sont les données projetées (vu comme des vecteurs de $\mathbb{R}^d$)

- maximiser la variance (empirique) totale des données projetées

$$\begin{aligned} \max \sum_{j=1}^{d'} \mathbf{u}_j^\top \hat{\mathbf{C}} \mathbf{u}_j &= \frac{1}{N-1} \sum_{j=1}^{d'} \sum_{i=1}^N |\mathbf{u}_j^\top (\mathbf{x}_i - \bar{\mathbf{x}})|^2 = \frac{1}{N-1} \sum_{i=1}^N \|\mathbf{U}^\top (\mathbf{x}_i - \bar{\mathbf{x}})\|^2 \\ &= \frac{1}{N-1} \sum_{i=1}^N \|\mathbf{z}_i - \bar{\mathbf{z}}\|^2 \end{aligned}$$

où $\mathbf{z}_i$ sont les données projetées (vu comme des vecteurs de $\mathbb{R}^{d'}$)

On a

$$\begin{aligned}\|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 &= \|\mathbf{x}_i - \bar{\mathbf{x}}\|^2 + \|\bar{\mathbf{x}} - \tilde{\mathbf{x}}_i\|^2 && \text{(Pythagore)} \\ &= \text{cste} + \|\mathbf{U}^\top (\bar{\mathbf{x}} - \tilde{\mathbf{x}}_i)\|^2 && \text{(orthogonalité)} \\ &= \text{cste} + \|\mathbf{z}_i - \bar{\mathbf{z}}\| && (\mathbf{U}^\top \mathbf{x}_i = \mathbf{U}^\top \tilde{\mathbf{x}}_i)\end{aligned}$$


Considérons la SVD de la matrice des données centrées $\underline{\mathbf{X}} = \hat{\mathbf{U}}\hat{\mathbf{\Sigma}}\hat{\mathbf{V}}$

$$\frac{1}{N-1} \sum_{j=1}^{d'} \mathbf{u}_j^\top \hat{\mathbf{U}} \hat{\mathbf{\Sigma}}^2 \hat{\mathbf{U}}^\top \mathbf{u}_j = \frac{1}{N-1} \sum_{j=1}^{d'} \sum_{i=1}^d \sigma_i^2 |\hat{\mathbf{u}}_i^\top \mathbf{u}_j|^2 \leq \frac{d'}{N-1} \sum_{i=1}^d \sigma_i^2$$

avec égalité si $\mathbf{u}_j = \hat{\mathbf{u}}_j$ pour tout $j = 1, \dots, d'$.

Une base orthogonale du sous-espace optimal est donné par les d' premiers vecteurs singuliers gauches de la matrice $\underline{\mathbf{X}}$.

Les variances selon chaque direction sont liées aux (carrés des) valeurs singulières.



Composantes principales = vecteurs singuliers de la matrice de covariance