

Optimisation Numérique et Sciences des Données

Sciences des données – Décomposition tensorielles pour les tableaux de données

Paul Catala (CRAN, UL)
paul.catala(at)univ-lorraine.fr

Master Ingénierie des Systèmes Complexes
Semestre 9 – 2025

D'après un cours de D. Brie, S. Miron et K. Usevich

1. Tableaux multidimensionnels

2. Décompositions tensorielles

3. Applications

- **Apprentissage automatique**: modélisation des distributions, réseaux de neurones, clustering, graphes
- **Chimiométrie**: MEEF, microscopie Raman polarisée
- **Imagerie médicale**: IRM, tomographie, EEG
- **Traitement d'antennes**: radar, astronomie, acoustique sous-marine, géophysique, MIMO

Les données viennent souvent sous la forme

$$\text{capteur} \times \text{caractéristique}_1 \times \dots \times \text{caractéristique}_n$$

Décomposition tensorielles:

- Compression
- Modélisation
- Fusion de données
- Explicabilité (caractéristiques dominantes, détection d'anomalies, ...)

Fonction multivariable:

$$\mathbf{v} = [v_1, \dots, v_N]$$

$$x : \mathbb{R}^N \rightarrow \mathbb{R}$$

$$\mathbf{v} \mapsto x(\mathbf{v})$$

Cas discret : en échantillonnant $x(\mathbf{v})$ sur une grille régulière, on obtien un **tableau multidimensionnel** de valeurs

$$\mathcal{X}_{i_1 i_2 \dots i_N}$$

On assimile un tenseur $\mathcal{X}$ à un tableau multidimensionnel.


N : ordre d'un tenseur (= nombre de modes)

($N = 0$) Scalaire s

($N = 1$) vecteur $\mathbf{v} = [v_i]$

($N = 2$) matrice $\mathbf{M} = [m_{ij}]$

($N \geq 3$) tenseur $\mathcal{T} = [t_{ijk}]_{i,j,k=1}^{I,J,K}, (\mathcal{T})_{ijk} = t_{ijk}$




FIBRES, TRANCHES (TENSEUR D'ORDRE 3)

Fibres:


colonnes

$$\mathcal{X}_{:,j,k}$$




lignes

$$\mathcal{X}_{i,:,k}$$



tubes


$$\mathcal{X}_{i,j,:}$$



Tranches:


horizontales

$$\mathcal{X}_{i,:,:}$$




latérales


$$\mathcal{X}_{:,j,:}$$



frontales


$$\mathcal{X}_{:,:,k}$$





Tenseur diagonal

$$(\mathcal{X})_{ijk} \neq 0 \text{ ssi } i = j = k$$




Tenseur (cubique) symétrique

$$(\mathcal{X})_{ijk} = \mathcal{X}_{\sigma(ijk)}, \sigma : \text{permutation}$$

Transformation d'un tenseur en une matrice

Un tenseur $\mathcal{Y}$ peut se déplier de N façons différentes : $\mathbf{Y}_{(n)}$



Transformation d'un tenseur en un vecteur $\mathbf{y} = \text{vec}(\mathcal{Y}) \ (IJK \times 1)$



Kronecker, Hadamard, Khatri-Rao

Notations

$$\mathbf{A} = [\mathbf{a}_1 \cdots \mathbf{a}_R], (I \times R) \quad \mathbf{B} = [\mathbf{b}_1 \cdots \mathbf{b}_R], (J \times R)$$

Produit de Kronecker

$$\mathbf{A} \otimes \mathbf{B} = \begin{bmatrix} a_{11}\mathbf{B} & a_{12}\mathbf{B} & \cdots \\ a_{21}\mathbf{B} & a_{22}\mathbf{B} & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

Produit de Khatri-Rao

$$\mathbf{A} \odot \mathbf{B} = [\mathbf{a}_1 \otimes \mathbf{b}_1 \cdots \mathbf{a}_R \otimes \mathbf{b}_R], (IJ \times R)$$

Produit de Hadamard (produit termes à termes)

$\mathbf{A}, \mathbf{B}$ matrices de même dimension $(I \times J)$

$$\mathbf{A} * \mathbf{B} = [a_{ij}b_{ij}], (I \times J)$$

Propriétés

$$\text{vec}(\mathbf{AXB}) = (\mathbf{B}^T \otimes \mathbf{A})\text{vec}(\mathbf{X})$$

$$(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = \mathbf{AC} \otimes \mathbf{BD}$$

$$(\mathbf{A} \otimes \mathbf{B})^\dagger = \mathbf{A}^\dagger \otimes \mathbf{B}^\dagger$$

$$(\mathbf{A} \odot \mathbf{B}) \odot \mathbf{C} = \mathbf{A} \odot (\mathbf{B} \odot \mathbf{C}) = \mathbf{A} \odot \mathbf{B} \odot \mathbf{C}$$

$$(\mathbf{A} \odot \mathbf{B})^\top (\mathbf{A} \odot \mathbf{B}) = \mathbf{A}^\top \mathbf{A} * \mathbf{B}^\top \mathbf{B}$$

$$(\mathbf{A} \odot \mathbf{B})^\dagger = (\mathbf{A}^\top \mathbf{A} * \mathbf{B}^\top \mathbf{B})^\dagger (\mathbf{A} \odot \mathbf{B})^\top$$

$^\top$: transposée

† : pseudoinverse

Produit tensoriel

$\mathbf{a} \circ \mathbf{b}$, $(I \times J)$, $(\mathbf{a} \circ \mathbf{b})_{ij} = a_i b_j$ i.e. $\mathbf{a} \circ \mathbf{b} = \mathbf{a} \mathbf{b}^T$, matrice de rang 1.

$\mathbf{a} \circ \mathbf{b} \circ \mathbf{c}$, $(I \times J \times K)$, $(\mathbf{a} \circ \mathbf{b} \circ \mathbf{c})_{ijk} = a_i b_j c_k$ i.e. tenseur de rang 1.

Produit n-mode

$$\mathbf{A} : (I \times I_n), \quad \mathcal{X} : (I_1 \times I_2 \cdots \times I_N)$$

$$\mathcal{X} \times_n \mathbf{A} : (I_1 \times \cdots \times I_{n-1} \times J \times I_{n+1} \cdots \times I_N)$$


$$(\mathcal{X} \times_n \mathbf{A})_{i_1 \cdots i_{n-1} j i_{n+1} \cdots i_N} = \sum_{i_n=1}^{I_n} x_{i_1 \cdots i_N} a_{j i_n}$$

1. Tableaux multidimensionnels

2. Décompositions tensorielles

3. Applications

DÉCOMPOSITIONS TENSORIELLES



$$\mathbf{X} \in \mathbb{R}^{I \times J}, \quad \mathbf{X} = \sum_{r=1}^R \mathbf{a}_r \mathbf{b}_r^T = \mathbf{A} \mathbf{B}^T$$

$$\begin{array}{c} J \\ \boxed{\mathbf{X}} \\ I \end{array} = \begin{array}{c} | \quad \mathbf{b}_1^T \quad | \\ | \quad \mathbf{a}_1 \quad | \end{array} + \cdots + \begin{array}{c} | \quad \mathbf{b}_R^T \quad | \\ | \quad \mathbf{a}_R \quad | \end{array} = \begin{array}{c} R \\ \boxed{\mathbf{A}} \\ I \end{array} \begin{array}{c} J \\ \boxed{\mathbf{B}^T} \\ R \end{array}$$

Rang d'une matrice :

1. nombre minimal de matrices de rang 1 permettant de représenter $\mathbf{X}$
2. taille minimale de la factorisation $\mathbf{A} \mathbf{B}^T$

Contraintes d'orthogonalité: SVD $\mathbf{X} = \mathbf{U} \mathbf{V}^T$

Extension de la SVD aux tenseurs depend de la définition du rang :

1. Décomposition CP (canonique polyadique)
2. Décomposition Tucker: HOSVD (Higher order SVD)


DÉCOMPOSITION DE TUCKER D'UN TENSEUR D'ORDRE 3

[Tucker, 1966], [De Lathauwer 1997]

$$(\mathcal{Y})_{ijk} = \sum_{p=1}^{R_1} \sum_{q=1}^{R_2} \sum_{r=1}^{R_3} g_{pqr} u_{ip} v_{jq} w_{kr}$$

$$\mathcal{Y} = \sum_{p=1}^{R_1} \sum_{q=1}^{R_2} \sum_{r=1}^{R_3} g_{pqr} \mathbf{u}_p \circ \mathbf{v}_q \circ \mathbf{w}_r$$

$$\mathcal{Y} = \mathcal{G} \times_1 \mathbf{U} \times_2 \mathbf{V} \times_3 \mathbf{W} = \llbracket \mathcal{G}, \mathbf{U}, \mathbf{V}, \mathbf{W} \rrbracket$$



$\mathcal{G}$ — tenseur coeur

$\mathbf{U}, \mathbf{V}, \mathbf{W}$ — matrices facteurs

$$\mathcal{X} = \mathcal{G} \times_1 \mathbf{A}^{(1)} \times_2 \mathbf{A}^{(2)} \cdots \times_N \mathbf{A}^{(N)} = \llbracket \mathcal{G}, \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$$

Non unicité de la décomposition de Tucker

$$\mathcal{X} = \llbracket \mathcal{G} \times_1 \mathbf{T}_1 \times_2 \mathbf{T}_2 \times_3 \mathbf{T}_3, \mathbf{A}\mathbf{T}_1^{-1}, \mathbf{B}\mathbf{T}_2^{-1}, \mathbf{C}\mathbf{T}_3^{-1} \rrbracket$$

Contraintes : Orthogonalité des modes et du tenseur coeur

$$\mathcal{X} = \llbracket \mathcal{G}, \mathbf{U}^{(1)}, \dots, \mathbf{U}^{(N)} \rrbracket$$

n-rank : rang colonne du tenseur déplié selon le mode n : $R_n = \text{rank}(\mathbf{X}_{(n)})$

$\Rightarrow$ **rang multilinéaire** du tenseur: $(R_1, R_2, \dots, R_N)$

Data: Data $\mathcal{X}$, rank- $(R_1, \dots, R_N)$

```
1 for  $n = 1, \dots, N$  do  
2   |    $[\mathbf{U}_n, \mathbf{\Lambda}, \mathbf{V}_n] = \text{svd}(\mathbf{X}_{(n)}, R_n)$   
3 end  
4  $\mathcal{G} = \mathcal{X} \times_1 \mathbf{U}_1^\top \cdots \times_N \mathbf{U}_N^\top$ 
```

Result: $\mathcal{G}, \mathbf{U}_1 \cdots \mathbf{U}_N$

Très proche d'une meilleure approximation de rang- $(R_1, \dots, R_N)$

[De Lathauwer 1997]

DÉCOMPOSITION CP D'UN TENSEUR D'ORDRE 3

CP (canonique polyadique) : Candecomp/PARAFAC [Hitchcock, 1927]
[Harshman, 1970-1972], [Carroll - Chang, 1970]

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r, \quad \boxed{\mathcal{X}} = \mathbf{a}_1 \left| \begin{array}{c} \mathbf{c}_1 / \\ \mathbf{b}_1 \end{array} \right. + \cdots + \mathbf{a}_R \left| \begin{array}{c} \mathbf{c}_R / \\ \mathbf{b}_R \end{array} \right.$$

rang tensoriel := nombre minimal R de tenseurs de rang 1 nécessaire pour représenter

$\mathcal{X}$.

Notation: $\mathcal{X} = \llbracket \mathbf{A}, \mathbf{B}, \mathbf{C} \rrbracket$, avec des *matrices facteurs*

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_R \end{bmatrix}, \mathbf{B} = \begin{bmatrix} \mathbf{b}_1 & \cdots & \mathbf{b}_R \end{bmatrix}, \mathbf{C} = \begin{bmatrix} \mathbf{c}_1 & \cdots & \mathbf{c}_R \end{bmatrix}$$

DÉCOMPOSITION CP (ORDRE 3) : ÉCRITURE PAR TRANCHE

$$\mathcal{X}_{:, :, k} = \text{Adiag}(C_{k, :}) B^T$$

$$\boxed{\mathcal{X}_{:, :, 1}} = \begin{array}{c} c_{1,1} \text{---} \\ | \\ \mathbf{a}_1 \end{array} \begin{array}{c} \mathbf{b}_1^T \text{---} \\ | \end{array} + \dots + \begin{array}{c} c_{R,1} \text{---} \\ | \\ \mathbf{a}_R \end{array} \begin{array}{c} \mathbf{b}_R^T \text{---} \\ | \end{array}$$

⋮

$$\boxed{\mathcal{X}_{:, :, K}} = \begin{array}{c} c_{1,K} \text{---} \\ | \\ \mathbf{a}_1 \end{array} \begin{array}{c} \mathbf{b}_1^T \text{---} \\ | \end{array} + \dots + \begin{array}{c} c_{R,K} \text{---} \\ | \\ \mathbf{a}_R \end{array} \begin{array}{c} \mathbf{b}_R^T \text{---} \\ | \end{array}$$

⇕

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r = \llbracket \mathbf{A}, \mathbf{B}, \mathbf{C} \rrbracket$$

$$\mathcal{X} = \sum_{r=1}^R \mathbf{a}_r^{(1)} \circ \dots \circ \mathbf{a}_r^{(N)} = \llbracket \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$$

Ecriture alternative par dépliage:

$$\mathbf{X}_{(1)} = \mathbf{A}^{(1)} (\mathbf{A}^{(N)} \odot \dots \odot \mathbf{A}^{(2)})^T, \quad (I_1 \times I_2 \dots I_N)$$

Cas $N = 3$: $\mathbf{X}_{(1)} = \mathbf{A}(\mathbf{C} \odot \mathbf{B})^T, \quad (I \times JK)$

Rang du tenseur : nombre minimal de tenseur de rang 1 nécessaire pour représenter $\mathcal{X}$. Définition analogue au cas matriciel ... mais le rang tensoriel a des propriétés très différentes !

- Le rang d'un tenseur peut être différent si on considère une décomposition sur $\mathbb{R}$ ou $\mathbb{C}$
- Rang maximal

$$\text{rang}(\mathcal{X}) \leq \min(IJ, IK, JK)$$

- Rang typique : rang lorsque **A**, **B** et **C** sont des matrices dont les valeurs sont des réalisations de v.a. à densité absolument continue $\neq$ rang maximal
- Approximation de rang faible : problème mal posé, impossibilité de calculer l'approximation de façon récursive ou explicite


- Survey : [Tomasi - Bro 2006]
- Moindres carrés alternés (ALS) [Harshman, 1970], [Bro, 1998]
- Méthode de descente de gradient avec recherche de pas optimal [Rajih - Comon - Harshman, 2008],
- Moindres carrés non linéaires : [Sorber - Van Barel - De Lathauwer, 2013].
- Diagonalisation conjointe, [De Lathauwer, 2006], [Luciani - Albera, 2014]
- Contrainte de non-négativité [Cichocki - Zdunek - Phan - Amari, 2009], [Royer - Thirion-Moreau - Comon, 2011].
- Boîte à outils : N-way (Matlab), tensor toolbox (Matlab), tensorlab (Matlab), three way (R), TensorLy (Python)

Data: Data $\mathcal{X}$, rank R


- 1 Initialize $\mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R}$
- 2 repeat
 - 3 for $n = 1, \dots, N$ do
 - 4 $\mathbf{V} = \mathbf{A}^{(1)\top} \mathbf{A}^{(1)} * \dots * \mathbf{A}^{(n-1)\top} \mathbf{A}^{(n-1)} * \mathbf{A}^{(n+1)\top} \mathbf{A}^{(n+1)} * \dots * \mathbf{A}^{(N)\top} \mathbf{A}^{(N)}$
 - 5 $\mathbf{A}^{(n)} = \mathbf{X}_n(\mathbf{A}^{(N)} \odot \dots \odot \mathbf{A}^{(n+1)} \dots \odot \mathbf{A}^{(n-1)} \dots \odot \mathbf{A}^{(1)}) \mathbf{V}^\dagger$
 - 6 Normalize columns of $\mathbf{A}^{(n)}$ (storing norms as $\boldsymbol{\lambda}$)
 - 7 end
- 8 until *fitting does not improve or max iteration reached*;

Result: $\boldsymbol{\lambda}, \mathbf{A}^{(1)} \dots \mathbf{A}^{(N)}$

CPD: $(I + J + K - 2)F$



Tucker: $IR_1 + JR_2 + KR_3 + R_1R_2R_3 - R_1^2 - R_2^2 - R_3^2$



Usages principaux:

Tucker: compression (meilleurs algorithmes)

CP: identification (grâce à des propriétés d'unicité)

1. Tableaux multidimensionnels

2. Décompositions tensorielles

3. Applications

On considère un tenseur $\mathcal{X}$:

- 5 capteurs industriels
- 50 instants de mesure
- 100 fréquence (e.g. imagerie hyperspectrale)

$$\mathcal{X} \simeq \sum_{r=1}^R a_r \circ b_r \circ c_r$$

- R : modes de fonctionnement du système
- a_r : capteurs sont impliqués, et leur importance
- b_r : signature temporelle (quels instants sont concernés)
- c_r : la signature fréquentielle (quelles fréquences sont concernées)

$$\boxed{\mathbf{M}} = \begin{array}{c} | \\ \mathbf{a}_1 \\ | \end{array} \begin{array}{c} \text{---} \mathbf{b}_1^{\top} \text{---} \\ \text{---} \end{array} + \dots + \begin{array}{c} | \\ \mathbf{a}_r \\ | \end{array} \begin{array}{c} \text{---} \mathbf{b}_r^{\top} \text{---} \\ \text{---} \end{array}$$

$$\begin{array}{c}
 \boxed{M_1} \\
 \vdots \\
 \boxed{M_N}
 \end{array}
 =
 \begin{array}{c}
 \begin{array}{c} c_{1,1} \cdot \\ | \\ \mathbf{a}_1 \end{array} \begin{array}{c} \mathbf{b}_1^T \\ \hline \end{array} + \dots + \begin{array}{c} c_{r,1} \cdot \\ | \\ \mathbf{a}_r \end{array} \begin{array}{c} \mathbf{b}_r^T \\ \hline \end{array} \\
 \begin{array}{c} c_{1,N} \cdot \\ | \\ \mathbf{a}_1 \end{array} \begin{array}{c} \mathbf{b}_1^T \\ \hline \end{array} + \dots + \begin{array}{c} c_{r,N} \cdot \\ | \\ \mathbf{a}_r \end{array} \begin{array}{c} \mathbf{b}_r^T \\ \hline \end{array}
 \end{array}$$

EXEMPLE EN CHIMIOMETRIE (MEEF)

$$\begin{array}{c}
 \boxed{M_1} \\
 \vdots \\
 \boxed{M_N}
 \end{array}
 =
 \begin{array}{c}
 c_{1,1} \cdot \boxed{a_1} \boxed{b_1^T} \\
 + \dots + \\
 c_{r,1} \cdot \boxed{a_r} \boxed{b_r^T}
 \end{array}$$

$$\Downarrow$$

$$\begin{array}{c}
 \dots \\
 \boxed{M_2} \\
 \boxed{M_1}
 \end{array}
 =
 \begin{array}{c}
 \boxed{a_1} \frac{c_1}{b_1} + \dots + \boxed{a_r} \frac{c_r}{b_r}
 \end{array}$$

EXEMPLE EN CHIMIOMETRIE (MEEF)


spectroscopie de fluorescence
matrice d'Emission/Excitation

rang = # composants de mélange
N experimentations, concentrations différentes


$$\begin{array}{c}
 \begin{array}{c} \text{Heatmap 1} \\ \vdots \\ \text{Heatmap N} \end{array} = \begin{array}{c} M_1 \\ \vdots \\ M_N \end{array} = \begin{array}{c} c_{1,1} \begin{array}{|c} a_1 \end{array} b_1^T \\ + \dots + \\ c_{r,1} \begin{array}{|c} a_r \end{array} b_r^T \end{array} \\
 \\
 \begin{array}{c} \text{Heatmap 1} \\ \vdots \\ \text{Heatmap N} \end{array} = \begin{array}{c} M_1 \\ \vdots \\ M_N \end{array} = \begin{array}{c} c_{1,N} \begin{array}{|c} a_1 \end{array} b_1^T \\ + \dots + \\ c_{r,N} \begin{array}{|c} a_r \end{array} b_r^T \end{array} \\
 \\
 \Downarrow \\
 \begin{array}{c} \begin{array}{c} \vdots \\ M_2 \\ M_1 \end{array} \end{array} = \begin{array}{c} c_1 \begin{array}{|c} a_1 \end{array} b_1^T \\ + \dots + \\ c_r \begin{array}{|c} a_r \end{array} b_r^T \end{array}
 \end{array}$$

EXAMPLE: CLASSIFICATION D'IMAGES

Réseau convolutionnel



Inconvenient: cout important de stockage



$$\mathcal{V}(x, y, t) = g\left(\sum_{i=x-d+1}^x \sum_{j=y-d+1}^y \sum_{s=1}^S \mathcal{K}(i-x+d, j-y+d, s, t) \mathcal{U}(i, j, s) + b(x, y, t)\right)$$


défini par tensor 4D $\mathcal{K} \in \mathbb{R}^{d \times d \times S \times T}$

⇒ compression par décomposition CP

(Lebedev et al., 2015)


$$\mathcal{K} \approx \sum_{r=1}^R \mathbf{a}_r \circ \mathbf{b}_r \circ \mathbf{c}_r \circ \mathbf{d}_r,$$

full convolution



→

sequence of 1D convolutions



- Les données se présentent très généralement sous forme matricielles/tensorielles
- Nécessité de savoir manipuler ces structures
- Il est important d'avoir des méthodes d'approximation/simplification de ces données. Cela passe souvent par des algorithmes de décompositions ou factorisations
- Les propriétés mathématiques des décompositions (existence, unicité, etc..) influent sur la complexité du problème.