

**Examen**  
**« Optimisation Numérique et Sciences des Données »**  
Durée 2 heures • Feuille manuscrite au format A4 autorisée • Calculatrice non autorisée

*Les réponses doivent être justifiées. Les exercices peuvent être résolus dans l'ordre que vous souhaitez. Le barème est indicatif.*

## 1 Questions de cours (4 points)

1. Donner la définition de la décomposition en valeurs singulières d'une matrice  $\mathbf{X} \in \mathbb{R}^{n \times p}$ .
2. Expliquer brièvement pourquoi la convexité est une propriété intéressante en optimisation.
3. Dans le problème d'optimisation associé à la classification SVM de données labellisées  $(\mathbf{x}_i, y_i)_{i=1}^N$ ,

$$\min_{\mathbf{a}, b} \frac{1}{2} \|\mathbf{a}\|^2 \quad \text{s.c.} \quad y_i(\mathbf{a}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, N$$

que représentent les variables d'optimisation ? la fonction objectif ? les contraintes ?

4. Soit le réseau à trois couches représenté en figure 1, qui comporte également une fonction d'activation  $\sigma$  sur chacune des couches latentes (bleues), ainsi que des vecteurs de biais  $\mathbf{b}^{(1)}$  et  $\mathbf{b}^{(2)}$  sur ces mêmes couches.




FIGURE 1 – Réseau de neurones

Comment s'appelle un tel réseau ? Exprimer la sortie  $y$  en fonction de l'entrée  $\mathbf{x} = (x_1, x_2, x_3)^\top$  et des paramètres du réseau  $\mathbf{W}^{(1)} = (w_{ij}^{(1)})$ ,  $\mathbf{W}^{(2)} = (w_{ij}^{(2)})$ ,  $\mathbf{v} = (v_1, v_2)^\top$ ,  $\mathbf{b}^{(1)}$ ,  $\mathbf{b}^{(2)}$  et  $\sigma$ .

## 2 Optimisation (5 points)

On considère la fonction convexe  $f : \mathbb{R}^2 \rightarrow \mathbb{R}$  suivante :

$$f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} - \mathbf{b}^\top \mathbf{x} + 2,$$

---

où

$$\mathbf{A} = \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix} \quad \text{et} \quad \mathbf{b} = \begin{bmatrix} 5 \\ 1 \end{bmatrix}.$$

On souhaite minimiser  $f$ .

1. Donner l'expression et calculer le vecteur gradient  $\mathbf{J}(\mathbf{x})$  de  $f$ .
2. Donner l'expression et calculer la matrice Hessienne  $\mathbf{H}(\mathbf{x})$  de  $f$ .
3. Quelles sont les conditions d'optimalité du problème de minimisation ?
4. En déduire le minimiseur  $(\mathbf{x}_*)$ , puis la valeur du minimum.
5. On minimise  $f$  itérativement à l'aide de la méthode de Newton, avec un pas  $\alpha$  constant. Déterminer, en expliquant vos calculs, le résultat  $(x_1, y_1)$  d'une itération de cet algorithme, en initialisant à  $(x_0, y_0) = (0, 0)$ . Quel serait un bon choix pour la valeur du pas  $\alpha$  ? Justifier.

### 3 SVM à noyau (5 points)

On considère un problème de classification à deux classes avec la base d'apprentissage

$$\mathbf{X} = \begin{bmatrix} -2 \\ -1 \\ 0 \\ 1 \\ 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ -1 \\ -1 \\ 1 \\ 1 \end{bmatrix}$$

où  $\mathbf{X}$  contient les observations et  $\mathbf{y}$  les classes associées. Noter que chaque observation  $x_i$ , ( $i = 1, \dots, 5$ ) est un scalaire (dans  $\mathbb{R}$ ).

1. Représenter les observations sur le segment de la figure 2a en utilisant deux couleurs (ou deux formes) différentes pour bien distinguer les classes 1 et  $-1$ .
2. Les classes sont-elles linéairement séparables ?
3. Si oui, représenter sur la même figure un hyperplan séparateur. Sinon, tracer un hyperplan qui conduit à un minimum de mauvaises classifications en précisant ce nombre.
4. On se propose maintenant de transformer les données dans un espace de représentation  $\mathbb{R}^2$  en utilisant une fonction de redescription  $\Phi(x)$  telle que :

$$\begin{aligned} \Phi &: \mathbb{R} \rightarrow \mathbb{R}^2 \\ x &\mapsto [x \quad x^2] \end{aligned}$$

- (a) On note  $\mathbf{Z} = [\mathbf{z}_1 \quad \mathbf{z}_2]$  la matrice à deux colonnes des données projetées. Calculer leurs coordonnées ( $\mathbf{z}_1$  et  $\mathbf{z}_2$ ) en utilisant les données d'apprentissage.
- (b) Représenter les données projetées sur la figure 2b en utilisant les mêmes couleurs (ou formes) que la question 1.
- (c) Les classes sont-elles linéairement séparables ? Dans l'affirmative, tracer sur la même figure le séparateur à marge maximale et calculer la marge.
- (d) Quels sont les vecteurs de support ?
- (e) Que se passe-t-il si l'on retire l'observation  $x_4$  (considérée comme valeur aberrante) des données d'apprentissage ? Expliquer en quelques lignes ce que devient l'hyperplan séparateur dans l'espace de redescription et la marge associée.

---

## 4 Problème : Décomposition en valeurs singulières et ACP (6 points)

Il est possible d'admettre le résultat d'une question et de l'utiliser pour résoudre les questions suivantes.

Soit un ensemble de données  $\{\mathbf{x}_1, \dots, \mathbf{x}_N\} \in \mathbb{R}^d$  ( $N > d$ ), et la matrice de données centrées correspondante

$$\underline{\mathbf{X}} = [\mathbf{x}_1 - \underline{\mathbf{x}} \quad \dots \quad \mathbf{x}_N - \underline{\mathbf{x}}] \in \mathbb{R}^{d \times N} \quad \text{où} \quad \underline{\mathbf{x}} := \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i.$$

L'analyse en composantes principales (ACP) est une technique de réduction de dimension, qui consiste à projeter chaque donnée  $\mathbf{x}_i$  sur des axes  $\mathbf{a}_1, \dots, \mathbf{a}_p \in \mathbb{R}^d$  ( $p < d$ ). Les  $p$  nouvelles coordonnées définissent alors des données projetées  $\tilde{\mathbf{x}}_i \in \mathbb{R}^p$ , données par

$$\tilde{\mathbf{x}}_i = \mathbf{A}^\top \mathbf{x}_i, \quad \text{où} \quad \mathbf{A} := [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_p].$$

Le principe de l'ACP est de choisir les axes  $\mathbf{a}_k$  de manière à maximiser la variance empirique des données projetées, souvent appelée *variance expliquée*, définie comme

$$\tilde{\mathcal{V}} := \frac{1}{N-1} \sum_{i=1}^N \|\tilde{\mathbf{x}}_i - \tilde{\underline{\mathbf{x}}}\|^2, \quad \text{où} \quad \tilde{\underline{\mathbf{x}}} := \frac{1}{N} \sum_{i=1}^N \tilde{\mathbf{x}}_i.$$

Dans la suite, on note

$$\mathbf{C} := \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top.$$

Cette matrice s'appelle *matrice de covariance* des données (non projetées).

1. Justifier que

$$\tilde{\mathcal{V}} = \sum_{k=1}^p \mathbf{a}_k^\top \mathbf{C} \mathbf{a}_k.$$

On souhaite déterminer les axes  $\mathbf{a}_1, \dots, \mathbf{a}_p$  qui maximisent  $\tilde{\mathcal{V}}$  (pour  $p$  donné). On supposera sans perte de généralités que  $\|\mathbf{a}_k\| = 1$  pour tout  $k$ . Soit la décomposition en valeurs singulières de  $\underline{\mathbf{X}}$

$$\underline{\mathbf{X}} = \mathbf{U} \mathbf{\Sigma} \mathbf{V} = \sum_{i=1}^d \sigma_i \mathbf{u}_i \mathbf{v}_i^\top.$$

2. Exprimer  $\mathbf{C}$  en fonction de  $\underline{\mathbf{X}}$ .

**Indication :** on rappelle que pour tout  $\mathbf{B} = [\mathbf{b}_1 \quad \mathbf{b}_2 \quad \dots]$ ,  $\mathbf{B} \mathbf{B}^\top = \sum \mathbf{b}_i \mathbf{b}_i^\top$ .

3. En déduire que

$$\mathbf{C} = \frac{1}{N-1} \sum_{i=1}^d \sigma_i^2 \mathbf{u}_i \mathbf{u}_i^\top.$$

4. Dédurre de ce qui précède et de la question 1. que pour tout choix d'axes  $\mathbf{a}_k$ ,

$$\tilde{\mathcal{V}} \leq \frac{p}{N-1} \sum_{i=1}^d \sigma_i^2.$$

5. Quand y-a-t-il égalité ci-dessus ? Conclure.




FIGURE 2 – SVM à noyau