

Optimisation numérique et science des données

Optimisation – Moindres carrés linéaires

Master Ingénierie des Systèmes Complexes
MISC923

E.-H. Djermoune (CRAN, UL, CNRS) el-hadi.djermoune@univ-lorraine.fr

15 septembre 2025

Programme du cours

1 Introduction

2 Formulation générale et exemples

- Moindre carrés linéaires
- Exemple 1 : régression polynomiale
- Exemple 2 : déconvolution


3 Résolution du problème

- Dérivation vectorielle
- Résolution explicite des moindres carrés

4 Moindres carrés régularisés


- Motivation
- Ajout d'une régularisation
- Exemple : déconvolution avec a priori lisse

Un premier exemple : régression linéaire



on cherche une relation simple entre
les variables d'entrée (explicatives) x_i et les données (ou mesures) y_i

Un premier exemple : régression linéaire



modèle linéaire $y_i \approx \beta_0 + \beta_1 x_i$
où (β_0, β_1) sont les paramètres du modèle à estimer

Solution par les moindres carrés

Construisons un fonction objectif en les paramètres (β_0, β_1)

Erreur modèle pour i fixé :

$$\varepsilon_i(\beta_0, \beta_1) = (y_i - \beta_0 - \beta_1 x_i)^2$$

Solution par les moindres carrés

Construisons un fonction objectif en les paramètres (β_0, β_1)

Erreur modèle pour i fixé :

$$\varepsilon_i(\beta_0, \beta_1) = (y_i - \beta_0 - \beta_1 x_i)^2$$

Erreur modèle totale :

$$\varepsilon(\beta_0, \beta_1) = \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2$$

Solution par les moindres carrés

Construisons une fonction objectif en les paramètres (β_0, β_1)

Erreur modèle pour i fixé :

$$\varepsilon_i(\beta_0, \beta_1) = (y_i - \beta_0 - \beta_1 x_i)^2$$

Erreur modèle totale :

$$\varepsilon(\beta_0, \beta_1) = \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2$$

Pour un vecteur de données fixé $\mathbf{y} = (y_1, \dots, y_N)^\top$ et des variables explicatives $\mathbf{x} = (x_1, \dots, x_N)^\top$ connues, on obtient alors le problème d'optimisation sans contraintes suivant :

$$\min_{\beta_0, \beta_1 \in \mathbb{R}} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2$$

C'est un problème de moindres carrés (linéaires).

On retrouve ce type de problème dans de très nombreuses applications, telles que l'ingénierie, l'économétrie, le traitement d'image, etc.

Programme du cours

1 Introduction

2 Formulation générale et exemples

- Moindre carrés linéaires
- Exemple 1 : régression polynomiale
- Exemple 2 : déconvolution

3 Résolution du problème

- Dérivation vectorielle
- Résolution explicite des moindres carrés

4 Moindres carrés régularisés

- Motivation
- Ajout d'une régularisation
- Exemple : déconvolution avec a priori lisse

Forme générale : moindres carrés linéaires

Hyp. : relation linéaire entre les données $\mathbf{y}$ et les variables à estimer.

$$\begin{array}{c} \boxed{\mathbf{y}} \\ \text{données} \end{array} = \begin{array}{c} \boxed{\mathbf{A}} \\ \text{mélange linéaire } \mathbf{Ax} \end{array} \begin{array}{c} \boxed{\mathbf{x}} \\ \text{variables à estimer} \end{array} + \begin{array}{c} \boxed{\mathbf{b}} \\ \text{bruit, erreur} \end{array}$$

Définitions et notations

- le vecteur $\mathbf{y} \in \mathbb{R}^M$ rassemble les données (que l'on veut modéliser)
- la matrice $\mathbf{A} \in \mathbb{R}^{M \times N}$ encode le modèle (supposé connu)
- le vecteur $\mathbf{x} \in \mathbb{R}^N$ donne les inconnues du problème
- le vecteur $\mathbf{b} \in \mathbb{R}^M$ exprime les erreurs (dus au modèle, bruit, etc.)

Forme générale : moindres carrés linéaires

Hyp. : relation linéaire entre les données $\mathbf{y}$ et les variables à estimer.

$$\mathbf{y} = \mathbf{A} \mathbf{x} + \mathbf{b}$$

données modèle linéaire $\mathbf{Ax}$ bruit, erreur

Problème des moindres carrés linéaires :

connaissant $\mathbf{y}$ et $\mathbf{A}$, trouver $\hat{\mathbf{x}}$ comme solution du problème

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} \|\mathbf{y} - \mathbf{Ax}\|_2^2$$

Forme générale : moindres carrés linéaires

Problème des moindres carrés linéaires :

connaissant $\mathbf{y}$ et $\mathbf{A}$, trouver $\hat{\mathbf{x}}$ comme solution du problème


$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} \|\mathbf{y} - \mathbf{Ax}\|_2^2$$

Nombre d'inconnues M vs nombre d'observations N


- si $M \geq N$: si $\text{rang}(\mathbf{A}) = N$, il y a au moins autant d'équations que d'inconnues. Le système $\mathbf{y} = \mathbf{Ax}$ est dit sur-déterminé ; la solution $\hat{\mathbf{x}}$ est unique.
- si $M < N$: il y a moins d'équations que d'inconnues. Le système $\mathbf{y} = \mathbf{Ax}$ est dit sous-déterminé. Il y a une infinité de solutions $\hat{\mathbf{x}}$.

Dans un premier temps, on s'intéresse au cas $M \geq N$.

Exemple 1 : régression polynomiale



Exemple 1 : régression polynomiale



Exemple 1 : régression polynomiale

On fixe (ou l'on connaît) le degré du polynôme (ici $d = 3$).

Modèle polynomial

$$y_m(t) = x_3 t^3 + x_2 t^2 + x_1 t + x_0$$

Mesures




$$y_i = y_m(t_i) + b_i \text{ pour } t_1, \dots, t_M \text{ connus}$$

Mise en équation

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_M \end{bmatrix} = \begin{bmatrix} 1 & t_1 & t_1^2 & t_1^3 \\ 1 & t_2 & t_2^2 & t_2^3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & t_M & t_M^2 & t_M^3 \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_M \end{bmatrix} = \mathbf{Ax} + \mathbf{b}$$

Le vecteur $\hat{\mathbf{x}}$ donne l'estimation au sens des moindres carrés des coefficients du polynôme $y_m(t)$.

Exemple 2 : déconvolution



Objectif

connaissant $h(t)$, retrouver $x(t)$ à partir de $y(t) = (h * x)(t) + b(t)$

Exemple 2 : déconvolution

Variables en temps discret $\mathbf{y} \in \mathbb{R}^M$, $\mathbf{h} \in \mathbb{R}^L$, $\mathbf{x} \in \mathbb{R}^N$, $M = N + L - 1$.


Produit de convolution en temps discret

$$y_m = \sum_{\ell=1}^L h_{\ell} x_{m-\ell+1}$$


Mise en équation

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{L-1} \\ \vdots \\ y_M \end{bmatrix} = \begin{bmatrix} h_1 & 0 & \cdots & 0 & 0 \\ h_2 & h_1 & & \vdots & \vdots \\ h_3 & h_2 & \cdots & 0 & 0 \\ \vdots & h_3 & \cdots & h_1 & 0 \\ h_{L-1} & \vdots & \ddots & h_2 & h_1 \\ h_L & h_{L-1} & & \vdots & h_2 \\ 0 & h_L & \ddots & h_{L-2} & \vdots \\ 0 & 0 & \cdots & h_{L-1} & h_{L-2} \\ \vdots & \vdots & & h_L & h_{L-1} \\ 0 & 0 & 0 & \cdots & h_L \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_M \end{bmatrix} = \mathbf{Ax} + \mathbf{b}$$


Exemple 2 : déconvolution



Exemple 2 : déconvolution



Exemple 2 : déconvolution



Programme du cours

1 Introduction

2 Formulation générale et exemples

- Moindres carrés linéaires
- Exemple 1 : régression polynomiale
- Exemple 2 : déconvolution

3 Résolution du problème

- Dérivation vectorielle
- Résolution explicite des moindres carrés

4 Moindres carrés régularisés

- Motivation
- Ajout d'une régularisation
- Exemple : déconvolution avec a priori lisse

Résolution du problème

On cherche à présent à trouver $\hat{\mathbf{x}}$ solution de

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} \|\mathbf{y} - \mathbf{Ax}\|_2^2$$

Commentaire sur la fonction objectif

- la fonction $\mathbf{x} \mapsto \|\mathbf{y} - \mathbf{Ax}\|_2^2$ est convexe (le démontrer !)
- le critère se réécrit

$$\|\mathbf{y} - \mathbf{Ax}\|_2^2 = (\mathbf{y} - \mathbf{Ax})^\top (\mathbf{y} - \mathbf{Ax}) \quad (1)$$

$$= \mathbf{y}^\top \mathbf{y} - \mathbf{x}^\top \mathbf{A}^\top \mathbf{y} - \mathbf{y}^\top \mathbf{Ax} + \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} \quad (2)$$

- le problème d'optimisation peut se reformuler de manière équivalente

$$\hat{\mathbf{x}} = \arg \min_{\mathbf{x} \in \mathbb{R}^N} \frac{1}{2} \mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} - \mathbf{y}^\top \mathbf{Ax}$$

Formulaire de dérivation vectorielle

Puisque le critère des moindres carrés est convexe, il suffit d'annuler le gradient pour trouver $\hat{\mathbf{x}}$ (cf cours 1).

Autrement dit, pour $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} - \mathbf{y}^\top \mathbf{A} \mathbf{x}$, il faut calculer $\nabla f(\mathbf{x})$

Résultats à connaître

[matrixcookbook]

$$\nabla f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$$

$$\nabla^2 f(\mathbf{x}) = \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^\top}$$

$$\frac{\partial \mathbf{x}^\top \mathbf{a}}{\partial \mathbf{x}} = \frac{\partial \mathbf{a}^\top \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$$

$$\frac{\partial \mathbf{x}^\top \mathbf{B} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{B} + \mathbf{B}^\top) \mathbf{x}$$

Résolution explicite des moindres carrés

On considère $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} - \mathbf{y}^\top \mathbf{A} \mathbf{x}$ (ou $f(\mathbf{x}) = \|\mathbf{y} - \mathbf{A} \mathbf{x}\|_2^2$)

Calcul de $\nabla f(\mathbf{x})$:

$$\begin{aligned} \nabla f(\mathbf{x}) &= \frac{1}{2} \frac{\partial \mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} - \frac{\partial \mathbf{y}^\top \mathbf{A} \mathbf{x}}{\partial \mathbf{x}} \\ &= \frac{1}{2} (\mathbf{A}^\top \mathbf{A} + (\mathbf{A}^\top \mathbf{A})^\top) \mathbf{x} - (\mathbf{y}^\top \mathbf{A})^\top \\ &= \mathbf{A}^\top \mathbf{A} \mathbf{x} - \mathbf{A}^\top \mathbf{y} \end{aligned}$$

Equations normales

$$\nabla f(\hat{\mathbf{x}}) = 0 \Leftrightarrow \mathbf{A}^\top \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^\top \mathbf{y}$$

Solution explicite ($\mathbf{A}^\top \mathbf{A}$ est inversible car $\mathbf{A}$ est de rang colonne plein)

$$\hat{\mathbf{x}} = \left[\mathbf{A}^\top \mathbf{A} \right]^{-1} \mathbf{A}^\top \mathbf{y} = \mathbf{A}^\dagger \mathbf{y} \quad \text{où } \mathbf{A}^\dagger \text{ est la pseudo-inverse de } \mathbf{A}$$

Pseudo-inverse de Moore-Penrose

Pour une matrice $\mathbf{A} \in \mathbb{R}^{M \times N}$ telle que

- $M \geq N$;
- les colonnes de $\mathbf{A}$ sont indépendantes ($\text{rang}(\mathbf{A}) = N$)

La matrice

$$\mathbf{A}^\dagger = \left[\mathbf{A}^\top \mathbf{A} \right]^{-1} \mathbf{A}^\top$$

est appelée la pseudo-inverse de Moore-Penrose de $\mathbf{A}$.

Propriétés

- $\mathbf{A}^\dagger$ est un inverse à gauche de $\mathbf{A}$, i.e., $\mathbf{A}^\dagger \mathbf{A} = \mathbf{I}_N$
- si $M = N$ et $\mathbf{A}$ inversible, alors $\mathbf{A}^\dagger = \mathbf{A}^{-1}$
- en pratique, $\mathbf{A}^\dagger$ peut être calculée efficacement à partir de
 - la décomposition QR de $\mathbf{A} = \mathbf{Q}\mathbf{R}$
 - la SVD de $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top$

Programme du cours

1 Introduction

2 Formulation générale et exemples

- Moindre carrés linéaires
- Exemple 1 : régression polynomiale
- Exemple 2 : déconvolution

3 Résolution du problème

- Dérivation vectorielle
- Résolution explicite des moindres carrés

4 Moindres carrés régularisés

- Motivation
- Ajout d'une régularisation
- Exemple : déconvolution avec a priori lisse

Motivation

Que se passe-t-il si l'on ajoute du bruit au modèle $\mathbf{y} = \mathbf{Ax}$?

- cas sans bruit $\mathbf{y} = \mathbf{Ax}$ $\xrightarrow{\text{moindres carrés}}$ $\hat{\mathbf{x}} = \mathbf{A}^\dagger \mathbf{y} = \mathbf{A}^\dagger \mathbf{Ax} = \mathbf{x}$
- cas bruité $\mathbf{y} = \mathbf{Ax} + \mathbf{b}$ $\xrightarrow{\text{moindres carrés}}$ $\hat{\mathbf{x}} = \mathbf{A}^\dagger \mathbf{y} = \mathbf{x} + \underbrace{\mathbf{A}^\dagger \mathbf{b}}_{\text{perturbation}}$

Analyse de sensibilité

idéalement, une petite variation des données $\mathbf{y}$ doit impliquer une petite variation de la solution $\hat{\mathbf{x}}$.

Autrement dit, pour $\|\mathbf{b}\|$ petit, $\|\mathbf{A}^\dagger \mathbf{b}\|$ doit rester petit

Retour sur l'exemple : déconvolution

cf notebook.

Sensibilité et conditionnement

La sensibilité d'un problème de moindres carrés se quantifie par le conditionnement de la matrice $\mathbf{A}$, noté $\text{cond}(\mathbf{A})$

$$\mathbf{y} = \mathbf{A}\mathbf{x} \rightarrow \hat{\mathbf{x}} = \mathbf{A}^\dagger \mathbf{y} = \mathbf{x}, \quad \mathbf{y} + \delta\mathbf{y} \rightarrow \hat{\mathbf{x}} = \mathbf{A}^\dagger (\mathbf{y} + \delta\mathbf{y}) = \mathbf{x} + \mathbf{A}^\dagger \delta\mathbf{y} = \mathbf{x} + \delta\mathbf{x}$$

En utilisant les propriétés des normes vectorielles

$$\|\mathbf{y}\| = \|\mathbf{A}\mathbf{x}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\| \text{ et } \|\delta\mathbf{x}\| = \|\mathbf{A}^\dagger \delta\mathbf{y}\| \leq \|\mathbf{A}^\dagger\| \cdot \|\delta\mathbf{y}\|$$

On obtient

$$\frac{\|\delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \underbrace{\|\mathbf{A}\| \cdot \|\mathbf{A}^\dagger\|}_{=\text{cond}(\mathbf{A})} \frac{\|\delta\mathbf{y}\|}{\|\mathbf{y}\|}$$

Interprétation $\text{cond}(\mathbf{A}) \nearrow$, sensibilité numérique $\nearrow$.

Cas idéal : $\text{cond}(\mathbf{A}) = 1$

Ajout d'une régularisation

Comment améliorer la stabilité de la solution des moindres carrés ?


→ le conditionnement du problème peut être amélioré par l'ajout d'une régularisation (ou pénalisation) dite de Tikhonov dans le critère à minimiser

Moindres carrés régularisés par Tikhonov

$$\min_{\mathbf{x} \in \mathbb{R}^N} \|\mathbf{y} - \mathbf{A}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_2^2 \quad \lambda \geq 0$$

- la régularisation $\lambda \|\mathbf{x}\|_2^2$ "déforme" le critère des moindres carrés initial au fur et à mesure que λ grandit
- le conditionnement du problème diminue avec λ

Exemple : déconvolution régularisée par Tikhonov



Cas général des moindres carrés régularisés

$$\min_{\mathbf{x} \in \mathbb{R}^N} \|\mathbf{y} - \mathbf{Ax}\|_2^2 + \lambda r(\mathbf{x}), \quad \lambda \geq 0$$

où $r(\mathbf{x})$ est une régularisation (ou pénalité) et $\lambda \geq 0$ contrôle le compromis entre "attache aux données" et régularisation

Pourquoi régulariser ?

- pour améliorer le conditionnement du problème ;
- pour rendre unique la solution du problème (cas $M < N$ et/ou $\mathbf{A}$ de rang déficient)
- pour prendre en compte des a priori ou des propriétés recherchées de la solution
- pour rendre le problème d'estimation de $\mathbf{x}$ *bien posé*.

Un exemple : débruitage d'un signal

On considère le modèle $\mathbf{y} = \mathbf{x} + \mathbf{b}$ avec $\mathbf{b}$ un bruit blanc Gaussien.

Exercice

- montrer que la solution du problème des moindres carrés est $\hat{\mathbf{x}} = \mathbf{y}$.
- on sait que le signal $\mathbf{x}$ recherché est lisse. On propose alors de pénaliser les variations trop rapides du signal $\mathbf{x}$ avec la fonction

$$r(\mathbf{x}) = \sum_{n=1}^{N-1} (x_{n+1} - x_n)^2$$

Montrer que $r(\mathbf{x})$ peut se mettre sous la forme $r(\mathbf{x}) = \|\mathbf{D}\mathbf{x}\|_2^2$

- donner la solution explicite du problème des moindres carrés régularisés.

Calcul de la solution régularisée

La fonction objectif s'écrit à présent

$$f(\mathbf{x}) = \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda \|\mathbf{D}\mathbf{x}\|_2^2$$


Le gradient est donné par

$$\begin{aligned}\nabla f(\mathbf{x}) &= \nabla \|\mathbf{y} - \mathbf{x}\|_2^2 + \lambda \nabla \|\mathbf{D}\mathbf{x}\|_2^2 \\ &= 2(\mathbf{x} - \mathbf{y}) + 2\lambda \mathbf{D}^\top \mathbf{D}\mathbf{x}\end{aligned}$$

La solution régularisée est obtenue en annulant le gradient :

$$\hat{\mathbf{x}} = \left(\mathbf{I}_N + \lambda \mathbf{D}^\top \mathbf{D} \right)^{-1} \mathbf{y}$$

Illustration



Illustration

