

TD 6

Classification

Exercice 6.1 Marge d'un hyperplan

On considère des données labellisées linéairement séparables (x_i, y_i) , $y_i \in \{1, -1\}$, et un hyperplan séparateur H d'équation $a^\top x + b = 0$, où $a \in \mathbb{R}^n$ et $b \in \mathbb{R}$. On supposera que x_1 et x_2 sont des vecteurs de support pour chacune des classes, c'est-à-dire tels que

$$a^\top x_1 + b = 1 \quad \text{et} \quad a^\top x_2 + b = -1.$$

1. Montrer que a est un vecteur normal à H , i.e. pour tout $x, y \in H$, $a^\top(x - y) = 0$.
2. Montrer que pour tout point $x \in \mathbb{R}^n$,

$$d(x, H) = \frac{|a^\top x + b|}{\|a\|}$$

3. En déduire l'expression de la marge de H en fonction de a .

Solution.

1. On a $a^\top(x - y) = a^\top x + b - (a^\top y + b) = 0 + 0 = 0$ car x et y appartiennent à l'hyperplan.
2. Pour tout point p de l'hyperplan H , on a

$$d(x, H) = \frac{|a^\top(x - p)|}{\|a\|} = \frac{|a^\top x + b - (a^\top p + b)|}{\|a\|} = \frac{|a^\top x + b|}{\|a\|}$$

3. La marge est donnée par $d(x_1, H) + d(x_2, H) = \frac{1}{\|a\|} + \frac{1}{\|a\|} = \frac{2}{\|a\|}$.

Exercice 6.2 Astuce du noyau

On considère un jeu de 8 données labellisées $(\mathbf{x}^{(i)}, y^{(i)})$, avec $\mathbf{x}^{(i)} \in \mathbb{R}^2$ et $y^{(i)} \in \{-1, +1\}$, pour $i = 1, \dots, 8$. Ces données sont représentées en Figure 6.1. On cherche à classer automatiquement ces données à l'aide de la méthode des machines à vecteurs de support (SVM).

1. On rappelle qu'une SVM classique consiste à résoudre le problème d'optimisation

$$\min_{\mathbf{a} \in \mathbb{R}^2, b \in \mathbb{R}} \quad \frac{1}{2} \|\mathbf{a}\|^2 \quad \text{s.c.} \quad y^{(i)}(\mathbf{a}^\top \mathbf{x}^{(i)} + b) \geq 1 \quad i = 1, \dots, 8 \quad (6.1)$$

- (a) Que représentent les contraintes du problème ?
 - (b) Que représente la fonction objectif ?
2. Expliquer pourquoi résoudre le problème (6.1) pour les données considérées ici ne permettra pas d'identifier les deux classes.

3. Expliquer le principe de l'astuce du noyau.
4. On applique aux données une transformation $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^2$. Le résultat est montré en Figure 6.2. Parmi les quatre transformations φ proposées ci-dessous, laquelle conduit au résultat observé ?

$$(a) \varphi(\mathbf{x}) = \begin{bmatrix} x_1 & x_1^2 + x_2^2 \end{bmatrix} \quad (b) \varphi(\mathbf{x}) = \begin{bmatrix} x_1 & x_1 + 2x_2 \end{bmatrix}$$

$$(c) \varphi(\mathbf{x}) = \begin{bmatrix} x_2 & x_1^2 - x_2^2 \end{bmatrix} \quad (d) \varphi(\mathbf{x}) = \begin{bmatrix} x_2 & x_1^2 \end{bmatrix}$$

Indiquer sur la Figure 6.2 à côté de chaque point la donnée initiale correspondante.

5. Représenter l'hyperplan séparateur optimal sur la Figure 6.2. Donner son équation, et déterminer sa marge. Quels sont les vecteurs de support ?
6. On considère une nouvelle donnée $\mathbf{x}^{(9)} = (-1, -\sqrt{2})$ et $y^{(9)} = -1$. Représenter cette nouvelle donnée sur la Figure 6.1 (on donne $\sqrt{2} \simeq 1.414$). Cette donnée sera-t-elle correctement classifiée par la SVM à noyau appris sur le jeu de données initial ? Justifier votre réponse.




FIGURE 6.1 – Jeu de données (rouge : -1, cyan : +1)

Exercice 6.3 Lagrangien

Soit $(x_i, y_i) \in \mathbb{R}^n \times \{1, -1\}$, $i = 1, \dots, p$, des données labellisées. Une SVM à marge souple consiste à résoudre le problème d'optimisation

$$\min_{\substack{a \in \mathbb{R}^n \\ b \in \mathbb{R} \\ \xi \in \mathbb{R}^p}} \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i \quad \text{s.c.} \quad \xi_i \geq 0, \quad y_i(a^\top x_i + b) \geq 1 - \xi_i \quad i = 1, \dots, p,$$

pour un α donné.

1. Que représente les variables ξ_i ?
2. Ecrire le Lagrangien $\mathcal{L}$ de ce problème.




FIGURE 6.2 – Données après transformation

3. Calculer les gradients par rapport à a , b et ξ de $\mathcal{L}$. Quelle condition doivent-ils satisfaire à l'optimum ?

Solution.

1. ξ_i représente l'écart de la donnée x_i du mauvais côté de la marge. Dans les SVM à marge souple, ces écarts sont autorisés mais pénalisés (par le terme $\sum \xi_i$ dans l'optimisation).
2. Mis sous forme standard, le problème devient

$$\min \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i \quad \text{s.c.} \quad -\xi_i \leq 0, \quad 1 - \xi_i - y_i(a^\top x_i + b) \leq 0$$

On a $2p$ contraintes d'inégalités : les contraintes de positivité des ξ_i et les contraintes de marge. On note respectivement μ_i et λ_i ($i = 1, \dots, p$) les multiplicateurs de Lagrange associés à ces contraintes. Le Lagrangien du problème est alors donné par

$$\mathcal{L}(a, b, \lambda, \mu) = \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i - \sum \mu_i \xi_i + \sum \lambda_i (1 - \xi_i - y_i(a^\top x_i + b))$$

3. On a

$$\nabla_a \mathcal{L}(a, b, \xi, \lambda, \mu) = a - \sum \lambda_i y_i x_i$$

$$\nabla_b \mathcal{L}(a, b, \xi, \lambda, \mu) = - \sum \lambda_i y_i$$

$$\nabla_\xi \mathcal{L}(a, b, \xi, \lambda, \mu) = \alpha - \mu - \lambda$$

A l'optimum, tous ces gradients doivent être nuls. En particulier, cela implique que

$$a = \sum \lambda_i y_i x_i, \quad \sum \lambda_i y_i = 0, \quad \mu + \lambda = \alpha$$

(comme μ et λ doivent être positives, la dernière contrainte impliquera en particulier que $0 \leq \lambda_i \leq \alpha$ pour tout i).

Exercice 6.4 Perceptron

On considère le réseau à deux couches représenté en Figure 6.3, où l'on a explicitement représenté la fonction non-linéaire σ et les biais b_1, b_2 :




FIGURE 6.3 – Réseau de neurones

1. Exprimer les sorties intermédiaires z_1 et z_2 en fonction de l'entrée $\mathbf{x} = [x_1 \ x_2 \ x_3]^\top$, des vecteurs de poids $\mathbf{w}_1 = [w_{11} \ w_{12} \ w_{13}]^\top$, $\mathbf{w}_2 = [w_{21} \ w_{22} \ w_{23}]^\top$, et des biais b_1, b_2 .
2. Exprimer de même la sortie finale y en fonction de $\mathbf{x}$ et des différents paramètres du réseau.