



Faculté des Sciences et Technologies
Master 2 Ingénierie des Systèmes Complexes (ISC)

Feuilles de TD

Optimisation numérique

P. Catala, E.-H. Djermoune

Table des matières

1	Introduction à l'optimisation	3
	Exercice 1.1 Questions de cours	
	Exercice 1.2 Formulation d'un problème d'optimisation	
	Exercice 1.3 Calcul vectoriel	
	Exercice 1.4 Convexité	
2	Moindres carrés linéaires	5
	Exercice 2.1 Formes matricielles	
	Exercice 2.2 Régression polynomiale	
	Exercice 2.3 Estimateur des moindres carrés	
3	Méthodes itératives	7
	Exercice 3.1 Méthode de descente de gradient	
	Exercice 3.2 Méthode de Newton	
4	Décomposition en valeurs singulières	9
	Exercice 4.1 Calcul de la SVD	
	Exercice 4.2 Approximation de rang faible	
5	Tenseurs	13
	Exercice 5.1 Manipulations de tenseurs	
	Exercice 5.2 Calculs tensoriels	
6	Classification	15
	Exercice 6.1 Marge d'un hyperplan	
	Exercice 6.2 Astuce du noyau	
	Exercice 6.3 Lagrangien	
	Exercice 6.4 Perceptron	

TD 1

Introduction à l'optimisation

Exercice 1.1 Questions de cours

1. On considère le problème $(\mathcal{P})$ d'optimisation suivant :

$$\min_{x_1, x_2} (x_1 - 3)^2 + (x_2 + 2)^2 \quad \text{t.q.} \quad \begin{cases} 3x_2^2 - x_2 = 0 \\ x_1 + x_2 \leq 2 \end{cases} \quad (\mathcal{P})$$

- (a) Donner la ou les variables du problème $(\mathcal{P})$. Quelle est la dimension de ce problème ?
 - (b) Donner l'expression de la fonction objectif du problème $(\mathcal{P})$.
 - (c) Donner les contraintes du problème $(\mathcal{P})$ et les classer par catégorie.
 - (d) A partir de votre analyse du problème $(\mathcal{P})$, proposer une simplification sous la forme d'un nouveau problème d'optimisation équivalent.
2. On considère à présent le problème d'optimisation suivant :

$$\min_{x_1, x_2} 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

- (a) Caractériser le problème d'optimisation : variables, fonction objectif, contraintes.
- (b) Soit $\mathbf{x}^* \in \mathbb{R}^2$. Enoncer une condition nécessaire pour que $\mathbf{x}^*$ soit un minimiseur local du problème d'optimisation.
- (c) Le vecteur $(0, 0)^\top$ est-il un minimiseur local du problème ?

Exercice 1.2 Formulation d'un problème d'optimisation

Des manufactures livrent chaque matin des pièces de carrosserie dans des usines d'assemblage de voitures. Il y a n manufactures qui produisent chacune une quantité journalière (fixe) $a_1, \dots, a_n$ de pièces, et m usines qui ont un besoin quotidien (fixe) de $b_1, \dots, b_m$ pièces, respectivement. On suppose que la quantité totale produite est égale à la quantité totale requise : les manufactures doivent écouler toutes leurs pièces, les usines doivent recevoir toutes leurs pièces.

Chaque manufacture peut livrer à plusieurs usines. La livraison de la i -ème manufacture vers la j -ème usine coûte c_{ij} . On souhaite déterminer le plan de livraison optimal, c'est-à-dire le nombre p_{ij} de pièces que chaque manufacture i doit expédier à chaque usine j de manière à minimiser le coût total des livraisons.

- 1. Quelles sont les variables de ce problème d'optimisation ?
- 2. Exprimer la fonction objectif du problème en fonction de l'ensemble des coûts c_{ij}
- 3. Quelles sont les contraintes du problème ? Ecrire le problème d'optimisation final.


Exercice 1.3 Calcul vectoriel

Pour chacune des fonctions suivantes, calculer le gradient et la Hessienne :


1. $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = x_1^3 - 2x_2^2 + 6x_1 - 24$.
2. $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, $f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$.
3. $f : \mathbb{R}^3 \rightarrow \mathbb{R}$, $f(x) = x^\top Qx + b^\top x$, où $Q \in \mathbb{R}^{3 \times 3}$ et $b \in \mathbb{R}^3$.

Exercice 1.4 Convexité


1. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction. Donner la définition de la convexité de f . Expliquer pourquoi la convexité est une propriété intéressante en optimisation numérique.
2. Montrer que la fonction $x \mapsto \|Ax\|^2$, où $x \in \mathbb{R}^3$ et $A \in \mathbb{R}^{3 \times 3}$, est convexe.
3. Parmi les fonctions univariées suivantes, lesquelles sont convexes ?



(a)




(b)




(c)


4. Parmi les fonctions bivariées suivantes, lesquelles sont convexes ?



(a)



(b)



(c)

TD 2

Moindres carrés linéaires

Exercice 2.1 Formes matricielles

Mettre sous forme matricielle les expressions ou les systèmes suivants :

1. $f(x_1, x_2) = 2x_1^2 + 4x_1x_2 + x_2^2 + x_1 + 2x_2$
2. $f(x_1, x_2, x_3) = x_1 + x_2^2 + x_3$
3. $\begin{cases} y_1 = 2x_1 + x_3 + 1 \\ y_2 = x_1 + x_2 + 2x_3 \end{cases}$

Exercice 2.2 Régression polynomiale

On observe des échantillons $\{y_1, \dots, y_m\}$ d'un signal, pris aux instants $\{t_1, \dots, t_m\} \subset \mathbb{R}$. Etant donné un degré $n \in \mathbb{N}$, on cherche un polynôme $p(t) = p_nt^n + p_{n-1}t^{n-1} + \dots + p_1t + p_0$ de degré au plus n tel que $p(t_i) \simeq y_i$ au sens des moindres carrés.

1. Ecrire le problème des moindres carrés linéaires par rapport au vecteur des coefficients $(p_0, \dots, p_n) \in \mathbb{R}^{n+1}$.
2. On souhaite maintenant aussi pénaliser la norme euclidienne du vecteur des coefficients du polynôme. Ecrire le problème des moindres carrés régularisé correspondant.

Exercice 2.3 Estimateur des moindres carrés

Soient x_1 et x_2 deux variables inconnues. On effectue trois mesures y_1, y_2 et y_3 reliées aux inconnues par le modèle suivant

$$\begin{cases} y_1 = 2x_1 + 3x_2 + b_1 \\ y_2 = 3x_2 + b_2 \\ y_3 = x_1 + b_3 \end{cases} \quad (2.1)$$

où $b = [b_1, b_2, b_3]^\top$ est un vecteur inconnu modélisant l'erreur (dûe à du bruit de mesure, à des erreurs de modèle, etc...)

1. Mettre le modèle (2.1) sous la forme générale $y = Ax + b$, en explicitant et nommant les quantités y , A et x .
2. Afin d'estimer x à partir de y , on cherche à présent à minimiser la norme euclidienne du vecteur d'erreur b . En déduire le problème d'optimisation correspondant, en fonction de y , A et x .
3. En détaillant les calculs, écrire le problème d'optimisation sous la forme standard

$$\min \frac{1}{2} x^\top Q x + p^\top x$$

où l'on donnera l'expression de la matrice Q et du vecteur p en fonction de A et y .

4. Calculer le gradient de la fonction objectif en fonction de Q et p .
5. Donner l'expression matricielle du minimiseur (global) du problème en fonction de Q et p , puis en fonction de A et y .

TD 3

Méthodes itératives

Exercice 3.1 Méthode de descente de gradient

1. On considère la fonction objectif $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ suivante

$$f(x) = \frac{1}{2}x^\top Qx \quad \text{avec} \quad Q = \begin{bmatrix} 1 & 0 \\ 0 & \gamma \end{bmatrix}, \quad \gamma > 0$$

- (a) Calculer $\nabla f(x)$
 - (b) On cherche à minimiser f par une stratégie de descente de gradient. Donner l'expression d'une itération k de cet algorithme en fonction du pas $\alpha^{(k)}$.
 - (c) Donner l'expression de $x^{(1)}$ en fonction de α_0 pour $x^{(0)} = [\gamma, 1]^\top$.
 - (d) Trouver le pas optimal pour cette itération.
2. Les figures ci-dessous montrent les résultats d'algorithmes de descente de gradient appliqués à la fonction f .
- (a) La figure 3.1a présente l'évolution de la distance $\|x^{(k)} - x^*\|_2^2$ où x^* est le minimiseur global de f pour trois stratégies de choix de pas : pas constant et pas optimal. Associer chaque courbe à la stratégie correspondante. Justifier votre réponse.
 - (b) La figure 3.1b présente la valeur de la fonction f au cours des itérations, dans une stratégie de pas fixe, pour différentes valeurs de pas. Commenter la figure et en déduire des recommandations pour le choix du pas de descente. Que se passe-t-il si l'on choisit un pas fixe $\alpha = 1$?




FIGURE 3.1 – Evolution de : (a) $\|x^{(k)} - x^*\|_2^2$; (b) la fonction objectif f , en fonction des itérations.

Exercice 3.2 Méthode de Newton

On considère la fonction $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ définie par

$$f(x) = \frac{1}{2}x^\top Qx - b^\top x, \quad \text{avec } Q \succ 0$$

1. Calculer $\nabla f(x)$ et en déduire son minimiseur.
2. Calculer $\nabla^2 f(x)$.
3. Exprimer $x^{(k+1)}$ en fonction de $x^{(k)}$ pour une itération de Newton à pas constant. Qu'en déduit-on ?

TD 4

Décomposition en valeurs singulières

Exercice 4.1 Calcul de la SVD

1. Les décompositions suivantes sont-elles des décompositions en valeurs singulières ? Justifier vos réponses.

(a) $\begin{bmatrix} 0 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$

(b) $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$

(c) $\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 4 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$

(d) $\begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 4 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$

Dans la suite on considère la matrice

$$\mathbf{X} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \\ 1 & -1 \end{bmatrix}$$

2. Quel est le rang de $\mathbf{X}$? Justifier.
3. Calculer la matrice $\mathbf{C} = \mathbf{X}\mathbf{X}^\top$.
4. Parmi les vecteurs suivants, lesquels sont des vecteurs propres de $\mathbf{C}$? Indiquer le cas échéant la valeur propre associée (on rappelle que $\mathbf{x}$ est un vecteur propre de $\mathbf{C}$ associé à la valeur propre λ si $\mathbf{x} \neq 0$ et $\mathbf{C}\mathbf{x} = \lambda\mathbf{x}$). Justifier vos réponses.

(a) $\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$ (b) $\begin{bmatrix} 0 \\ 2 \\ 0 \end{bmatrix}$ (c) $\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ (d) $\begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$ (e) $\begin{bmatrix} -1 \\ 1 \\ 2 \end{bmatrix}$

5. En déduire les valeurs singulières de la matrice $\mathbf{X}$. Les vecteurs propres trouvés à la question précédente correspondent-ils à des vecteurs singuliers droits ou gauches de $\mathbf{X}$?
6. En déduire finalement la décomposition en valeurs singulières $\mathbf{U}\Sigma\mathbf{V}^\top$ de $\mathbf{X}$ en utilisant les propriétés suivantes :
- les vecteurs singuliers gauches doivent être normalisés, *i.e.* $\|\mathbf{u}_k\|_2 = 1$;
 - les vecteurs singuliers droits s'obtiennent à partir des valeurs singulières non nulles et des vecteurs singuliers gauches correspondants comme $\mathbf{v}_k = \frac{1}{\sigma_k} \mathbf{X}^\top \mathbf{u}_k$.

Exercice 4.2 Approximation de rang faible

1. On considère dans cette question la matrice $\mathbf{A}$ définie par

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 1 \\ -1 & 1 & -1 \\ 1 & -1 & -2 \end{bmatrix}.$$

- Calculer la matrice $\mathbf{B} = \mathbf{A}^\top \mathbf{A}$.
 - Quel est le rang de $\mathbf{B}$? En déduire une valeur propre et un vecteur propre de $\mathbf{B}$ (on rappelle qu'un couple valeur/vecteur propre est un couple $(\lambda, \mathbf{v})$ tel que $\mathbf{v} \neq 0$ et $\mathbf{B}\mathbf{v} = \lambda\mathbf{v}$).
 - Quel est le rang de $\mathbf{B} - 6\mathbf{I}_3$? Trouver deux vecteurs $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^3$ non colinéaires (et non nuls) tels que $\mathbf{B}\mathbf{v}_1 = 6\mathbf{v}_1$ et $\mathbf{B}\mathbf{v}_2 = 6\mathbf{v}_2$.
 - Trouver les valeurs singulières de $\mathbf{A}$, ainsi que les vecteurs singuliers droits associés.
2. Soit $\mathbf{X} \in \mathbb{R}^{m \times n}$, pour $m, n \in \mathbb{N}$ donnés. On note

$$\mathbf{X} = \mathbf{U} \operatorname{diag}(\sigma_1, \dots, \sigma_r, 0, \dots, 0) \mathbf{V}^\top$$

la décomposition en valeurs singulières de $\mathbf{X}$, avec $\sigma_1 \geq \dots \geq \sigma_r > 0$. Montrer que

$$\|\mathbf{X}\|_F = \sqrt{\sum_{j=1}^r \sigma_j^2}$$

où $\|\mathbf{X}\|_F = \sqrt{\operatorname{Tr}(\mathbf{X}^\top \mathbf{X})}$ est la norme de Frobenius.

3. En déduire la valeur de

$$\|\mathbf{X} - \mathbf{X}_s\|_F^2$$

lorsque $\mathbf{X}_s = \mathbf{U}_s \operatorname{diag}(\sigma_1, \dots, \sigma_s) \mathbf{V}_s^\top$, où $\mathbf{U}_s$ et $\mathbf{V}_s$ sont les troncatures de $\mathbf{U}$ et $\mathbf{V}$ à s colonnes.

Solution

1. On a

$$\mathbf{B} = \begin{bmatrix} 3 & -3 & 0 \\ -3 & 3 & 0 \\ 0 & 0 & 6 \end{bmatrix}$$

2. (a) $\mathbf{B}$ est de rang 2 : si l'on regarde par exemple ses colonnes, la dernière colonne est très clairement orthogonale à toutes les autres, et les deux premières sont colinéaires. L'ensemble des colonnes engendrent donc un espace de dimension 2. $\mathbf{B}$ étant de taille 3, elle n'est donc pas de rang plein, et donc n'est pas inversible. Autrement dit, il existe un vecteur *non nul* $\mathbf{v}$ tel que $\mathbf{B}\mathbf{v} = 0$. Par conséquent, 0 est une valeur propre de $\mathbf{B}$. Un vecteur propre associée est par exemple $\mathbf{v} = \begin{bmatrix} 1 & 1 & 0 \end{bmatrix}^\top$, puisque

$$\mathbf{B}\mathbf{v} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

- (b) On a

$$\mathbf{B} - 6\mathbf{I}_3 = \begin{bmatrix} -3 & -3 & 0 \\ -3 & -3 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

qui est de rang 1. Un premier vecteur dans le noyau de cette matrice est

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

et un deuxième, non colinéaire, est

$$\mathbf{v}_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Il s'agit donc de deux vecteurs propres associés à la valeur propre 6.

- (c) On sait que les valeurs singulières sont les racines (positives) des valeurs propres de $A^\top A$: ici, on a donc, dans l'ordre décroissant

$$\sigma_1 = \sigma_2 = \sqrt{6}, \quad \sigma_3 = 0$$

associée respectivement aux vecteurs singuliers droits $\mathbf{v}_1, \mathbf{v}_2$ définis précédemment, et $\mathbf{v}_3 = [1 \ 1 \ 0]^\top$.

3. Notons Σ la matrice diagonale des valeurs singulières. On a, par orthonormalité de $\mathbf{U}$ et $\mathbf{V}$,

$$\begin{aligned} \text{Tr}(\mathbf{X}^\top \mathbf{X}) &= \text{Tr}(\mathbf{V} \Sigma^\top \Sigma \mathbf{V}^\top) \\ &= \text{Tr}(\Sigma^\top \Sigma) \\ &= \sum_{j=1}^r \sigma_j^2 \end{aligned}$$

puisque les valeurs singulières au-delà de r sont nulles.

4. On a

$$\begin{aligned} \mathbf{X} - \mathbf{X}_s &= \mathbf{U} \Sigma \mathbf{V}^\top - \mathbf{U}_s \Sigma_s \mathbf{V}_s^\top = [\mathbf{U}_s \ \star] \begin{bmatrix} \Sigma_s & 0 \\ 0 & \Sigma_{r-s} \end{bmatrix} [\mathbf{V}_s \ \star]^\top - \mathbf{U}_s \Sigma_s \mathbf{V}_s^\top \\ &= [\mathbf{U}_s \ \star] \begin{bmatrix} \Sigma_s & 0 \\ 0 & \Sigma_{r-s} \end{bmatrix} [\mathbf{V}_s \ \star]^\top - [\mathbf{U}_s \ \star] \begin{bmatrix} \Sigma_s & 0 \\ 0 & 0 \end{bmatrix} [\mathbf{V}_s \ \star]^\top \\ &= \mathbf{U} \begin{bmatrix} 0 & 0 \\ 0 & \Sigma_{r-s} \end{bmatrix} \mathbf{V}^\top \end{aligned}$$

où $\Sigma_{r-s} = \text{diag}(\sigma_{s+1}, \dots, \sigma_r, 0, \dots)$. On en déduit, par un raisonnement similaire à la question précédente :

$$\|X - X_s\|_F = \sqrt{\sum_{j=s+1}^r \sigma_j^2}.$$

TD 5

Tenseurs

Exercice 5.1 Manipulations de tenseurs

1. On considère le tenseur suivant :

$$\mathcal{X}_{:, :, 1} = \begin{bmatrix} 1 & -1 & 0 \\ 2 & 0 & 1 \\ 1 & 2 & 3 \end{bmatrix}, \quad \mathcal{X}_{:, :, 2} = \begin{bmatrix} -1 & -1 & 1 \\ 0 & 0 & 2 \\ 3 & 2 & 1 \end{bmatrix}.$$

- (a) Quel est l'ordre de ce tenseur ? Quelles sont ses dimensions ?
 (b) Expliciter les fibres suivantes : $\mathcal{X}_{:, 2, 1}$, $\mathcal{X}_{3, :, 2}$, $\mathcal{X}_{1, 2, :}$.
 (c) Expliciter les tranches suivantes : $\mathcal{X}_{:, 2, :}$, $\mathcal{X}_{3, :, :}$.
2. On considère le tenseur suivant :

$$\mathcal{Y}_{:, :, 1, 1} = \begin{bmatrix} 1 & -3 \\ 0 & 1 \end{bmatrix}, \quad \mathcal{Y}_{:, :, 1, 2} = \begin{bmatrix} 0 & -1 \\ 2 & -2 \end{bmatrix}, \quad \mathcal{Y}_{:, :, 2, 1} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix},$$

$$\mathcal{Y}_{:, :, 2, 2} = \begin{bmatrix} 1 & -1 \\ 1 & 2 \end{bmatrix}, \quad \mathcal{Y}_{:, :, 3, 1} = \begin{bmatrix} 0 & 0 \\ -1 & 0 \end{bmatrix}, \quad \mathcal{Y}_{:, :, 3, 2} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

- (a) Quel est l'ordre de ce tenseur ? Quelles sont ses dimensions ?
 (b) Expliciter les fibres suivantes : $\mathcal{X}_{:, 2, 3, 1}$, $\mathcal{X}_{1, :, 2, 2}$, $\mathcal{X}_{2, 2, :, 1}$, $\mathcal{X}_{1, 2, 3, :}$.
 (c) Expliciter les tranches suivantes : $\mathcal{X}_{1, :, :, 2}$, $\mathcal{X}_{:, 2, :, 2}$, $\mathcal{X}_{:, 1, 3, :}$, $\mathcal{X}_{2, :, 2, :}$.
3. Etant donné le tenseur $\mathcal{X}$ ci-dessus, déterminer le tenseur $\mathcal{Z}$ tel que

$$\mathcal{Z}_{ijk} = \mathcal{X}_{ikj}.$$

On donnera la solution en explicitant les tranches frontales de $\mathcal{Z}$.

Exercice 5.2 Calculs tensoriels

On donne :

$$\mathbf{a} = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{c} = [1 \quad -1], \quad \mathbf{M} = \begin{bmatrix} 1 & 1 \\ 0 & -1 \\ 2 & 0 \\ 3 & 1 \end{bmatrix}$$

1. Calculer les produits tensoriels suivants : $\mathbf{a} \circ \mathbf{b}$, $\mathbf{a} \circ \mathbf{c}$, $\mathbf{a} \circ \mathbf{b} \circ \mathbf{c}$.
 2. Calculer les produits de Kronecker $\mathbf{c} \otimes \mathbf{M}$ et $\mathbf{M} \otimes \mathbf{c}$.
 3. Calculer le produit 3-mode $(\mathbf{a} \circ \mathbf{b} \circ \mathbf{c}) \times_3 \mathbf{M}$

TD 6

Classification

Exercice 6.1 Marge d'un hyperplan

On considère des données labellisées linéairement séparables (x_i, y_i) , $y_i \in \{1, -1\}$, et un hyperplan séparateur H d'équation $a^\top x + b = 0$, où $a \in \mathbb{R}^n$ et $b \in \mathbb{R}$. On supposera que x_1 et x_2 sont des vecteurs de support pour chacune des classes, c'est-à-dire tels que

$$a^\top x_1 + b = 1 \quad \text{et} \quad a^\top x_2 + b = -1.$$

1. Montrer que a est un vecteur normal à H , i.e. pour tout $x, y \in H$, $a^\top(x - y) = 0$.
2. Montrer que pour tout point $x \in \mathbb{R}^n$,

$$d(x, H) = \frac{|a^\top x + b|}{\|a\|}$$

3. En déduire l'expression de la marge de H en fonction de a .

Solution.

1. On a $a^\top(x - y) = a^\top x + b - (a^\top y + b) = 0 + 0 = 0$ car x et y appartiennent à l'hyperplan.
2. Pour tout point p de l'hyperplan H , on a

$$d(x, H) = \frac{|a^\top(x - p)|}{\|a\|} = \frac{|a^\top x + b - (a^\top p + b)|}{\|a\|} = \frac{|a^\top x + b|}{\|a\|}$$

3. La marge est donnée par $d(x_1, H) + d(x_2, H) = \frac{1}{\|a\|} + \frac{1}{\|a\|} = \frac{2}{\|a\|}$.

Exercice 6.2 Astuce du noyau

On considère un jeu de 8 données labellisées $(\mathbf{x}^{(i)}, y^{(i)})$, avec $\mathbf{x}^{(i)} \in \mathbb{R}^2$ et $y^{(i)} \in \{-1, +1\}$, pour $i = 1, \dots, 8$. Ces données sont représentées en Figure 6.1. On cherche à classer automatiquement ces données à l'aide de la méthode des machines à vecteurs de support (SVM).

1. On rappelle qu'une SVM classique consiste à résoudre le problème d'optimisation

$$\min_{\mathbf{a} \in \mathbb{R}^2, b \in \mathbb{R}} \quad \frac{1}{2} \|\mathbf{a}\|^2 \quad \text{s.c.} \quad y^{(i)}(\mathbf{a}^\top \mathbf{x}^{(i)} + b) \geq 1 \quad i = 1, \dots, 8 \quad (6.1)$$

- (a) Que représentent les contraintes du problème ?
 - (b) Que représente la fonction objectif ?
2. Expliquer pourquoi résoudre le problème (6.1) pour les données considérées ici ne permettra pas d'identifier les deux classes.

3. Expliquer le principe de l'astuce du noyau.
4. On applique aux données une transformation $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}^2$. Le résultat est montré en Figure 6.2. Parmi les quatre transformations φ proposées ci-dessous, laquelle conduit au résultat observé ?

$$(a) \varphi(\mathbf{x}) = \begin{bmatrix} x_1 & x_1^2 + x_2^2 \end{bmatrix} \quad (b) \varphi(\mathbf{x}) = \begin{bmatrix} x_1 & x_1 + 2x_2 \end{bmatrix}$$

$$(c) \varphi(\mathbf{x}) = \begin{bmatrix} x_2 & x_1^2 - x_2^2 \end{bmatrix} \quad (d) \varphi(\mathbf{x}) = \begin{bmatrix} x_2 & x_1^2 \end{bmatrix}$$

Indiquer sur la Figure 6.2 à côté de chaque point la donnée initiale correspondante.

5. Représenter l'hyperplan séparateur optimal sur la Figure 6.2. Donner son équation, et déterminer sa marge. Quels sont les vecteurs de support ?
6. On considère une nouvelle donnée $\mathbf{x}^{(9)} = (-1, -\sqrt{2})$ et $y^{(9)} = -1$. Représenter cette nouvelle donnée sur la Figure 6.1 (on donne $\sqrt{2} \simeq 1.414$). Cette donnée sera-t-elle correctement classifiée par la SVM à noyau appris sur le jeu de données initial ? Justifier votre réponse.




FIGURE 6.1 – Jeu de données (rouge : -1, cyan : +1)

Exercice 6.3 Lagrangien

Soit $(x_i, y_i) \in \mathbb{R}^n \times \{1, -1\}$, $i = 1, \dots, p$, des données labellisées. Une SVM à marge souple consiste à résoudre le problème d'optimisation

$$\min_{\substack{a \in \mathbb{R}^n \\ b \in \mathbb{R} \\ \xi \in \mathbb{R}^p}} \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i \quad \text{s.c.} \quad \xi_i \geq 0, \quad y_i(a^\top x_i + b) \geq 1 - \xi_i \quad i = 1, \dots, p,$$

pour un α donné.

1. Que représente les variables ξ_i ?
2. Ecrire le Lagrangien $\mathcal{L}$ de ce problème.




FIGURE 6.2 – Données après transformation

3. Calculer les gradients par rapport à a , b et ξ de $\mathcal{L}$. Quelle condition doivent-ils satisfaire à l'optimum ?

Solution.

1. ξ_i représente l'écart de la donnée x_i du mauvais côté de la marge. Dans les SVM à marge souple, ces écarts sont autorisés mais pénalisés (par le terme $\sum \xi_i$ dans l'optimisation).
2. Mis sous forme standard, le problème devient

$$\min \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i \quad \text{s.c.} \quad -\xi_i \leq 0, \quad 1 - \xi_i - y_i(a^\top x_i + b) \leq 0$$

On a $2p$ contraintes d'inégalités : les contraintes de positivité des ξ_i et les contraintes de marge. On note respectivement μ_i et λ_i ($i = 1, \dots, p$) les multiplicateurs de Lagrange associés à ces contraintes. Le Lagrangien du problème est alors donné par

$$\mathcal{L}(a, b, \lambda, \mu) = \frac{1}{2} \|a\|^2 + \alpha \sum \xi_i - \sum \mu_i \xi_i + \sum \lambda_i (1 - \xi_i - y_i(a^\top x_i + b))$$

3. On a

$$\nabla_a \mathcal{L}(a, b, \xi, \lambda, \mu) = a - \sum \lambda_i y_i x_i$$

$$\nabla_b \mathcal{L}(a, b, \xi, \lambda, \mu) = - \sum \lambda_i y_i$$

$$\nabla_{\xi} \mathcal{L}(a, b, \xi, \lambda, \mu) = \alpha - \mu - \lambda$$

A l'optimum, tous ces gradients doivent être nuls. En particulier, cela implique que

$$a = \sum \lambda_i y_i x_i, \quad \sum \lambda_i y_i = 0, \quad \mu + \lambda = \alpha$$

(comme μ et λ doivent être positives, la dernière contrainte impliquera en particulier que $0 \leq \lambda_i \leq \alpha$ pour tout i).

Exercice 6.4 Perceptron

On considère le réseau à deux couches représenté en Figure 6.3, où l'on a explicitement représenté la fonction non-linéaire σ et les biais b_1, b_2 :




FIGURE 6.3 – Réseau de neurones

1. Exprimer les sorties intermédiaires z_1 et z_2 en fonction de l'entrée $\mathbf{x} = [x_1 \ x_2 \ x_3]^\top$, des vecteurs de poids $\mathbf{w}_1 = [w_{11} \ w_{12} \ w_{13}]^\top$, $\mathbf{w}_2 = [w_{21} \ w_{22} \ w_{23}]^\top$, et des biais b_1, b_2 .
2. Exprimer de même la sortie finale y en fonction de $\mathbf{x}$ et des différents paramètres du réseau.