

Annale 2022: corrigé

Paul Catala

1 Optimisation numérique

1.1 Méthode de Newton-Raphson

1. On considère la fonction objectif $J(x, y) = \frac{1}{2}x^2 + \frac{9}{2}y^2 - x - 18y + 20$.

Le gradient ∇J de J au point (x, y) est défini comme le vecteur

$$\nabla J(x, y) = \begin{bmatrix} \partial_1 J(x, y) \\ \partial_2 J(x, y) \end{bmatrix}.$$

où $\partial_1 J$ et $\partial_2 J$ sont les dérivées partielles de J par rapport à x et y respectivement.

La dérivation par rapport à x donne $\partial_1 J(x, y) = x - 1$.

La dérivation par rapport à y donne $\partial_2 J(x, y) = 9y - 18$.

Le gradient du critère est donc finalement

$$\nabla J(x, y) = \begin{bmatrix} x - 1 \\ 9y - 18 \end{bmatrix}.$$

2. La matrice hessienne $\nabla^2 J$ de J en (x, y) est définie comme

$$\nabla^2 J(x, y) = \begin{bmatrix} \partial_{11} J(x, y) & \partial_{12} J(x, y) \\ \partial_{21} J(x, y) & \partial_{22} J(x, y) \end{bmatrix}.$$

Les dérivées partielles secondes $\partial_{11} J$ et $\partial_{12} J$ s'obtiennent en dérivant $\partial_1 J$ par rapport à x et y respectivement; les dérivées partielles secondes $\partial_{21} J$ et $\partial_{22} J$ s'obtiennent de même à partir de $\partial_2 J$.

La matrice hessienne est donc finalement

$$\nabla^2 J(x, y) = \begin{bmatrix} 1 & 0 \\ 0 & 9 \end{bmatrix}.$$

3. Une itération de l'algorithme de Newton à partir d'un point (x_0, y_0) fournit un nouveau point (x_1, y_1) défini par la règle de mise à jour suivante

$$\begin{bmatrix} x_1 \\ y_1 \end{bmatrix} = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} - \alpha \nabla^2 J(x_0, y_0)^{-1} \nabla J(x_0, y_0)$$

où $\alpha > 0$ est un pas à choisir. Ici $\nabla^2 J(x_0, y_0)$ est une matrice diagonale avec des entrées strictement positives, elle est donc bien inversible (déterminant non nul), et son inverse est simplement donné par

$$\nabla J^2(x_0, y_0)^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{9} \end{bmatrix}.$$

En utilisant les formules trouvées aux question précédentes, on obtient donc

$$\begin{bmatrix} x_1 \\ y_1 \end{bmatrix} = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} - \alpha \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{9} \end{bmatrix} \begin{bmatrix} x - 1 \\ 9y - 18 \end{bmatrix} = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} - \alpha \begin{bmatrix} x_0 - 1 \\ y_0 - 2 \end{bmatrix},$$

soit, coordonnée par coordonnée

$$\begin{cases} x_1 = (1 - \alpha)x_0 + \alpha \\ y_1 = (1 - \alpha)y_0 + 2\alpha \end{cases}$$

4. La fonction J est (strictement) convexe car sa Hessienne est définie positive (valeurs propres strictement positives). Elle admet donc un unique minimiseur, qui satisfait la condition d'optimalité de premier ordre

$$\nabla J(x_*, y_*) = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

c'est-à-dire

$$\begin{cases} x_* - 1 = 0 \\ 9y_* - 18 = 0 \end{cases} \iff \begin{cases} x_* = 1 \\ y_* = 2 \end{cases}.$$

On remarque que ce minimiseur est atteint en une seule itération lorsque le pas α est choisi égal à 1.

5. La valeur du critère au minimum est

$$J(1, 2) = \frac{1}{2} + 4\frac{9}{2} - 1 - 36 + 20 = \frac{3}{2}.$$

1.2 Formulation d'un problème d'optimisation

1. Les variables du problèmes sont les dimension x, y et z du parallélépipède. Le critère à minimiser est la surface $S(x, y, z) = 2(xy + yz + xz)$ du parallélépipède, et les contraintes sont celles du volume fixe $V = xyz = 1$ et de positivité des dimensions. On obtient donc le problème suivant

$$\min 2(xy + xz + yz) \quad \text{s.c.} \quad \begin{cases} x > 0 \\ y > 0 \\ z > 0 \\ xyz = 1 \end{cases}.$$


2. La contrainte de volume fixe impose $z = \frac{1}{xy}$ (valable car $xy > 0$). En réinjectant, on obtient le problème à deux variables suivant

$$\min 2(xy + \frac{1}{y} + \frac{1}{x}) \quad \text{s.c.} \quad \begin{cases} x > 0 \\ y > 0 \end{cases}.$$

2 Classification

2.1 SVM à noyau

1. Le jeu de données est le suivant:




2. La séparabilité linéaire signifie ici que les deux classes sont de par et d'autre d'un point. Ce n'est pas le cas ici: les deux classes ne sont pas linéairement séparables.
3. L'hyperplan suivant conduit à une erreur de classification, ce qui est bien le nombre minimal d'erreurs:




4. (a) On a

$$Z = \Phi(X) = \begin{bmatrix} X & X \odot X \end{bmatrix} = \begin{bmatrix} -2 & 4 \\ -1 & 1 \\ 0 & 0 \\ 1 & 1 \\ 2 & 4 \end{bmatrix}.$$


- (b) Graphiquement:



- (c) Les données sont bien linéairement séparables. Un hyperplan séparateur séparera les segments formés par les données $[x_1, x_4]$ et $[x_2, x_3]$. On vérifie graphiquement que ces segments sont parallèles, et que l'hyperplan séparateur à marge maximale est la droite parallèle à ces segments passant par le point de coordonnées $(0,1)$. La marge est la distance entre les points x_3 et x_4 , c'est-à-dire $\sqrt{2}$.
- (d) Il y a quatre vecteurs de support: x_1 et x_4 (pour la classe 1) et x_2 et x_3 (pour la classe -1). Ce sont toutes les données situées à la distance minimale de l'hyperplan.



- (e) Si l'on retire la donnée x_4 , qui est l'un des vecteurs de support, l'hyperplan séparateur change. Le nouvel hyperplan séparateur est parallèle à l'axe des abscisses et passe par $(0,2.5)$, comme montré sur la figure ci-dessous. Les vecteurs x_1 , x_2 et x_3 sont les nouveaux vecteurs de support. La nouvelle marge est 1.5.



3 Décompositions matricielles

3.1 Valeurs propres et valeurs singulières

1. On note $X = U\Sigma V^\top$ la décomposition en valeurs singulières de X , où U et V sont orthonormales et $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ est positive. On a donc $C = XX^\top = U\Sigma^2U^\top$ par orthonormalité de V .

- (a) oui: la décomposition $U\Sigma^2U^\top$ est à la fois une décomposition en valeurs propres ($U^{-1} = U^\top$) et en valeurs singulières.
 - (b) non: les valeurs propres de C sont σ_i^2 , les valeurs singulières de X σ_i .
 - (c) oui.
2. $C = U\Sigma^2U^\top$ est une décomposition en valeurs propres, les vecteurs propres de C sont donc les colonnes de U ($CU = U\Sigma^2$). Par conséquent
- (a) oui
 - (b) non: la décomposition en valeurs propres n'est pas définie pour une matrice rectangulaire
 - (c) non: : les vecteurs singuliers droits sont les colonnes de V . Dans le cas général, $U \neq V$.

3.2 La SVD

1. On a

$$C = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 4 \end{bmatrix}.$$

2. De par la décomposition $C = XX^\top$ avec $X \in \mathbb{R}^{3 \times 2}$, C est au plus de rang 2. Elle est en fait de rang 2 car X est de rang 2.
3. On vérifie pour chaque vecteur v (non nul) s'il existe un réel λ tel que $Cv = \lambda v$.
- (a) non
 - (b) non
 - (c) oui, avec $\lambda = 7$
 - (d) oui, avec $\lambda = 3$
 - (e) non
 - (f) oui, avec $\lambda = 0$.
4. Les valeurs propres associées sont donc 7,3 et 0, et elles sont toutes positives.
5. On a vu que le carré des valeurs propres de C étaient les valeurs singulières de X au carré. Les valeurs singulières de X sont donc $+\sqrt{7}$, $+\sqrt{3}$ et 0 (car les valeurs singulières sont toujours positives).
6. On a vu que les vecteurs propres de C étaient les vecteurs singuliers à gauche de X . On sait donc que

$$u = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix},$$

est un vecteur singulier gauche associé à la plus grande valeur singulière $\sqrt{7}$. Comme indiqué, on trouve u_1 en normalisant u :

$$u_1 = \frac{1}{\sqrt{14}} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}.$$

On détermine v_1 à l'aide de la deuxième indication indications:

$$v_1 = \frac{1}{\sqrt{7}} \frac{1}{\sqrt{14}} \begin{bmatrix} 0 & 1 & 2 \\ 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} = \frac{1}{7\sqrt{2}} \begin{bmatrix} 7 \\ 7 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

On en déduit finalement

$$X_1 = \sqrt{7} \frac{1}{\sqrt{14}} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 3 & 3 \\ 2 & 2 \end{bmatrix}.$$

7. On a

$$\|X - X_1\|_F^2 = \left\| \begin{bmatrix} -0.5 & 0.5 \\ -0.5 & 0.5 \\ 1 & -1 \end{bmatrix} \right\|_F^2 = 4 \cdot \frac{1}{2^2} + 2 = 3.$$

NB: On retrouve $\|X - X_1\|_F = \sqrt{3} = \sqrt{\sigma_2^2 + \sigma_3^2}$.