

Annale 2024: corrigé

Paul Catala

1 Optimisation numérique

1.1 Questions de cours

1. (a) Les variables du problème sont x_1 et x_2
(b) La fonction objectif du problème est $f(x_1, x_2) = (x_1 - 3)^2 + (x_2 + 2)^2$
(c) Le problème a deux contraintes: une contrainte d'égalité $3x_2^2 - x_1 = 0$, et une contrainte d'inégalité $x_1 + x_2 \leq 2$
(d) La contrainte d'égalité peut se reformuler $x_1 = 3x_2^2$, et donne l'expression de x_1 en fonction de x_2 . On peut donc reformuler le problème en fonction de x_2 uniquement. En réinjectant dans le problème $(\mathcal{P})$, on obtient le nouveau critère

$$\begin{aligned} g(x_2) &= (3x_2^2 - 3)^2 + (x_2 + 2)^2 = 9x_2^4 - 18x_2^2 + 9 + x_2^2 + 2x_2 + 2 \\ &= 9x_2^4 - 17x_2^2 + 2x_2 + 11 \end{aligned}$$

et la nouvelle contrainte

$$3x_2^2 + x_2 \leq 2$$

Le problème est donc équivalent au nouveau problème

$$\min_x 9x^4 - 17x^2 + 2x + 11 \quad \text{tel que} \quad x(3x + 1) \leq 2 \quad (\mathcal{P}')$$

2. (a) Les variables sont x_1, x_2 , la fonction objectif est $f(x_1, x_2) = 100(x_2 - x_1^2) + (1 - x_1)^2$, et il n'y a pas de contraintes.
(b) Soit $\mathbf{x}^* := (x_1^*, x_2^*) \in \mathbb{R}^2$. Une condition nécessaire pour que $\mathbf{x}^*$ soit un minimiseur local est que le gradient de f en $\mathbf{x}^*$ soit nul (si f est de plus convexe, alors $\mathbf{x}^*$ est en fait un minimiseur global).
(c) Calculons le gradient de f . On a

$$f(x_1, x_2) = 100x_2^2 - 200x_1^2x_2 + 100x_1^4 + x_1^2 - 2x_1 + 1,$$

donc

$$\nabla f(x_1, x_2) = \begin{bmatrix} \partial_1 f(x_1, x_2) \\ \partial_2 f(x_1, x_2) \end{bmatrix} = \begin{bmatrix} -400x_1x_2 + 400x_1^3 + 2x_1 - 2 \\ 200x_2 - 400x_1^2 \end{bmatrix}.$$

En particulier,

$$\nabla f(0,0) = \begin{bmatrix} -2 \\ 0 \end{bmatrix} \neq \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

donc $[0,0]^\top$ n'est pas un minimiseur local du problème.

3. (a) Une fonction f est convexe si et seulement si

$$\forall x, y, \quad \forall t \in [0, 1], \quad f(tx + (1-t)y) \leq tf(x) + (1-t)f(y).$$

Autrement dit, toute corde prise entre deux points du graphe de f est au-dessus du graphe de f .

- (b) La fonction (a) est convexe, mais pas strictement convexe: entre -1 et 1 , toute corde est confondu avec le graphe de la fonction (il y a égalité dans la définition précédente).

La fonction (b) est (strictement) convexe.

La fonction (c) n'est pas convexe.

La fonction (d) est (strictement) convexe.

- (c) La convexité est une propriété intéressante en optimisation, car pour une fonction convexe, tout minimiseur local est en fait un minimiseur global (autrement dit, il n'y a que des minima globaux). On a donc de meilleures garanties de trouver le minimum global dans ce cas.

1.2 Moindres carrés linéaires

1. Le système (1) peut s'écrire sous forme matricielle comme

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$$

où

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} 2 & 3 \\ 0 & 3 \\ 1 & 0 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}.$$

$\mathbf{y}$ est le vecteur d'observations, $\mathbf{x}$ est le vecteur d'inconnues, et $\mathbf{A}$ est la matrice de design.

2. Puisque $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$, on a donc $\|\mathbf{b}\|_2 = \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2$. Le problème d'optimisation que l'on cherche à résoudre est donc

$$\min_{\mathbf{x} \in \mathbb{R}^3} \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2.$$

En pratique on minimise plutôt la norme euclidienne au carré (ce qui est équivalent)

$$\min_{\mathbf{x} \in \mathbb{R}^3} \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{y}\|_2^2.$$

Ce problème s'appelle les moindres carrés linéaires.

3. On a

$$\begin{aligned}\frac{1}{2}\|\mathbf{Ax} - \mathbf{y}\|_2^2 &= \frac{1}{2}(\mathbf{Ax} - \mathbf{y})^\top (\mathbf{Ax} - \mathbf{y}) = \frac{1}{2}\mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} - \mathbf{y}^\top \mathbf{Ax} + \frac{1}{2}\mathbf{y}^\top \mathbf{y} \\ &= \frac{1}{2}\mathbf{x}^\top \mathbf{Qx} + \mathbf{p}^\top \mathbf{x} + \mathbf{y}^\top \mathbf{y}\end{aligned}$$

où $\mathbf{Q} = \mathbf{A}^\top \mathbf{A}$ et $\mathbf{p} = -\mathbf{A}^\top \mathbf{y}$. En pratique le terme constant $\mathbf{y}^\top \mathbf{y}$ peut être ignoré lors de l'optimisation car il ne change pas le minimiseur. Le problème d'optimisation sous forme standard est donc

$$\min_{\mathbf{x} \in \mathbb{R}^3} \frac{1}{2}\mathbf{x}^\top \mathbf{Qx} + \mathbf{p}^\top \mathbf{x}.$$

4. On appelle f la fonction objectif. On a

$$\nabla f(\mathbf{x}) = \mathbf{Qx} + \mathbf{p}.$$

5. La fonction f est quadratique, donc en particulier convexe, donc tout minimiseur local est global. Une condition nécessaire et donc ici suffisante d'optimalité est que le gradient soit nul. On en déduit que le minimiseur $\mathbf{x}^*$ doit ici satisfaire

$$\mathbf{Qx}^* = -\mathbf{p}.$$

Or

$$\mathbf{Q} = \mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 5 & 6 \\ 6 & 9 \end{bmatrix}$$

est inversible (le déterminant est non nul). On en déduit

$$\mathbf{x}^* = -\mathbf{Q}^{-1}\mathbf{p},$$

soit


$$\mathbf{x}^* = (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top \mathbf{y} = \mathbf{A}^\dagger \mathbf{y}.$$

La matrice $\mathbf{A}^\dagger$ s'appelle la pseudo-inverse de $\mathbf{A}$.

2 Classification

2.1 SVM à noyau

1. Le jeu de données est le suivant:



2. La séparabilité linéaire signifie ici que les deux classes sont de part et d'autre d'un point. Ce n'est pas le cas ici: les deux classes ne sont pas linéairement séparables.


3. L'hyperplan suivant conduit à une erreur de classification, ce qui est bien le nombre minimal d'erreurs:




4. (a) On a

$$Z = \Phi(X) = \begin{bmatrix} X & X \odot X \end{bmatrix} = \begin{bmatrix} -2 & 4 \\ -1 & 1 \\ 0 & 0 \\ 1 & 1 \\ 2 & 4 \end{bmatrix}.$$

(b) Graphiquement:




- (c) Les données sont bien linéairement séparables. Un hyperplan séparateur séparera les segments formés par les données $[x_1, x_4]$ et $[x_2, x_3]$. On vérifie graphiquement que ces segments sont parallèles, et que l'hyperplan séparateur à marge maximale est la droite parallèle à ces segments passant par le point de coordonnées $(0,1)$. La marge est la distance entre les points x_3 et x_4 , c'est-à-dire $\sqrt{2}$.
- (d) Il ya quatre vecteurs de support: x_1 et x_4 (pour la classe 1) et x_2 et x_3 (pour la classe -1). Ce sont toutes les données situées à la distance minimale de l'hyperplan.



- (e) Si l'on retire la donnée x_4 , qui est l'un des vecteurs de support, l'hyperplan séparateur change. Le nouvel hyperplan séparateur est parallèle à l'axe des abscisses et passe par $(0, 2.5)$, comme montré

sur la figure ci-dessous. Les vecteurs x_1 , x_2 et x_3 sont les nouveaux vecteurs de support. La nouvelle marge est 1.5.



3 Décompositions matricielles

3.1 Valeurs propres et valeurs singulières

1. On note $X = U\Sigma V^\top$ la décomposition en valeurs singulières de X , où U et V sont orthonormales et $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_n)$ est positive. On a donc $C = XX^\top = U\Sigma^2U^\top$ par orthonormalité de V .
 - (a) oui: la décomposition $U\Sigma^2U^\top$ est à la fois une décomposition en valeurs propres ($U^{-1} = U^\top$) et en valeurs singulières.
 - (b) non: les valeurs propres de C sont σ_i^2 , les valeurs singulières de X σ_i .
 - (c) oui.
2. $C = U\Sigma^2U^\top$ est une décomposition en valeurs propres, les vecteurs propres de C sont donc les colonnes de U ($CU = U\Sigma^2$). Par conséquent
 - (a) oui
 - (b) non: la décomposition en valeurs propres n'est pas définie pour une matrice rectangulaire
 - (c) non: : les vecteurs singuliers droits sont les colonnes de V . Dans le cas général, $U \neq V$.

3.2 La SVD

1. On a

$$C = \begin{bmatrix} 1 & 2 & 0 \\ 2 & 5 & 2 \\ 0 & 2 & 4 \end{bmatrix}.$$

2. De par la décomposition $C = XX^\top$ avec $X \in \mathbb{R}^{3 \times 2}$, C est au plus de rang 2. Elle est en fait de rang 2 car X est de rang 2.

3. On vérifie pour chaque vecteur v (non nul) s'il existe un réel λ tel que $Cv = \lambda v$.
- (a) non
 - (b) non
 - (c) oui, avec $\lambda = 7$
 - (d) oui, avec $\lambda = 3$
 - (e) non
 - (f) oui, avec $\lambda = 0$.
4. Les valeurs propres associées sont donc 7, 3 et 0, et elles sont toutes positives.
5. On a vu que le carré des valeurs propres de C étaient les valeurs singulières de X au carré. Les valeurs singulières de X sont donc $+\sqrt{7}$, $+\sqrt{3}$ et 0 (car les valeurs singulières sont toujours positives).
6. On a vu que les vecteurs propres de C étaient les vecteurs singuliers à gauche de X . On sait donc que

$$u = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix},$$

est un vecteur singulier gauche associé à la plus grande valeur singulière $\sqrt{7}$. Comme indiqué, on trouve u_1 en normalisant u :

$$u_1 = \frac{1}{\sqrt{14}} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}.$$

On détermine v_1 à l'aide de la deuxième indication:

$$v_1 = \frac{1}{\sqrt{7}} \frac{1}{\sqrt{14}} \begin{bmatrix} 0 & 1 & 2 \\ 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} = \frac{1}{7\sqrt{2}} \begin{bmatrix} 7 \\ 7 \\ 2 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

On en déduit finalement

$$X_1 = \sqrt{7} \frac{1}{\sqrt{14}} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 3 & 3 \\ 2 & 2 \end{bmatrix}.$$

7. On a

$$\|X - X_1\|_F^2 = \left\| \begin{bmatrix} -0.5 & 0.5 \\ -0.5 & 0.5 \\ 1 & -1 \end{bmatrix} \right\|_F^2 = 4 \cdot \frac{1}{2^2} + 2 = 3.$$

NB: On retrouve $\|X - X_1\|_F = \sqrt{3} = \sqrt{\sigma_2^2 + \sigma_3^2}$.