

Examen 2025: corrigé

Paul Catala

1 Question de cours

1. La courbe bleue est celle qui converge le plus rapidement: il s'agit de la solution avec pas optimal. La courbe rouge est celle qui converge le moins rapidement: il s'agit de la solution avec pas constant. La courbe verte restante est la solution avec backtracking.
2. (a) Cette décomposition n'est pas une SVD car la matrice U n'est pas orthogonale: en effet,

$$\begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & 1 \end{bmatrix} = \begin{bmatrix} 1 & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 1 \end{bmatrix} \neq I_2$$

- (b) Cette décomposition est une SVD: on vérifie bien que U et V sont orthogonales, et que S est diagonale avec entrées positives.
 - (c) Cette décomposition n'est pas une SVD car les entrées diagonales de S ne sont pas toutes positives
 - (d) Cette décomposition n'est pas une SVD car ni U ni V ne sont orthogonales.
3. (a) On a $z_1 = w_{11}x_1 + w_{12}x_2 = w_{13}x_3 + b_1 = \mathbf{w}_1^\top \mathbf{x} + b_1$, et de même $y_2 = \mathbf{w}_2^\top \mathbf{x} + b_2$.
 - (b) On a $y = v_1\sigma(z_1) + v_2\sigma(z_2) = v_1\sigma(\mathbf{w}_1^\top \mathbf{x}) + v_2\sigma(\mathbf{w}_2^\top \mathbf{x})$.

2 Optimisation numérique

1. Ce problème admet un minimiseur, car le critère est une fonction convexe de $\mathbf{R}^3$. L'unicité du minimiseur dépend des propriétés de A : ici, la matrice A est de rang 2, et a donc un noyau non réduit à $\{0\}$. Autrement dit, si $\mathbf{x}_0$ est une solution du problème, alors pour tout $\mathbf{z} \in \text{Ker } A$, $\mathbf{x}_0 + \mathbf{z}$ est aussi solution (car $A(\mathbf{x}_0 + \mathbf{z}) = A\mathbf{x}_0$).

2. On a

$$\begin{aligned}
 f(\mathbf{x}) &= \frac{1}{2}(\mathbf{Ax} - \mathbf{y})^\top (\mathbf{Ax} - \mathbf{y}) + \frac{1}{2}\mathbf{x}^\top \mathbf{x} \\
 &= \frac{1}{2}\mathbf{x}^\top \mathbf{A}^\top \mathbf{Ax} - \frac{1}{2}\mathbf{x}^\top \mathbf{A}^\top \mathbf{y} - \frac{1}{2}\mathbf{y}^\top \mathbf{Ax} + \frac{1}{2}\mathbf{y}^\top \mathbf{y} + \frac{1}{2}\mathbf{x}^\top \mathbf{x} \\
 &= \frac{1}{2}\mathbf{x}^\top (\mathbf{A}^\top \mathbf{A} + \mathbf{I})\mathbf{x} - (\mathbf{A}^\top \mathbf{y})^\top \mathbf{x} + \frac{1}{2}\|\mathbf{y}\|^2 \\
 &= \frac{1}{2}\mathbf{x}^\top \mathbf{Px} + \mathbf{q}^\top \mathbf{x} + r.
 \end{aligned}$$

où $\mathbf{P} = \mathbf{A}^\top \mathbf{A} + \mathbf{I}$, $\mathbf{q} = -\mathbf{A}^\top \mathbf{y}$ et $r = 1/2\|\mathbf{y}\|^2$.

3. On a

$$\begin{aligned}
 \frac{\partial}{\partial \mathbf{x}} \left(\frac{1}{2}\mathbf{x}^\top \mathbf{Px} \right) &= \mathbf{Px} \\
 \frac{\partial}{\partial \mathbf{x}} (\mathbf{q}^\top \mathbf{x}) &= \mathbf{q} \\
 \frac{\partial}{\partial \mathbf{x}} r &= 0.
 \end{aligned}$$

Par conséquent, le gradient de f en $\mathbf{x}$ est donné par

$$\nabla f(\mathbf{x}) = \mathbf{Px} + \mathbf{q} = (\mathbf{A}^\top \mathbf{A} + \mathbf{I})\mathbf{x} - \mathbf{A}^\top \mathbf{y}.$$

4. La fonction f est convexe, donc tout minimiseur local est un minimiseur global. Une condition nécessaire et suffisante d'optimalité est donc

$$\nabla f(\mathbf{x}_*) = 0$$

On en déduit

$$(\mathbf{A}^\top \mathbf{A} + \mathbf{I})\mathbf{x}_* = \mathbf{A}^\top \mathbf{y}.$$

Or


$$\mathbf{A}^\top \mathbf{A} + \mathbf{I} = \begin{bmatrix} 4 & -3 & 0 \\ -3 & 4 & 0 \\ 0 & 0 & 7 \end{bmatrix}$$

est inversible (déterminant non nul). On obtient donc

$$\mathbf{x}_* = (\mathbf{A}^\top \mathbf{A} + \mathbf{I})^{-1} \mathbf{A}^\top \mathbf{y}.$$


3 Classification

3.1 Séparateur linéaire



- 1.
2. L'hyperplan optimal est la droite horizontale d'équation $y = 3/2$. La marge est $2 \times 0.5 = 1$.
3. Les vecteurs de support sont les données 1, 3 pour la classe +1, et 6 pour la classe -1.

3.2 Astuce du noyau




4. Les deux classes ne sont pas linéairement séparables.

5. L'astuce du noyau consiste à appliquer une transformation aux données, de manière à les rendre linéairement séparables dans le nouvel espace de représentation.
6. Les données de la classe négative sont inchangées par cette transformation, car elles sont toutes de norme inférieure à 2. Les nouvelles coordonnées des points de la classe positive sont

$$(3, 3), (11, 7), (7, 7), (11, 7)$$

Les classes sont linéairement séparables dans cet espace de représentation.



7. L'hyperplan optimal est la droite d'équation $y = -x + 4$. La marge est $2 \times \sqrt{2} = 2\sqrt{2}$.
8. Si l'on applique la transformation à l'échantillon $(6, 6)$, on obtient comme nouvelles coordonnées $(-1, -1)$. Avec ce noyau, l'échantillon sera donc (probablement faussement) classé négatif.
9. Une transformation possible est $\psi : (x_1, x_2) \mapsto (x_1, x_2, x_1^2 + x_2^2)$, pour séparer les données selon leur norme euclidienne.

4 Décompositions matricielles

1. (a) On a

$$\mathbf{B} = \begin{bmatrix} 3 & -3 & 0 \\ -3 & 3 & 0 \\ 0 & 0 & 6 \end{bmatrix}$$

- (b) $\mathbf{B}$ est de rang 2 (les deux premières colonnes sont colinéaires). $\mathbf{B}$ a donc un noyau non réduit à 0, ce qui signifie qu'il existe $\mathbf{x}$ tel que $\mathbf{B}\mathbf{x} = 0 = 0 \cdot \mathbf{x}$. 0 est donc une valeur propre de $\mathbf{B}$. Un vecteur du noyau est donné par

$$\mathbf{v}_0 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

- (c) On a

$$\mathbf{B} - 6\mathbf{I}_3 = \begin{bmatrix} -3 & -3 & 0 \\ -3 & -3 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Cette matrice est de rang 1. On a

$$(\mathbf{B} - 6\mathbf{I}_3) \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \quad \text{donc} \quad \mathbf{B} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} = 6 \cdot \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

et de même

$$\mathbf{B} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = 6 \cdot \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$\mathbf{v}_1 = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$ et $\mathbf{v}_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$ sont donc deux vecteurs propres non colinéaires associés à la valeur propre 6.

- (d) Les valeurs singulières de A sont les racines des valeurs singulières de $\mathbf{B}$, c'est-à-dire $\sigma_1 = \sigma_2 = \sqrt{6}$ et $\sigma_3 = 0$. Les vecteurs singuliers droits associés sont $\mathbf{v}_1, \mathbf{v}_2$ et $\mathbf{v}_0$ respectivement (que l'on normalise usuellement).

2. On a

$$\begin{aligned} \text{Tr}(\mathbf{X}^\top \mathbf{X}) &= \text{Tr}(\mathbf{V}\Sigma\mathbf{U}^\top \mathbf{U}\Sigma\mathbf{V}^\top) \\ &= \text{Tr}(\mathbf{V}\Sigma\Sigma\mathbf{V}^\top) \\ &= \text{Tr}(\mathbf{V}^\top \mathbf{V}\Sigma^2) \\ &= \text{Tr}(\Sigma^2) \\ &= \sum_{i=1}^r \sigma_i^2 \end{aligned}$$

où l'on a utilisé dans l'ordre l'orthogonalité de $\mathbf{U}$, $\text{Tr}(AB) = \text{Tr}(BA)$, et l'orthogonalité de $\mathbf{V}$. Le résultat attendu s'obtient en élevant à la puissance 1/2 l'équation précédente.