

Examen « traitements statistiques et big data »

Durée 2 heures • Feuille manuscrite au format A4 autorisée • Calculatrice non autorisée

1 Optimisation numérique.

1.1 Méthode de Newton-Raphson

Soit un problème d'optimisation à deux variable x et y dont le critère est donné par l'expression suivante :

$$J(x, y) = \frac{1}{2}x^2 + \frac{9}{2}y^2 - x - 18y + 20$$

1. Donner l'expression du gradient du critère et calculer le.
2. Donner l'expression de la matrice hessienne du critère et calculer la.
3. En considérant que l'algorithme itératif de Newton-Raphson est initialisé à des valeurs quelconques x_0 et y_0 , dérouler cet algorithme pour déterminer les valeurs suivantes notées x_1 et y_1 en expliquant vos calculs.
4. Que constatez-vous ? Commentez.
5. Que vaut le minimiseur ? Que vaut le minimum du critère ?

1.2 Formulation d'un problème d'optimisation

On souhaite déterminer un parallélépipède rectangle de volume unité ($V = 1$) avec une surface S minimale.

1. Formuler ce problème comme un problème d'optimisation en précisant les variables de décision, le critère et les contraintes.
2. Transformer l'expression du critère pour faire apparaître une fonction de deux variables de décision.
3. Représenter le critère dans le plan d'une seule variable de décision, en fixant une valeur pour l'autre variable de décision. Donner sur le graphe les valeurs du critère pour quelques valeurs de la variable de décision libre.

2 Classification.

2.1 SVM à noyau

On considère un problème de classification à deux classes avec la base d'apprentissage :

$$\mathbf{X} = \begin{bmatrix} -2 \\ -1 \\ 0 \\ 1 \\ 2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 1 \\ -1 \\ -1 \\ 1 \\ 1 \end{bmatrix}$$

où $\mathbf{X}$ contient les observations et $\mathbf{y}$ les classes associées. Noter que chaque observation x_i ($i = 1, \dots, 5$) est un scalaire (dans $\mathbb{R}$).

1. Représenter les observations par des $\circ$ sur le segment de la figure 1(a) en utilisant deux couleurs différentes pour bien distinguer les classes 1 et -1 .

2. Les classes sont-elles linéairement séparables ?
3. Dans l'affirmative, représenter sur la même figure un hyperplan séparateur. Sinon, tracer un hyperplan qui conduit à un minimum de mauvaises classifications en précisant ce nombre.
4. On se propose maintenant de transformer les données dans un espace de représentation $\mathbb{R}^2$ en utilisant une fonction de redescription $\Phi(x)$ telle que :

$$\begin{aligned}\Phi : \quad \mathbb{R} &\rightarrow \mathbb{R}^2 \\ x &\mapsto [x, x^2]\end{aligned}$$

- (a) On note $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2]$ la matrice à deux colonnes des données projetées. Calculer leurs coordonnées ($\mathbf{z}_1$ et $\mathbf{z}_2$) en utilisant les données d'apprentissage.
- (b) Représenter les données projetées sur la figure 1(b) en utilisant les mêmes couleurs que la question 1.
- (c) Les classes sont-elles linéairement séparables ? Dans l'affirmative, tracer sur la même figure le séparateur à marge maximum et calculer la marge.
- (d) Quels sont les vecteurs de supports ?
- (e) Que se passe-t-il si l'on retire l'observation x_4 (considérée comme valeur aberrante) des données d'apprentissage ? Expliquer en quelques lignes ce que devient l'hyperplan séparateur dans l'espace de redescription et la marge associée.




FIGURE 1 – Grilles de représentation des données à classifier (SVM).

3 Décompositions matricielles.

3.1 Valeurs propres et valeurs singulières

Soit $\mathbf{X}$ une matrice réelle de dimensions $m \times n$ avec $m > n$. On définit une matrice $\mathbf{C} = \mathbf{X}\mathbf{X}^\top$.

1. Les valeurs propres λ_i de la matrice $\mathbf{C}$, correspondent-elles aux :
 - (a) valeurs singulières de $\mathbf{C}$?
 - (b) valeurs singulières σ_i de $\mathbf{X}$?
 - (c) carrés des valeurs singulières σ_i de $\mathbf{X}$?
2. Les vecteurs propres de la matrice $\mathbf{C}$, correspondent-ils aux :
 - (a) vecteurs singuliers à gauche de $\mathbf{X}$?
 - (b) vecteurs propres de $\mathbf{X}$?
 - (c) vecteurs singuliers à droite de $\mathbf{X}$?

3.2 La SVD

Considérons la matrice $\mathbf{X}$ suivante :

$$\mathbf{X} = \begin{bmatrix} 0 & 1 \\ 1 & 2 \\ 2 & 0 \end{bmatrix}.$$

1. Calculer le produit $\mathbf{C} = \mathbf{X}\mathbf{X}^\top$.
2. Quel est le rang de $\mathbf{C}$?
3. Quels vecteurs parmi les suivants sont des vecteurs propres de la matrice $\mathbf{C}$?
(a) $\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$ (b) $\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ (c) $\begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix}$ (d) $\begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$ (e) $\begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}$ (f) $\begin{bmatrix} 4 \\ -2 \\ 1 \end{bmatrix}$
4. Quelles sont les valeurs propres associées ? Combien y a-t-il de valeurs propres positives ?
5. Trouver les valeurs singulières $\sigma_1 \geq \sigma_2 \geq \sigma_3$ de $\mathbf{X}$.
6. Calculer la meilleure approximation $\mathbf{X}_1 = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^\top$ de rang 1 (par rapport à la norme de Frobenius), en utilisant les propriétés suivantes :
 - les vecteurs singuliers à gauche doivent être normalisés ($\|\mathbf{u}_k\|_2 = 1$) ;
 - les vecteurs singuliers à droite peuvent être obtenus par $\mathbf{v}_k = \frac{1}{\sigma_k} \mathbf{X}^\top \mathbf{u}_k$ à partir de vecteurs singuliers à gauche $\mathbf{u}_k$ (normalisés) et des valeurs singulières σ_k .
7. Calculer l'erreur d'approximation $\|\mathbf{X} - \mathbf{X}_1\|_F$, où $\|\mathbf{Y}\|_F$ est la norme de Frobenius :

$$\|\mathbf{Y}\|_F^2 = \sum_{i,j} (Y(i,j))^2.$$